

MÉMOIRE

Présenté en vue de l'obtention du Master en Ingénieur de gestion (finalité spécialisée)

IA générative et complémentarités organisationnelles : à quelles conditions l'encadrement améliore-t-il le travail du savoir ? Un essai contrôlé randomisé.

Par Sallah DASSY

Directeur : Professeur Nicolas van Zeebroeck

Assesseur : Professeur Eric Grunberger

Année académique 2025-2026

J'autorise la consultation de ce mémoire.



Remerciements

Je tiens à exprimer ma plus sincère gratitude à mon promoteur, le Professeur Nicolas van Zeebroeck, pour la confiance qu'il m'a accordée, sa disponibilité tout au long de ce travail et la rigueur exigeante de ses retours, qui ont constamment élevé le niveau de ce mémoire. Ses orientations en ont façonné aussi bien la conception que l'interprétation des résultats.

Je remercie chaleureusement Danylav, mon camarade, qui a accepté d'évaluer avec moi les 194 textes rédigés par les participants à l'étude. Son sérieux et son engagement ont été essentiels à la fiabilité de cette évaluation, et je lui suis reconnaissant du temps qu'il y a consacré.

Ma reconnaissance va également à chacune des personnes qui ont accepté de participer à l'expérience et d'y consacrer de leur temps. Sans leur curiosité et leur engagement, cette recherche, qui repose entièrement sur leur contribution, n'aurait tout simplement pas été possible.

Je pense ensuite à ma mère, à qui je dois bien plus que ces quelques lignes ne sauraient dire. Son soutien n'a jamais faibli, en toutes circonstances et depuis toujours ; sa confiance, sa présence et les sacrifices qu'elle a consentis tout au long de mon parcours ont rendu possibles mes études et, avec elles, ce travail. Elle a été, et demeure, un appui d'une force inestimable.

Je remercie aussi ma sœur et mon frère pour leur soutien constant, ainsi que ma famille, mes proches et mes camarades de classe, dont les encouragements ne m'ont jamais fait défaut.

Mes remerciements les plus profonds reviennent enfin à celle qui partage ma vie. Pour sa patience, pour le soutien sans faille qu'elle a toujours su être et pour tout ce qu'elle a accompli pour moi durant ces années d'études : elle a été, à chaque instant, le plus solide des appuis, et c'est à elle que je dois, plus qu'à quiconque, d'avoir mené ce travail à son terme.

Résumé

L'intelligence artificielle générative améliore la productivité individuelle des travailleurs du savoir, mais ses gains s'accompagnent de coûts cachés (surconfiance, substitution de l'effort cognitif, homogénéisation des productions) que la seule volonté de vérifier ne suffit pas à corriger. Ce mémoire part d'une hypothèse transposée de la théorie des complémentarités de Milgrom & Roberts (1995) au niveau du comportement individuel : l'IA ne produirait des gains durables que couplée à des mécanismes organisationnels d'encadrement, de la même manière que l'investissement digital ne produit de rendement que couplé à un renouvellement stratégique (Bughin & van Zeebroeck, 2021).

Pour la tester, un essai contrôlé randomisé à trois conditions a été conduit auprès de 97 jeunes adultes francophones (analyse principale en intention de traiter, sensibilité sur 85 participants après exclusions) sur une tâche de rédaction analytique. La condition C1 (contrôle) travaille sans IA ; la condition C2 dispose d'un accès libre à un chatbot (GPT-4o) ; la condition C3 structure cet accès en deux étapes : une production initiale autonome, puis une phase où l'IA critique le texte du participant, en signalant ses faiblesses et ses hypothèses implicites, sans jamais rédiger à sa place. Chaque participant réalise d'abord une tâche de référence sans IA, qui mesure sa capacité de base. La qualité des productions est évaluée en aveugle de la condition par deux évaluateurs, et complétée par des indicateurs objectifs : fiabilité factuelle, traces d'usage de l'IA, similarité entre productions et calibration entre confiance et performance.

Trois résultats se dégagent. D'abord, l'accès libre accélère fortement le travail, tandis que l'encadrement n'apporte aucun gain de vitesse. Ensuite, l'encadrement déplace effectivement le comportement d'un mode substitutif, où l'utilisateur délègue et recopie, vers un mode complémentaire, où il produit puis révise. Enfin, l'hypothèse centrale n'est pas confirmée : sur cette tâche que l'IA traite avec compétence, l'accès libre obtient la qualité évaluée la plus élevée et l'encadrement la plus basse. Cet avantage de l'accès libre n'est toutefois ni général ni de fond : il se concentre sur les dimensions visibles du texte (rédaction, structure, longueur), ne se retrouve ni sur la fiabilité factuelle ni sur le jugement critique, et s'accompagne de deux coûts que l'encadrement permet de contenir, l'homogénéisation des productions et le découplage entre la confiance déclarée et la performance réelle.

L'encadrement ne garantit donc pas un meilleur livrable lorsque l'IA est déjà compétente sur la tâche ; sa valeur se situe ailleurs, dans la préservation du jugement, de la diversité et de la lucidité de l'utilisateur, que l'usage libre érode silencieusement. Cette valeur dépend de la faillibilité de l'IA pour la tâche et de l'appropriation effective du dispositif par l'utilisateur, ce qui invite à concevoir la supervision humaine non comme une simple consigne, mais comme une capacité organisationnelle qui se construit et se soutient.

Table des matières

Remerciements	1
Résumé	2
1 Introduction	8
2 Revue de littérature	11
2.1 La promesse : gains de productivité et égalisation des performances	11
2.2 Les failles : frontière dentelée, surconfiance et coûts cachés	14
2.3 Les solutions : fonctions de forçage cognitif et garde-fous organisationnels	18
2.4 Cadre théorique des complémentarités et hypothèses	22
3 Méthodologie	26
3.1 Plan expérimental	26
3.2 Participants	28
3.3 Tâches expérimentales	29
3.4 Conditions expérimentales	31
3.5 Opérationnalisation des variables	34
3.6 Hypothèses opérationnalisées	39
3.7 Plan d'analyse statistique	39
3.8 Plateforme expérimentale	41
3.9 Protocole éthique	42
3.10 Limites méthodologiques	42
4 Résultats	43
4.1 Description de l'échantillon	43
4.1.1 Recrutement et attrition	43
4.1.2 Caractéristiques de l'échantillon analysable	44
4.1.3 Détail des participants signalés <i>excluded</i>	44
4.1.4 Vérification de l'équilibre de la randomisation	45
4.2 Vitesse de complétion (H1)	45
4.2.1 Choix de la mesure : temps actif et non temps horloge	46
4.2.2 Statistiques descriptives	46
4.2.3 Analyse de covariance	47
4.3 Mode d'interaction avec l'IA, mesures objectives (H3, partie 1)	49
4.3.1 Sémantique du nombre de messages selon la condition	49
4.3.2 Définition opérationnelle de l'« usage effectif » de l'IA en C3	49
4.3.3 Taux de rétention textuelle	50
4.3.4 Nombre de messages utilisateur délibérés	51
4.4 Mode d'interaction avec l'IA, auto-rapport (H3, partie 2)	52
4.5 Engagement intra-condition C3 (analyse exploratoire)	55
4.6 Qualité globale (H2)	56
4.6.1 Fiabilité inter-évaluateurs	56

4.6.2	Statistiques descriptives et analyse de covariance	57
4.6.3	Décomposition par dimension : un avantage de surface	58
4.6.4	Le rôle de la longueur	59
4.6.5	Robustesse et égalisation	59
4.6.6	Qui révise, et avec quel effet ?	60
4.7	Fiabilité factuelle (VD3)	60
4.8	Surconfiance (H4)	62
4.9	Homogénéisation des productions et contenu des interactions	63
4.10	Synthèse des résultats	64
5	Discussion	65
5.1	Interprétation des résultats à la lumière de la littérature	65
5.1.1	La vitesse et le mode d'interaction : des effets attendus, de magnitude exceptionnelle	65
5.1.2	Le paradoxe central : un encadrement qui transforme le comportement sans améliorer la qualité (H2)	66
5.1.3	Pourquoi l'encadrement n'améliore pas la qualité : trois explications convergentes	66
5.1.4	Les coûts cachés de l'IA libre : homogénéisation et découplage de la confiance .	67
5.1.5	Égalisation et équité : qui bénéficie, qui s'engage	67
5.1.6	Retour au cadre des complémentarités : une hypothèse conditionnelle à la frontière technologique	68
5.1.7	L'encadrement comme capacité organisationnelle, non comme simple consigne .	68
5.2	Limites méthodologiques	69
5.2.1	Validité interne	69
5.2.2	Validité externe	69
5.2.3	Validité écologique	70
5.2.4	La limite décisive : une tâche située à l'intérieur de la frontière technologique .	70
6	Conclusion	71
6.1	Implications managériales	71
6.2	Implications pour la gouvernance de l'IA	72
6.3	Pistes de recherche futures	73
	Déclaration sur l'utilisation de l'IA générative	75
	Bibliographie	76
A	Tableaux de synthèse de la revue de littérature	80
A.1	Essais contrôlés randomisés sur la productivité avec IA générative	80
A.2	Interventions testées et efficacité empirique	80
B	Dossiers des tâches expérimentales	82
B.1	Tâche de référence (<i>baseline</i>) : déclin de fréquentation d'une médiathèque	82
B.2	Tâche expérimentale : évaluation d'une stratégie de l'auto-école Starter	82
B.3	System prompt de la condition C3	84
C	Calibration du <i>system prompt</i> de la condition C3	86
C.1	Protocole de calibration	86
C.2	Brouillon initial soumis au chatbot	86

C.3	Tableau récapitulatif des 20 scénarios	87
C.4	Réponses détaillées du modèle	87
D	Grille de notation : ancres des quatre dimensions	93
E	Grille d'extraction de la VD3 (fiabilité factuelle)	96
E.1	Cadre méthodologique	96
E.2	Conventions d'extraction	96
E.3	Grille de la tâche de référence (<i>baseline</i> , médiathèque)	97
E.4	Grille expérimentale (auto-école Starter)	97
F	Structure des données et code d'analyse	99
F.1	Dictionnaire des données	99
F.2	Code d'analyse	101

Table des figures

2.1	Effets de l'accès à ChatGPT sur le temps de complétion et la qualité de la rédaction professionnelle. Source : Noy & Zhang (2023).	11
2.2	La courbe en J de la productivité : les investissements complémentaires intangibles dépriment d'abord la productivité mesurée avant de produire des gains. Source : Brynjolfsson, Rock & Syverson (2021).	13
2.3	La frontière technologique dentelée de l'IA : des tâches de difficulté perçue comparable peuvent se situer à l'intérieur ou à l'extérieur des capacités du modèle. Source : Dell'Acqua et al. (2023).	14
2.4	Performance sur une tâche située hors de la frontière technologique : le taux de réponses correctes chute de 84,5 % (contrôle) à 60,0 % et 70,6 % avec l'accès à l'IA. Source : Dell'Acqua et al. (2023).	15
2.5	Rendement des investissements digitaux selon le degré de renouvellement stratégique : le rendement moyen masque une forte variance, nul sans renouvellement et négatif sous forte turbulence. Figure recréée d'après les coefficients rapportés par Bughin & van Zeebroeck (2021).	23
2.6	Transposition au niveau micro-comportemental de l'hypothèse de complémentarité validée au niveau macro-organisationnel. La condition C3 joue, à l'échelle individuelle, le rôle que joue le renouvellement stratégique à l'échelle de l'entreprise : c'est ce couplage qui permet à la technologie de produire ses gains.	24
3.1	Architecture en deux étapes de la condition C3 (IA guidée) : une production initiale obligatoire sans IA, suivie d'une étape de critique-révision en mode sounding board.	32
4.1	Attrition par phase du protocole.	43
4.2	Temps actif de complétion de la tâche expérimentale par condition.	47
4.3	Temps actif expérimental vs. tâche de référence, par condition.	48
4.4	Taux de rétention textuelle, C2 vs. C3.	50
4.5	Rétention textuelle stratifiée par usage effectif du chatbot en C3.	51
4.6	Sous-échelles d'usage déclaré de l'IA (Hou et al., 2025).	52
4.7	Effort cognitif perçu par condition.	54
4.8	Performance perçue par condition.	55
4.9	Croisement dialogue × révision en C3.	56
4.10	Qualité globale de la production expérimentale par condition.	57
4.11	Qualité par dimension et par condition.	58
4.12	Longueur des productions expérimentales par condition.	59
4.13	Fiabilité factuelle (F1-Score) par condition.	61
4.14	Performance perçue vs. performance réelle, par condition.	62
4.15	Similarité intra-condition des productions.	63

Liste des tableaux

4.1	Répartition des participants par condition (échantillon phase 5, n = 97).	44
4.2	Équilibre de la randomisation sur les facteurs stratifiés (échantillon PP, n = 85).	45
4.3	Comparaison des deux opérationnalisations du temps de complétion expérimental (ITT, n = 97).	46
4.4	Temps actif de complétion de la tâche expérimentale par condition (ITT, n = 97).	47
4.5	ANCOVA sur le temps actif de la tâche expérimentale (ITT, n = 97). Sommes des carrés de type III. Les valeurs ajustées (<i>estimated marginal means</i>) tiennent compte des covariables.	48
4.6	Contrastes planifiés sur le temps actif expérimental (ANCOVA, ajustement Holm).	48
4.7	Taux de rétention textuelle (RDL normalisé), C2 et C3 (PP).	51
4.8	Nombre de messages utilisateur délibérés par condition (ITT phase 5).	52
4.9	Sous-échelles d'usage déclaré de l'IA (Hou et al., 2025), C2 et C3 (PP).	53
4.10	Distribution des comportements de révision entre la version fin d'étape A et la version finale soumise, condition C3 (n = 33).	55
4.11	Qualité globale de la production expérimentale par condition (ITT, n = 97; échelle 1 à 4).	57
4.12	Contrastes planifiés sur la qualité globale (ANCOVA, ITT; estimations en points sur l'échelle 1 à 4).	58
4.13	Fiabilité factuelle de la production expérimentale par condition (PP).	61
4.14	Performance perçue et réelle par condition (PP).	62

Chapitre 1

Introduction

L'intelligence artificielle générative produit des gains de productivité individuels que les essais contrôlés randomisés mesurent de manière convergente : réduction de 37 % du temps de complétion sur des tâches rédactionnelles (Noy & Zhang, 2023), hausse de 15 % de la productivité d'agents de support client (Brynjolfsson, Li & Raymond, 2023), augmentation de 26 % du nombre de tâches complétées (*pull requests*) par des développeurs logiciels dans trois entreprises (Cui et al., 2025). Un résultat secondaire traverse cette littérature : l'IA bénéficie de manière disproportionnée aux travailleurs initialement les moins performants, comprimant la distribution de productivité plutôt que de l'élargir (Noy & Zhang, 2023 ; Brynjolfsson, Li & Raymond, 2023 ; Cui et al., 2025). La traduction de ces gains microéconomiques en productivité agrégée n'est cependant pas automatique : Brynjolfsson, Rock & Syverson (2019) parlent à ce titre d'un « paradoxe de productivité moderne », rappelant que l'électrification industrielle mit environ trente ans à se traduire en gains agrégés. Pourquoi les gains individuels ne se traduisent-ils pas immédiatement en productivité agrégée, et à quelles conditions pourraient-ils le faire ?

L'ampleur de l'exposition des travailleurs du savoir à cette technologie est sans précédent. Eloundou et al. (2024), à partir d'une annotation systématique de 19 265 tâches du répertoire O*NET par des humains et par GPT-4, estiment qu'environ 80 % de la main-d'œuvre américaine pourrait voir au moins 10 % de ses tâches affectées par les grands modèles de langage. Ce schéma contraste avec les vagues d'automatisation précédentes, qui touchaient les emplois routiniers et peu qualifiés : Felten, Raj & Seamans (2023) montrent que l'exposition à l'IA générative est positivement et significativement corrélée au salaire médian et au niveau de formation requis, les professions les plus exposées incluant les enseignants du supérieur en sciences humaines et diverses professions du langage et de l'analyse. L'IA générative n'automatise pas des gestes ; elle intervient sur la matière première du travail du savoir.

Mais la traduction de ces gains individuels en progrès agrégé n'est pas acquise. Acemoglu (2024) estime le gain de productivité agrégée attribuable à l'IA bien en deçà des prévisions les plus optimistes, parce que les essais existants portent sur des tâches faciles à automatiser tandis que les tâches complexes y résistent. Une part de l'explication tient aux investissements organisationnels complémentaires qu'une technologie à usage général requiert avant de produire ses gains, ce qui pourrait rendre les effets de l'IA réels mais encore invisibles (Brynjolfsson, Rock & Syverson, 2021).

Au niveau individuel, les mêmes expériences qui documentent des gains révèlent des vulnérabilités systématiques. Dell'Acqua et al. (2023) mettent en évidence une « frontière technologique dentelée » (*jagged technological frontier*) : sur les tâches situées à l'extérieur des capacités de l'IA, les utilisateurs adoptent ses conclusions erronées sans examen critique, dégradant significativement leur performance par rapport au groupe contrôle. Noy & Zhang (2023) rapportent que 68 % des participants soumettent le texte de l'IA sans le modifier. Bastani et al. (2025) montrent dans un RCT publié dans *PNAS* que l'accès libre à GPT-4 dégrade les résultats à l'examen de 17 % par rapport au groupe contrôle lorsque l'IA n'est plus disponible, l'outil agissant comme une béquille cognitive plutôt que comme un complément. La surconfiance, la substitution de l'effort cognitif et l'homogénéisation des productions constituent des coûts cachés dont le chapitre suivant documente l'étendue et les mécanismes.

La résolution de ce double paradoxe, gains micro réels mais stagnation macro d'une part, productivité immédiate mais coûts différés d'autre part, repose, selon l'hypothèse centrale de ce mémoire, sur la notion de complémentarités. Milgrom & Roberts (1995) formalisent cette idée à l'aide de la théorie de la supermodularité : des activités sont complémentaires lorsque « faire davantage de l'une augmente les rendements de faire davantage des autres » (p. 181). Le changement partiel, l'introduction d'une technologie sans les ajustements organisationnels correspondants, peut alors avoir des rendements nuls ou négatifs, comme l'illustre l'échec de l'automatisation massive de General Motors dans les années 1980, faute d'ajustement des processus et des politiques de ressources humaines (Milgrom & Roberts, 1995). Bughin & van Zeebroeck (2021) valident ce cadre dans le contexte de la transformation digitale : le rendement des investissements digitaux, bien que substantiel en moyenne, disparaît en l'absence de renouvellement stratégique et devient négatif sous haute turbulence concurrentielle. Ce résultat fonde l'hypothèse du présent mémoire : au niveau micro-comportemental, les mécanismes organisationnels d'encadrement de l'IA jouent le même rôle de complément que le renouvellement stratégique joue au niveau organisationnel.

La question de recherche centrale est la suivante : l'introduction de mécanismes organisationnels d'encadrement modifie-t-elle la nature et l'ampleur des gains de productivité associés à l'utilisation de l'IA générative sur des tâches de travail du savoir ? Trois sous-questions la structurent. L'accès libre à l'IA, sans encadrement, améliore-t-il effectivement la productivité et la qualité du travail par rapport à un groupe contrôle sans IA ? L'ajout de mécanismes organisationnels transforme-t-il cette relation, notamment sur les dimensions de fiabilité factuelle et de qualité analytique ? Et les mécanismes organisationnels modifient-ils le processus même d'utilisation de l'IA, en déplaçant l'interaction d'un mode substitutif vers un mode complémentaire ?

Pour répondre à ces questions, ce mémoire propose un essai contrôlé randomisé à trois conditions. Chaque participant réalise d'abord une tâche de référence de rédaction sans accès à l'IA (*baseline*), qui mesure sa capacité de base, puis une tâche expérimentale de rédaction analytique dans la condition qui lui est assignée. La condition C1 (contrôle) fait réaliser cette tâche expérimentale sans accès à l'IA ; la condition C2 (IA libre) donne accès à un chatbot reposant sur GPT, sans encadrement ni contrainte ; la condition C3 (IA guidée) donne accès au même chatbot mais structure son usage en deux étapes successives : une production initiale obligatoire sans accès à l'IA, suivie d'une étape de critique-révision durant laquelle l'IA identifie les hypothèses implicites, signale les éléments à vérifier et refuse de rédiger directement à la place du participant, pendant que celui-ci révisé son texte. Cette architecture est entièrement justifiée par des résultats empiriques convergents documentés dans la revue de littérature. Le dispositif est complété par un questionnaire post-tâche et par l'analyse des données d'interaction issues des logs du chatbot, afin de documenter le processus d'utilisation de l'IA au-delà de ses seuls résultats.

La littérature existante a documenté les gains de l'IA libre (Noy & Zhang, 2023 ; Brynjolfsson, Li & Raymond, 2023 ; Cui et al., 2025), les risques de l'utilisation non encadrée (Dell'Acqua et al., 2023 ; Bastani et al., 2025) et l'efficacité de certaines interventions cognitives prises isolément (Bućinca et al., 2021 ; Bastani et al., 2025 ; Ghosh et al., 2026). Le présent mémoire s'en distingue en testant un dispositif qui combine, dans une architecture séquentielle structurée, plusieurs interventions empiriquement validées (engagement cognitif préalable obligatoire, interaction en mode *sounding board*, identification des hypothèses implicites) plutôt qu'une intervention unique isolée. Il transpose ainsi au niveau micro-comportemental l'hypothèse de complémentarité que Milgrom & Roberts (1995) formalisent en théorie et que Bughin & van Zeebroeck (2021) valident au niveau macro-organisationnel. La question est d'autant plus pertinente que le cadre européen de régulation de l'IA (Règlement (UE) 2024/1689) impose aux organisations des mécanismes de supervision humaine pour les systèmes à haut risque, alors que

la question de savoir lesquels produisent effectivement les résultats escomptés reste encore largement ouverte.

Le mémoire s'organise comme suit. Le chapitre 2 propose une revue de la littérature structurée en quatre temps : les gains de productivité et l'effet d'égalisation documentés dans les essais contrôlés randomisés (section 2.1), les failles et les coûts cachés de l'utilisation non encadrée (section 2.2), les interventions et garde-fous organisationnels dont l'efficacité a été démontrée empiriquement (section 2.3), et le cadre théorique des complémentarités qui intègre ces résultats et en dérive quatre hypothèses testables (section 2.4). Le chapitre 3 détaille la méthodologie : plan expérimental à trois conditions, opérationnalisation des variables dépendantes et de contrôle, et plan d'analyse statistique. Le chapitre 4 présente les résultats quantitatifs du RCT. Le chapitre 5 discute ces résultats à la lumière de la littérature et en expose les limites méthodologiques. Le chapitre 6 en tire les implications, sous forme de recommandations managériales pour l'intégration de l'IA en entreprise et d'enseignements pour la gouvernance européenne de l'IA (Règlement (UE) 2024/1689), et identifie les pistes de recherche future.

Chapitre 2

Revue de littérature

2.1 La promesse : gains de productivité et égalisation des performances

L'émergence des grands modèles de langage (LLMs) a suscité un intérêt considérable quant à leur potentiel d'amélioration de la productivité des travailleurs du savoir. Contrairement aux vagues d'automatisation précédentes, qui ciblaient les tâches routinières et codifiables (Autor et al., 2003), l'IA générative opère sur des tâches créatives et cognitives historiquement réservées à l'expertise humaine (Noy & Zhang, 2023). Eloundou et al. (2024) estiment qu'environ 80 % de la main-d'œuvre américaine pourrait voir au moins 10 % de ses tâches affectées par les LLMs (19 % des travailleurs dans des métiers où plus de la moitié des tâches sont exposées), et Felten, Raj & Seamans (2023) soulignent que les métiers les plus exposés sont cette fois les professions qualifiées et bien rémunérées (rédacteurs, analystes, enseignants), et non les emplois routiniers peu qualifiés des vagues précédentes. Une série d'essais contrôlés randomisés (RCT) conduits entre 2023 et 2025 fournit désormais des estimations causales de cet impact au niveau microéconomique.

Des gains de productivité substantiels et convergents

Les premiers RCT à grande échelle documentent des gains de productivité significatifs lorsque les travailleurs accèdent librement à un outil d'IA générative. Noy & Zhang (2023), dans une expérience portant sur 444 professionnels qualifiés, montrent que l'accès à ChatGPT réduit le temps de complétion de tâches rédactionnelles de 37 % tout en augmentant la qualité évaluée par des pairs en aveugle de 0,45 écart-type, sur les trois dimensions mesurées (qualité rédactionnelle, contenu, originalité).




FIGURE 2.1. Effets de l'accès à ChatGPT sur le temps de complétion et la qualité de la rédaction professionnelle. Source : Noy & Zhang (2023).

Brynjolfsson, Li & Raymond (2023) confirment ces gains dans un contexte radicalement différent, celui du déploiement échelonné d'un assistant conversationnel basé sur GPT auprès de 5 172 agents de support client d'une entreprise Fortune 500. L'accès à l'outil augmente la productivité de 15,2 % (résolutions par heure), réduit d'environ 25 % les escalades managériales et de 40 % l'attrition des agents récemment embauchés, suggérant que l'IA améliore non seulement la productivité mais aussi les conditions de travail.

Le plus grand RCT de terrain à ce jour, publié dans *Management Science*, porte sur 4 867 développeurs logiciels répartis dans trois entreprises (Microsoft, Accenture et une entreprise Fortune 100 du secteur électronique). Cui et al. (2025) estiment que l'accès randomisé à GitHub Copilot augmente de 26 % le nombre de *pull requests* complétées chez les développeurs qui adoptent l'outil, un effet plus faible si l'on inclut les 30 à 40 % qui ne l'utilisent pas malgré l'accès gratuit : l'adoption volontaire n'est pas automatique.

La convergence de ces résultats, obtenus dans des contextes variés (rédaction professionnelle, support client, développement logiciel), avec des populations, des outils (ChatGPT, GPT fine-tuné, GitHub Copilot) et des plans méthodologiques différents (RCT en ligne, quasi-expérience naturelle, RCT de terrain), constitue un faisceau de preuves robuste en faveur d'un effet positif de l'IA générative sur la productivité au niveau microéconomique.

Un effet d'égalisation systématique

Au-delà de l'effet moyen, un résultat remarquablement convergent émerge de la littérature : l'IA générative bénéficie de manière disproportionnée aux travailleurs initialement les moins performants, comprimant ainsi la distribution de productivité.

Noy & Zhang (2023) observent que la pente de régression entre la performance à la tâche 1 (sans IA) et la tâche 2 (avec IA) passe de 0,49 dans le groupe contrôle à 0,25 dans le groupe traité. Les travailleurs initialement faibles améliorent principalement la qualité de leur production, tandis que les travailleurs initialement forts maintiennent leur qualité en gagnant du temps.

Brynjolfsson et al. (2023) trouvent un gradient encore plus prononcé : les agents du quintile le plus bas gagnent +36 % quand ceux du quintile supérieur ne montrent aucun gain significatif, un agent de deux mois d'ancienneté assisté par l'IA égalant un agent de six mois sans IA. Dell'Acqua et al. (2023) confirment ce schéma chez 758 consultants BCG : sur les tâches situées à l'intérieur de la frontière technologique de l'IA (*inside the frontier*, celles qu'elle traite avec compétence comme la rédaction persuasive ou la génération d'idées), le demi-inférieur gagne +43 % en qualité contre +17 % pour le demi-supérieur. Doshi & Hauser (2024) l'étendent au domaine créatif (les rédacteurs les moins créatifs rejoignent les plus créatifs grâce aux idées générées par GPT-4) et Cui et al. (2025) à la programmation (les développeurs de faible ancienneté progressent de 27 à 39 % contre 8 à 13 % pour ceux de forte ancienneté).

Ce résultat est théoriquement significatif car il inverse la logique du changement technologique biaisé en faveur des compétences (*skill-biased technical change*) qui caractérisait les vagues d'automatisation précédentes (Autor et al., 2003 ; Felten et al., 2023). Brynjolfsson et al. (2023) proposent un mécanisme : l'outil d'IA, entraîné sur les conversations des meilleurs agents, agit comme un vecteur de dissémination des pratiques tacites (*tacit knowledge*), transférant les comportements des *top performers* vers les agents moins qualifiés et transmettant un savoir organisationnel auparavant difficile à articuler et à enseigner.

Du micro au macro : limites de la transposition

Si les gains microéconomiques sont réels, leur magnitude est sensible au contexte et leur traduction en gains macroéconomiques reste incertaine. Cui et al. (2025) soulignent que leur estimation de +26 % est « substantiellement plus faible que la réduction de 58 % du temps de complétion trouvée par Peng et al. (2023) en laboratoire » (p. 12) : en milieu réel, le codage n'est qu'une partie du travail et le temps gagné ne se convertit pas intégralement en production, les autres activités constituant un goulot d'étranglement.

L'adoption n'est par ailleurs pas automatique même gratuite : 30 à 40 % des développeurs n'essaient pas l'outil (Cui et al., 2025).

Acemoglu (2024) montre que ces gains micro ne se traduisent pas mécaniquement en gains macro : croisant les données d'exposition d'Eloundou et al. (2024) avec les taux d'automatisation rentable, il estime le gain de productivité totale des facteurs à 0,53 à 0,66 % sur dix ans seulement, bien en deçà des prévisions de Goldman Sachs ou de McKinsey, parce que les RCT existants portent sur des tâches « faciles à apprendre » alors qu'au moins 27 % des tâches exposées sont « difficiles à apprendre ». Brynjolfsson, Rock & Syverson (2019, 2021) proposent un cadre complémentaire, la « courbe en J » de la productivité : l'introduction d'une technologie à usage général s'accompagne d'investissements complémentaires intangibles (réorganisation des processus, formation, expérimentation) non comptabilisés, qui dépriment la productivité mesurée avant de produire des gains, comme pour l'électrification (David, 1990). Les gains de l'IA générative pourraient ainsi être réels mais encore invisibles, les organisations se trouvant dans la phase descendante de la courbe, à investir dans les compléments organisationnels nécessaires.




FIGURE 2.2. La courbe en J de la productivité : les investissements complémentaires intangibles dépriment d'abord la productivité mesurée avant de produire des gains. Source : Brynjolfsson, Rock & Syverson (2021).

Synthèse des essais contrôlés randomisés

Le tableau A.1, en annexe, synthétise les principaux essais contrôlés randomisés sur la productivité avec IA générative discutés dans ce chapitre (classés par taille d'échantillon décroissante ; les tailles d'effet sont rapportées dans l'unité originale de chaque étude).

La diversité des plans (RCT en ligne, expérience naturelle, RCT de terrain) et des contextes (rédaction, support client, éducation, programmation, conseil) renforce la robustesse des résultats convergents.

Ces observations convergent avec la thèse de Bughin & van Zeebroeck (2021) selon laquelle l'accès à une technologie ne se traduit en gains de productivité que sous certaines conditions organisationnelles, et le résultat le plus contre-intuitif de la littérature illustre cette logique. Kreitmeir & Raschky (2024), exploitant le bannissement temporaire de ChatGPT en Italie (mars 2023) comme expérience naturelle, montrent sur 36 358 utilisateurs GitHub que le ban améliore la productivité et la qualité du code des

développeurs les moins expérimentés (+10 % de probabilité d'activité productive après le ban) tout en pénalisant les experts sur les tâches routinières (résolution d'issues : $-0,77$ pp, $p < 0,10$). Que les novices performant mieux sans l'IA sur des tâches complexes suggère que les gains d'égalisation documentés ailleurs pourraient être en partie illusoire, masquant une dépendance plutôt qu'un véritable apprentissage. Cette tension entre productivité immédiate et développement des compétences à long terme est l'une des questions centrales que les sections suivantes approfondiront.

2.2 Les failles : frontière dentelée, surconfiance et coûts cachés

La section précédente a documenté des gains de productivité réels mais variables au niveau micro, et incertains au niveau macro. La présente section examine les conditions dans lesquelles l'accès libre à l'IA générative, sans mécanismes d'encadrement, produit des résultats nuls ou négatifs, à travers trois phénomènes interconnectés : l'opacité de la frontière technologique de l'IA, la surconfiance systématique des utilisateurs et les coûts cachés au niveau collectif.

La frontière technologique dentelée

Dell'Acqua et al. (2023) introduisent le concept de frontière technologique dentelée (*jagged technological frontier*) pour décrire la nature irrégulière des capacités de l'IA. Contrairement à une frontière lisse, où les capacités progresseraient uniformément avec la difficulté, la frontière de l'IA est dentelée : certaines tâches apparemment complexes (génération d'idées, rédaction persuasive) se situent à l'intérieur de la frontière (*inside the frontier*), où l'IA est compétente, tandis que d'autres apparemment plus simples (intégration de données qualitatives et quantitatives, vérification factuelle) se situent à l'extérieur (*outside the frontier*), où l'IA produit des erreurs systématiques sans signaler son incertitude. Ces deux termes seront utilisés tels quels dans la suite du mémoire.




FIGURE 2.3. La frontière technologique dentelée de l'IA : des tâches de difficulté perçue comparable peuvent se situer à l'intérieur ou à l'extérieur des capacités du modèle. Source : Dell'Acqua et al. (2023).

L'expérience de Dell'Acqua et al., menée avec 758 consultants de BCG, illustre cette dualité. Sur 18 sous-tâches de conception de produit à l'intérieur de la frontière, l'accès à GPT-4 améliore la qualité de +42,5 % et réduit le temps de 22 à 28 %. Mais sur une tâche d'analyse de cas exigeant l'intégration de

données chiffrées et d'indices qualitatifs subtils, située à l'extérieur de la frontière, le taux de réponses correctes chute de 84,5 % (contrôle) à 60 % (GPT + Overview) et 70 % (GPT seul), soit une dégradation de 14,5 à 24,5 points. L'IA, promptée avec les mêmes données, produit une conclusion erronée car elle ne saisit pas les nuances des entretiens qualitatifs, et la majorité des consultants l'adoptent sans la remettre en question.




FIGURE 2.4. Performance sur une tâche située hors de la frontière technologique : le taux de réponses correctes chute de 84,5 % (contrôle) à 60,0 % et 70,6 % avec l'accès à l'IA. Source : Dell'Acqua et al. (2023).

Cette frontière est non seulement irrégulière, elle est aussi largement invisible : même des professionnels qualifiés ne distinguent pas fiablement les tâches que l'IA traite avec compétence de celles où elle échoue. Les modèles se trompent fréquemment (GPT-4 ne répond correctement que dans 51 % des problèmes de mathématiques de lycée chez Bastani et al., 2025 ; Kabir et al., 2024, cités par Kreitmeir & Raschky, 2024, établissent un taux d'erreur de 52 % sur 517 réponses de programmation, dont les utilisateurs ne repèrent pas l'erreur dans 39 % des cas), et ces erreurs passent largement inaperçues, les élèves ayant un accès libre à GPT-4 l'utilisant massivement sans repérer ses fautes logiques. La frontière n'est donc pas seulement dentelée, elle est invisible à ceux qui s'en servent.

La surconfiance face aux systèmes automatisés

Le vrai problème n'est pas que l'IA se trompe, c'est que les utilisateurs ne détectent pas ses erreurs et qu'ils ne cherchent souvent pas à les détecter. Parasuraman & Manzey (2010) appellent ce phénomène la complaisance face à l'automatisation, un biais documenté de longue date dans les sciences cognitives appliquées et dont la robustesse est l'un des résultats les mieux établis du domaine.

Parasuraman & Manzey (2010) synthétisent plusieurs décennies de recherche en aviation, en médecine et en contrôle de processus. En aviation, lors d'un vol simulé, 75 % des pilotes suivent une recommandation automatisée erronée d'éteindre le mauvais moteur, contre 25 % avec une checklist papier ; confrontés à une fausse alerte, 67 % rapportent même avoir « vu » des indications confirmant une panne inexistante (« mémoire fantôme »), le biais distordant rétrospectivement la perception elle-même. En médecine, lorsque les radiologues s'appuient sur un diagnostic assisté par ordinateur, leur taux de détection des cancers non signalés par le système chute de 46 % à 21 %.

La littérature sur l'IA générative reproduit ces schémas avec une régularité remarquable. Noy & Zhang (2023) trouvent que 68 % des participants traités soumettent le texte de ChatGPT sans le modifier, même avec des incitations financières fortes à l'effort (schéma de rémunération convexe avec bonus pour les notes élevées). En moyenne, les participants ne consacrent que 3 minutes à l'édition après avoir collé le

texte de l'IA, et leurs productions ne reçoivent « pas de meilleures notes que le texte brut de ChatGPT » (Section 2.4). Dell'Acqua et al. (2023) rapportent un taux de rétention (*retainment*) dont le mode se situe à environ 0,87 sur une échelle de 0 à 1 (mesuré par la distance de Damerau-Levenshtein restreinte), confirmant un copier-coller quasi intégral des réponses de l'IA.

La relation entre taux de rétention textuelle (le *retainment* de Dell'Acqua et al., soit la proportion du texte de l'IA conservée telle quelle dans la production finale) et performance est toutefois plus complexe qu'il n'y paraît. Dell'Acqua et al. (2023) trouvent que, sur les tâches à l'intérieur de la frontière, un taux de rétention élevé est associé à une meilleure performance (coefficient de régression $\sim 1,21$, hautement significatif). Ce résultat contre-intuitif s'explique de deux manières : l'IA est assez performante sur ces tâches pour que le copier-coller constitue une stratégie rationnelle, ou un prompting itératif de haute qualité aboutit à une production proche de la dernière réponse de l'IA sans abdication du jugement. Ce qui pose problème n'est donc pas le taux de rétention en soi, mais le taux de rétention sur les tâches où l'IA se trompe : sur les tâches à l'extérieur de la frontière, le même copier-coller conduit à adopter des conclusions erronées, et la distinction entre les deux cas échappe aux utilisateurs.

Ce résultat a une implication directe pour la conception d'un dispositif d'encadrement de l'IA. Pénaliser le copier-coller en tant que tel serait une erreur, puisque sur les tâches *inside frontier* ce comportement est rationnel et efficace. La cible doit être le copier-coller appliqué aux tâches où l'IA risque de se tromper. La condition C3 du présent mémoire est conçue précisément dans cette logique : elle ne mesure pas l'édition, elle force l'engagement cognitif préalable et l'identification des hypothèses implicites, deux mécanismes qui restent pertinents quel que soit le type de tâche.

Lee et al. (2025) apportent un éclairage complémentaire à partir d'une enquête auprès de 319 travailleurs du savoir (936 exemples concrets d'utilisation) : la confiance envers l'IA est le prédicteur le plus puissant de la non-mise en œuvre de la pensée critique, devançant tous les facteurs liés à la tâche ou au profil, tandis que la confiance en ses propres compétences est associée à davantage de pensée critique. Ce « schéma dual » prolonge directement la complaisance face à l'automatisation de Parasuraman & Manzey (2010) dans le contexte de l'IA générative. L'étude documente en outre un déplacement de la nature de l'effort cognitif, qui passe de la production d'information à sa vérification, de la résolution de problèmes à l'intégration des réponses de l'IA et de l'exécution des tâches à leur supervision (*stewardship*) : 55 à 79 % des participants rapportent une réduction de l'effort cognitif, la moins prononcée concernant l'évaluation critique des productions (55 %).

Le résultat le plus troublant concerne l'écart entre la performance réelle et la performance perçue : les utilisateurs jugent mal l'effet de l'IA sur leur propre travail. Becker et al. (2025), dans un essai randomisé auprès de seize développeurs expérimentés travaillant sur leurs propres projets, observent que l'accès à l'IA augmente leur temps de réalisation de 19 %, alors que ces mêmes développeurs croient après coup avoir été 20 % plus rapides, soit un écart de près de quarante points entre la réalité et la perception. Cette illusion n'est pas propre aux praticiens : interrogés au préalable, des experts en économie comme en apprentissage automatique prévoyaient eux aussi un gain de temps de l'ordre de 38 à 39 %, à l'opposé du ralentissement réellement observé. Le même aveuglement se retrouve ailleurs : chez Bastani et al. (2025), les élèves dont les résultats se dégradent avec l'IA n'en perçoivent rien, et chez Doshi & Hauser (2024), les rédacteurs assistés ne mesurent pas davantage l'amélioration réelle de leur créativité. Dans tous les cas, la perception se découple de la performance, ce qui fait de la confiance ressentie un indicateur peu fiable de l'effet réel de l'IA.

Parasuraman & Manzey (2010) identifient trois sources distinctes de ce phénomène : (a) une réallocation attentionnelle ouverte, les utilisateurs cessant de vérifier les données brutes ; (b) une cécité inattention-

nelle (*inattentional blindness*), où ils regardent l'information contradictoire mais ne la traitent pas cognitivement ; et (c) un biais décisionnel actif, où ils perçoivent l'information contradictoire mais l'écartent au profit de la recommandation automatisée.

Surtout, les interventions intuitives échouent systématiquement à corriger ces biais : les instructions explicites de vérifier n'ont aucun effet sur les taux d'erreur, soixante minutes de pratique ne réduisent pas la complaisance, et le travail en équipe ne corrige pas le biais (études citées dans Parasuraman & Manzey, 2010). Dell'Acqua et al. (2023) aggravent ce constat : la formation au *prompt engineering* (condition « GPT + Overview »), loin de réduire la surconfiance, l'amplifie. Les consultants formés au prompting sont plus rapides (−30 % de temps) mais significativement moins précis (−24 points d'exactitude) que ceux qui utilisent l'IA sans formation (−18 % de temps, −13 pp) : la formation augmente la confiance envers l'IA, amplifiant le copier-coller et réduisant l'effort de vérification critique.

Coûts cachés : effet béquille, homogénéisation, modalité d'interaction et érosion du capital humain

Au-delà de la surconfiance individuelle, trois coûts cachés émergent de la littérature.

L'effet béquille. Un premier coût caché tient à ce que l'IA, en exécutant la tâche à la place de l'utilisateur, peut l'empêcher d'acquérir les compétences que cette tâche est censée développer : tant que l'outil est disponible la performance est bonne, mais dès qu'il est retiré elle s'effondre. Bastani et al. (2025) en fournissent la démonstration la plus nette dans un essai contrôlé randomisé portant sur environ 1 000 lycéens turcs (*PNAS*). Trois conditions sont comparées : un contrôle sans IA, un groupe « GPT Base » utilisant GPT-4 sans contrainte, et un groupe « GPT Tutor » utilisant le même modèle via un *system prompt* qui le force à guider l'élève étape par étape sans jamais donner directement la réponse.

Pendant les exercices assistés, les deux groupes IA surpassent largement le contrôle (GPT Base +48 %, GPT Tutor +127 %). Mais à l'examen non assisté, sans aucune ressource, GPT Base obtient des notes inférieures de 17 % au contrôle, tandis que GPT Tutor ne s'en distingue plus : les garde-fous du prompt annulent intégralement l'effet béquille. Les auteurs départagent deux explications concurrentes (les erreurs de l'IA égarent les élèves, ou les élèves l'utilisent comme une béquille sans s'engager cognitivement) en faveur de la seconde : 67 % des premiers messages du groupe GPT Base sont des demandes directes de réponse ou des répétitions de l'énoncé, contre 37 % pour GPT Tutor. L'IA non encadrée substitue l'effort cognitif plutôt qu'elle ne le complète, ce qui rejoint l'observation de Brynjolfsson et al. (2023) selon laquelle seuls les agents qui suivent activement les recommandations de l'IA en tirent un apprentissage durable.

L'homogénéisation des productions. Doshi & Hauser (2024), dans une expérience portant sur 293 rédacteurs et 600 évaluateurs, montrent que l'accès à des idées générées par GPT-4 améliore la créativité individuelle évaluée par des tiers (nouveau et utilité) mais réduit la diversité collective : les histoires écrites avec une idée de l'IA sont significativement plus similaires entre elles que celles écrites sans IA. Dell'Acqua et al. (2023) confirment ce résultat : les productions des consultants assistés par GPT-4 présentent une variabilité nettement réduite. L'IA, issue d'un même modèle entraîné sur un même corpus, oriente les utilisateurs vers des espaces de solutions similaires.

Ce coût, invisible au niveau individuel, représente un appauvrissement systématique au niveau collectif et fournit une piste d'explication au décalage entre gains micro et stagnation macro discuté en section 2.1 : si chaque individu gagne en productivité mais que les productions convergent vers un standard moyen, la diversité créative qui alimente l'innovation organisationnelle se réduit, sans que cette perte de

variété soit captée par les indicateurs traditionnels de productivité.

Le rôle déterminant de la modalité d'interaction. Chen & Chan (2024), dans un essai contrôlé randomisé portant sur 355 participants utilisant GPT-4, comparent deux modalités de collaboration sur du contenu publicitaire évalué par des clics réels sur Facebook et Instagram. Dans la modalité *ghostwriter*, l'IA rédige un premier brouillon que l'humain édite ; dans la modalité *sounding board*, l'humain rédige d'abord et l'IA fournit ensuite un retour critique. La première produit des textes significativement plus similaires entre eux et une créativité perçue plus faible, tandis que la seconde permet aux participants non experts d'atteindre un niveau de performance proche de celui des experts, sans les effets d'ancrage observés dans la modalité *ghostwriter*.

Ce résultat est central pour la conception du présent mémoire : l'ordre de l'interaction (qui produit en premier, qui critique ensuite) détermine la qualité du résultat plus encore que la qualité brute du modèle. C'est cette logique qui structure la condition C3, où le participant produit une première version avant de soumettre son travail à la critique de l'IA.

L'érosion du capital humain. Trois études convergent sur un mécanisme inquiétant : l'usage de l'IA peut éroder les compétences qu'elle est censée augmenter. Les élèves de Bastani et al. (2025) sous GPT Base développent moins de compétences que le contrôle, devenant paradoxalement plus dépendants ; chez Kreitmeir & Raschky (2024), les novices privés de ChatGPT produisent un code de meilleure qualité sur les tâches complexes, l'effort de résolution autonome générant un apprentissage que le raccourci par l'IA court-circuite. Brynjolfsson et al. (2023) prolongent la logique aux données elles-mêmes : si les meilleurs agents cessent de produire des réponses originales, les données d'entraînement futures s'appauvrissent. Le risque est donc à double détente : érosion des compétences humaines à court terme, érosion des modèles à long terme.

Ces phénomènes convergent vers un constat : l'accès libre à l'IA générative, sans mécanismes d'encadrement, peut produire des gains de productivité immédiats au prix de coûts différés significatifs. La question devient alors celle des mécanismes permettant de capturer les bénéfices de l'IA tout en neutralisant ses effets délétères.

2.3 Les solutions : fonctions de forçage cognitif et garde-fous organisationnels

La section précédente a établi que la surconfiance envers l'IA est un phénomène robuste, résistant aux instructions simples, à l'entraînement et au travail en équipe (Parasuraman & Manzey, 2010), et que la formation au prompt engineering peut même l'aggraver (Dell'Acqua et al., 2023). La présente section examine les interventions qui ont démontré une efficacité empirique pour réduire la surconfiance et améliorer la qualité de la collaboration humain-IA.

Les fonctions de forçage cognitif

Le cadre des processus duaux (Kahneman, 2011) distingue deux modes de pensée : le Système 1, rapide, automatique et heuristique (reconnaître un visage familier, lire un mot, répondre à « 2 + 2 » sans effort conscient), et le Système 2, lent, délibéré et analytique (calculer « 17 × 24 », évaluer une argumentation, détecter une erreur logique), qui doit être activé volontairement et consomme des ressources cognitives.

Buçinca, Malaya & Gajos (2021) soutiennent que l'interaction avec une IA recommandatrice maintient les utilisateurs en mode Système 1 : plutôt que d'évaluer analytiquement chaque suggestion, ils dé-

veloppent une heuristique globale de confiance envers le système, et les explications de l'IA, censées favoriser l'esprit critique, sont interprétées comme un signal général de compétence qui augmente la confiance plutôt que la vigilance. C'est pourquoi les interventions cognitives doivent forcer structurellement le passage en Système 2, plutôt que de compter sur la volonté individuelle de vérifier.

Buçinca et al. (2021) testent cette hypothèse dans une tâche de décision nutritionnelle ($n = 199$), comparant une IA explicable classique (recommandation et explication présentées ensemble) à trois fonctions de forçage cognitif interrompant l'automatisme : l'accès à la demande (cliquer pour voir la suggestion), la mise à jour (décider avant de voir la suggestion, puis pouvoir la modifier) et le délai imposé (suggestion différée de 30 secondes pendant lesquelles le participant réfléchit).

Lorsque l'IA fournit une recommandation incorrecte, les participants en IA explicable classique ne détectent l'erreur que dans 8 % des cas, contre 27 % avec une fonction de forçage cognitif et 49 % sans IA. Le taux global de surconfiance passe de 64 % à 48 % (réduction modérée mais significative, $d = 0,36$, $p = 0,003$), les trois fonctions produisant des effets comparables. La simple présence d'explications n'aide donc pas à détecter les erreurs : il faut une rupture structurelle du flux cognitif.

Ghosh et al. (2026) étendent ces résultats au travail du savoir. Dans un essai contrôlé randomisé portant sur 214 participants réalisant des tâches de rédaction assistées par GPT-4o, ils comparent quatre conditions inspirées du cadre de pensée critique de Halpern (1998, 2013) : un contrôle sans intervention (None), une condition « Assumptions » (identifier les hypothèses implicites du plan rédigé par l'IA), une condition « WhatIf » (envisager des scénarios alternatifs) et une condition « Both » combinant les deux.

La condition Assumptions produit le taux de surconfiance le plus bas de l'étude (63 %), significativement inférieur à WhatIf (80,7 %, $p = 0,008$) ; le contrôle se situe à 70,6 %, cohérent avec les taux de copier-coller de Noy & Zhang (68 %) et la rétention textuelle de 0,87 de Dell'Acqua et al.

L'étude révèle aussi un découplage entre préférence et efficacité : WhatIf est perçue comme plus utile par les participants, mais c'est Assumptions qui réduit objectivement le plus la surconfiance, ce qui rejoint le compromis acceptabilité/performance identifié par Buçinca et al. (2021). La condition Both ne fait pas mieux que la meilleure intervention prise isolément : empiler les interventions diffuse l'attention plutôt que de l'approfondir, une parcimonie qui est une leçon directe pour la conception des dispositifs d'encadrement de l'IA.

Les explications et le coût cognitif de la vérification

Vasconcelos et al. (2023), à travers cinq études ($N = 731$), proposent un cadre qui réconcilie les résultats contradictoires sur les explications de l'IA explicable : la surconfiance n'est pas une fatalité cognitive mais un choix stratégique, les individus arbitrant entre le coût cognitif de la vérification et le bénéfice attendu de la précision. Elle est donc le « défaut rationnel » lorsque le coût de vérification est élevé et le bénéfice faible.

Les explications ne réduisent dès lors la surconfiance que lorsqu'elles abaissent ce coût : les explications visuelles (*highlight*) la réduisent sur les tâches difficiles (jusqu'à 0 % lorsqu'elles rendent l'erreur saillante) mais pas sur les tâches faciles, tandis que les explications textuelles, plus coûteuses, restent sans effet ; un bénéfice monétaire élevé la réduit également.

Ce cadre complète celui de Buçinca et al. (2021) : les fonctions de forçage cognitif augmentent le coût de la passivité, les explications bien conçues abaissent le coût de la vérification, deux leviers agissant sur le même arbitrage. Les mécanismes organisationnels d'encadrement de l'IA doivent donc non seulement

forcer la vérification mais aussi la faciliter, en rendant les productions de l'IA et leurs limites aussi transparentes que possible.

La complémentarité humain-machine comme propriété conditionnelle

Lu & Zhang (2024), dans *Information Systems Research*, démontrent que la complémentarité humain-machine n'est pas automatique mais conditionnelle à la réunion simultanée de deux facteurs. Leur expérience de terrain (entreprise de microcrédit asiatique, 23 602 demandes de prêt) manipule orthogonalement la complexité informationnelle (petit vs. grand volume de données) et la présence d'explications structurées de la machine (valeurs de Shapley issues d'une analyse SHAP).

La collaboration humain-machine ne surpasse la machine seule que lorsque les deux conditions sont réunies : avec un grand volume et des explications structurées, le taux de défaut des prêts passe de 5,15 % (décision de la machine seule) à 3,13 % (collaboration humain-machine), tandis que ni le grand volume de données seul ni les explications seules ne produisent d'amélioration significative.

Lu & Zhang interprètent ce résultat via la *dual-process theory* : le grand volume d'information capte l'attention et engage l'individu, tandis que les explications structurées fournissent les points de référence explicites qui déclenchent un *rethinking*, une reconsidération active où l'évaluateur revient sur sa décision initiale après avoir observé le raisonnement de la machine. L'humain, confronté au raisonnement de la machine, reconsidère sa décision et corrige l'algorithme sur les dossiers où des éléments qualitatifs lui échappent, tandis que la machine reste plus fiable sur les cas proches de ses seuils de décision ; cette division du travail complémentaire n'émerge qu'avec la bonne conception du système.

Le résultat de Lu & Zhang offre le modèle le plus précis de ce que la condition C3 cherche à reproduire : non pas une amélioration linéaire de la performance par ajout d'éléments, mais l'activation d'un mode cognitif différent, le *rethinking*, qui n'émerge que sous certaines conditions de conception. L'enjeu n'est pas d'ajouter des contraintes pour rendre l'usage de l'IA plus difficile, mais de réunir les conditions structurelles qui rendent possible le passage du Système 1 au Système 2.

Les garde-fous intégrés au prompt

Bastani et al. (2025), déjà présentés (section 2.2), fournissent le test le plus direct de l'efficacité des garde-fous intégrés au prompt. Le *system prompt* du GPT Tutor combine trois modifications par rapport au GPT Base : la solution correcte y est incluse pour éliminer les hallucinations, l'IA est instruite de guider étape par étape sans donner la réponse, et les erreurs courantes des élèves avec les indices correspondants sont intégrées. Le résultat décisif est qu'à l'examen non assisté, GPT Tutor ne se distingue pas du contrôle tandis que GPT Base dégrade la performance de 17 % ($p < 0,05$) : les garde-fous annulent entièrement l'effet béquille, et l'analyse des logs confirme le mécanisme (37 % de messages superficiels contre 67 % en condition non guidée). Contraints par la conception de l'outil, les élèves apprennent à interagir de manière substantive.

Les checklists organisationnelles

Les interventions documentées jusqu'ici opèrent au niveau cognitif (forcer le Système 2) ou au niveau de l'interface (modifier le prompt). La littérature sur les checklists organisationnelles offre un troisième levier : structurer le processus de travail lui-même.

Haynes, Gawande et al. (2009) rapportent les résultats du programme *Safe Surgery Saves Lives* de l'OMS (étude pré-/post-intervention, 7 688 patients, 8 hôpitaux dans 8 pays) : l'introduction d'une checklist

chirurgicale en 19 items, structurée en trois phases (avant l'anesthésie, avant l'incision, avant la sortie du bloc), réduit la mortalité de 47 % (1,5 % à 0,8 %, $p = 0,003$) et les complications de 36 % (11 % à 7 %, $p < 0,001$), dans les pays à hauts comme à faibles revenus, après ajustement pour le *case mix*.

Le mécanisme est « multifactoriel », combinant des changements systémiques (l'adhérence à l'anti-bioprophylaxie passe de 56 % à 83 %) et comportementaux (pause formelle obligatoire, présentation de l'équipe, briefing pré-opératoire). La checklist n'est pas un formulaire passif mais un outil de « conscience collective » (*collective awareness*, Haynes et al., 2009, p. 497), « orale, réalisée entre pairs, et intentionnellement conçue pour rendre visible la conformité ou non aux processus de sécurité » (Haynes et al., 2009, p. 497). Cette redevabilité par les pairs rejoint l'un des rares facteurs réducteurs d'erreurs identifiés par Parasuraman & Manzey (2010) : la *perceived accountability*, le sentiment d'être personnellement responsable du résultat.

Vers une mesure du recours approprié (*appropriate reliance*)

Schemmer et al. (2023) proposent un cadre pour évaluer la qualité de la collaboration humain-IA au-delà de la surconfiance : leur modèle distingue deux dimensions indépendantes, la *sensibilité aux bons conseils* (suivre une suggestion correcte lorsqu'on s'était trompé) et la *résistance aux mauvais conseils* (maintenir un jugement correct face à une suggestion erronée), le recours approprié supposant les deux simultanément élevés.

Dans leur étude ($n = 200$, détection de faux avis), les explications de type *feature importance* augmentent la sensibilité aux bons conseils (29,6 % à 38,9 %, $p = 0,05$) sans dégrader la résistance, mais la performance complémentaire n'est pas atteinte, ce qui confirme la difficulté à réaliser la complémentarité humain-IA documentée par Lu & Zhang (2024). Surtout, la confiance augmente simultanément l'adoption des bons conseils et la vulnérabilité aux mauvais ($\beta = 0,06$ et $\beta = -0,05$, $p < 0,01$) : elle est une arme à double tranchant.

Une mesure unidimensionnelle de la surconfiance, comme le taux de copier-coller (Noy & Zhang) ou le taux de rétention textuelle (Dell'Acqua et al.), est donc potentiellement trompeuse, car elle ne distingue pas la bonne adoption de la mauvaise. Les métriques comportementales du présent RCT seront interprétées à la lumière de cette distinction lors de la discussion des résultats.

Synthèse des interventions testées

Le tableau A.2, en annexe, récapitule les principales interventions testées dans la littérature et leur efficacité empirique pour réduire la surconfiance ou améliorer la complémentarité humain-IA.

Les interventions efficaces partagent une caractéristique commune, qui ressort de la synthèse ci-dessous.

Convergences

Malgré la diversité des domaines (nutrition, microcrédit, éducation, chirurgie, détection de faux avis, rédaction) et des interventions, un même principe traverse cette littérature : les interventions efficaces imposent structurellement un engagement cognitif délibéré, là où celles qui échouent présupposent que les utilisateurs traiteront l'information de manière analytique si on la leur fournit. Or les explications de l'IA sont traitées comme un signal heuristique (Bućinca et al., 2021), les instructions de vérifier sont ignorées et l'entraînement simple n'a aucun effet sur la complaisance (Parasuraman & Manzey, 2010), et la formation au prompt engineering augmente la confiance plutôt que l'esprit critique (Dell'Acqua et al., 2023). Le levier commun est donc de modifier l'arbitrage coût-bénéfice de l'engagement critique :

augmenter le coût de la passivité (fonctions de forçage cognitif), réduire le coût de la vérification (explications bien conçues ; Vasconcelos et al., 2023), ou structurer le processus pour rendre la vérification incontournable (checklists).

2.4 Cadre théorique des complémentarités et hypothèses

Les trois sections précédentes ont documenté un paradoxe apparent : l'IA générative améliore la productivité (section 2.1), mais produit simultanément des effets délétères (section 2.2) que les interventions structurelles parviennent à corriger plus efficacement que les interventions reposant sur la seule volonté individuelle de vérifier (section 2.3). La présente section propose un cadre théorique intégrateur qui résout ce paradoxe, en montrant que l'IA et les mécanismes organisationnels sont des compléments au sens économique du terme, et en dérivant les hypothèses testables du RCT.

La théorie des complémentarités

Milgrom & Roberts (1995) formalisent une intuition simple à l'aide d'un cadre mathématique précis. L'intuition : dans une organisation, la valeur d'une décision dépend des autres décisions prises en parallèle. Adopter une nouvelle technologie de production sans modifier le système de formation ne donne pas le tiers du résultat qu'on obtiendrait en modifiant les deux ensemble ; cela peut même donner un résultat nul ou négatif. Les éléments d'un système organisationnel ne s'additionnent pas, ils interagissent.

Formellement, deux activités sont dites complémentaires lorsque « faire davantage de l'une augmente les rendements de faire davantage des autres » (Milgrom & Roberts, 1995, p. 181). Les auteurs démontrent quatre implications de cette propriété, toutes directement pertinentes pour le présent mémoire.

Premièrement, le changement partiel peut avoir des rendements négatifs. L'illustration la plus frappante est celle de General Motors dans les années 1980. L'entreprise investit 80 milliards de dollars en robotique et en équipements automatisés, sans ajuster ses politiques de ressources humaines, ses processus de décision ni son développement produit. Le résultat, tel que les auteurs le décrivent : « des lignes d'assemblage qui auraient dû être les plus flexibles au monde mais qui ne produisaient qu'un seul modèle, tandis que la corporation, dans son ensemble, perdait de l'argent à des taux sans précédent » (Milgrom & Roberts, 1995, p. 194). La technologie seule ne suffit pas, et elle peut même aggraver la situation lorsqu'elle est introduite dans un système qui ne lui est pas adapté.

Deuxièmement, la coordination centrale est nécessaire : les décisions individuelles isolées convergent rarement vers l'optimum global, chaque agent optimisant pour son propre périmètre, de sorte que le système peut rester bloqué dans une configuration sous-optimale. Troisièmement, les erreurs coordonnées sont moins coûteuses que les erreurs indépendantes, ce qui justifie économiquement les processus standardisés et les garde-fous communs.

Quatrièmement, ce qui produit la valeur, c'est le système, pas l'élément. On ne peut pas extraire un élément (par exemple, une politique RH performante) d'une organisation qui réussit, le greffer sur une autre organisation, et s'attendre au même résultat. Les éléments tirent leur valeur des interactions entre eux. La technologie, les compétences, les processus et les incitations doivent former un ensemble cohérent.

De la théorie à l'empirie : technologie digitale et investissements complémentaires

Deux courants empiriques valident ce cadre théorique dans le contexte de la transformation digitale.

Bughin & van Zeebroeck (2021) estiment le rendement des investissements digitaux à partir de trois enquêtes annuelles consécutives (2017-2019) portant sur environ 450 grandes entreprises. Le rendement moyen est de 26 % ($\beta = 0,26$, $p < 0,01$), soit près du double du rendement des investissements traditionnels (14 %), mais cette moyenne masque une variance considérable : sans renouvellement stratégique, le rendement est statistiquement non significatif ; sous haute turbulence concurrentielle, le coefficient devient négatif (environ -3 %, marginalement significatif à $p < 0,10$). Ce n'est que couplé à un renouvellement stratégique audacieux que l'investissement digital produit des rendements substantiels et significatifs, l'éventail allant de -3 % à 49 % selon le mix stratégie/turbulence. Les auteurs identifient les capacités digitales relatives comme le facteur le plus puissant, expliquant 45 % de l'effet combiné sur les rendements.




FIGURE 2.5. Rendement des investissements digitaux selon le degré de renouvellement stratégique : le rendement moyen masque une forte variance, nul sans renouvellement et négatif sous forte turbulence. Figure recréée d'après les coefficients rapportés par Bughin & van Zeebroeck (2021).

Brynjolfsson, Rock & Syverson (2021) offrent une formalisation complémentaire avec la « courbe en J » de la productivité (section 2.1) : les gains d'une technologie à usage général ne se matérialisent qu'après l'accumulation d'investissements complémentaires intangibles (processus, formation, nouveaux actifs informationnels) qui dépriment d'abord la productivité mesurée. Les organisations déployant l'IA générative se trouvent probablement dans la phase descendante de cette courbe, à investir dans les compléments organisationnels nécessaires sans que les gains soient encore visibles dans les statistiques agrégées.

Application au contexte de l'IA générative : synthèse des mécanismes

Le parallèle entre ces cadres macro-organisationnels et les résultats des RCT au niveau micro-comportemental est frappant.

L'IA sans encadrement (condition C2 du RCT) correspond à un investissement digital sans renouvellement stratégique, ou à un déploiement technologique sans les investissements complémentaires de la courbe en J : des gains moyens apparents qui masquent une variance élevée, avec des rendements nuls ou négatifs dans certaines configurations (Dell'Acqua et al., 2023, pour les tâches hors frontière ; Bastani et al., 2025, pour l'apprentissage ; Becker et al., 2025, pour les experts). L'IA avec mécanismes organisationnels (condition C3) correspond à l'inverse à un investissement couplé au renouvellement stratégique : les garde-fous (Bastani et al., 2025), les fonctions de forçage cognitif (Bućinca et al., 2021 ; Ghosh et

al., 2026), les explications structurées (Lu & Zhang, 2024; Vasconcelos et al., 2023) et les checklists (Haynes et al., 2009) jouent le rôle de « compléments organisationnels » permettant de capturer la valeur de la technologie.

Lu & Zhang (2024) formalisent cette logique au niveau du mécanisme cognitif : la complémentarité humain-IA n'est réalisée que lorsque la complexité informationnelle et les explications structurées sont simultanément présentes, complémentarité au sens strict de Milgrom & Roberts où ni l'une ni l'autre seule ne suffit. Chen & Chan (2024) ajoutent que la modalité d'interaction (l'humain produit puis l'IA critique, plutôt que l'inverse) constitue un complément supplémentaire déterminant.

La théorie des processus duaux (Kahneman, 2011) fournit le mécanisme micro : l'IA non encadrée maintient les utilisateurs en Système 1 (heuristique, copier-coller, abdication du jugement), tandis que les mécanismes organisationnels (production initiale, prompts interdisant la réponse directe, révision après critique) forcent le passage en Système 2. Parasuraman & Manzey (2010) ancrent ce mécanisme dans une tradition antérieure à l'IA générative, montrant que la complaisance face à l'automatisation est un phénomène attentionnel non corrigible par la volonté individuelle mais réductible par des interventions structurelles, et Lee et al. (2025) le confirment pour l'IA générative (la confiance en l'IA est le prédicteur le plus puissant de la non-mise en œuvre de la pensée critique).

Articulation du niveau macro et du niveau micro

Le présent mémoire transpose au niveau micro-comportemental une hypothèse de complémentarité que Bughin & van Zeebroeck (2021) ont validée au niveau macro-organisationnel. Le schéma suivant rend explicite ce parallèle.




FIGURE 2.6. Transposition au niveau micro-comportemental de l'hypothèse de complémentarité validée au niveau macro-organisationnel. La condition C3 joue, à l'échelle individuelle, le rôle que joue le renouvellement stratégique à l'échelle de l'entreprise : c'est ce couplage qui permet à la technologie de produire ses gains.

Hypothèses

Sur la base de cette revue de littérature, les hypothèses suivantes sont formulées pour le RCT.

Les quatre hypothèses qui suivent forment un système cohérent plutôt qu'une simple liste. H1 teste la réplication du résultat le plus convergent de la littérature : l'IA libre accélère le travail. H2 et H3 testent l'hypothèse centrale du mémoire à deux niveaux distincts : le résultat (H2, qualité) et le processus (H3, mode d'interaction). H4, formulée à titre exploratoire, teste un mécanisme secondaire, la surconfiance, dont la réduction serait un marqueur indirect de l'engagement cognitif. L'interprétation des résultats devra tenir compte de la cohérence entre ces niveaux : un effet positif sur H2 sans effet sur H3 suggérerait que les gains de C3 proviennent d'autres mécanismes que le changement de mode d'interaction, et appellerait à reconsidérer le modèle théorique.

H1 : L'accès libre à l'IA (C2) réduit le temps de complétion par rapport au contrôle (C1). Noy & Zhang (2023) trouvent -37 % de temps, Brynjolfsson et al. (2023) +15 % de résolutions par heure, et Cui et al. (2025) +26 % de tâches complétées. L'effet sur la vitesse est le résultat le plus convergent de la littérature.

H2 : L'IA encadrée par des mécanismes organisationnels (C3) améliore la qualité et la fiabilité factuelle par rapport à l'IA libre (C2). Les garde-fous du GPT Tutor annulent le -17 % du GPT Base (Bastani et al., 2025), la collaboration humain-machine ne surpasse la machine seule qu'avec la bonne conception (Lu & Zhang, 2024, taux de défaut de 5,15 % à 3,13 %), et les fonctions de forçage cognitif (Bucinca et al., 2021 ; Ghosh et al., 2026) comme les explications bien conçues (Vasconcelos et al., 2023) réduisent la surconfiance. L'architecture de C3 combine ces mécanismes dans un système cohérent (production initiale obligatoire, critique en mode *sounding board*, identification des hypothèses implicites) ; la théorie des complémentarités prédit que c'est leur combinaison, et non chaque mécanisme pris isolément, qui doit produire l'effet.

H3 : L'IA libre (C2) est dominée par un mode substitutif (copier-coller), tandis que l'IA encadrée (C3) favorise un mode complémentaire (engagement cognitif actif). Noy & Zhang (2023) rapportent 68 % de copier-coller sans édition et Dell'Acqua et al. (2023) un taux de rétention textuelle modal de ~0,87 ; les garde-fous du GPT Tutor transforment le mode d'interaction (37 % de messages superficiels contre 67 % pour GPT Base ; Bastani et al., 2025), la fonction « Assumptions » produit le taux de surconfiance le plus bas (63,0 % contre 70,6 % et 80,7 % ; Ghosh et al., 2026), et la modalité *sounding board* (l'humain produit, l'IA critique) surpasse le *ghostwriter* (Chen & Chan, 2024). Cette hypothèse porte sur le processus, pas seulement sur le résultat.

H4 (exploratoire) : L'écart entre la performance perçue et la performance réelle est plus grand en C2 qu'en C3. Becker et al. (2025) documentent un écart de 39 points entre perception (+20 %) et réalité (-19 %), Bastani et al. (2025) des étudiants ne percevant pas la dégradation de leur apprentissage, Doshi & Hauser (2024) une auto-évaluation non significative malgré une amélioration objective, et Lee et al. (2025) 55 à 79 % de travailleurs rapportant une réduction de l'effort cognitif. À notre connaissance, peu de travaux ont mesuré si des mécanismes organisationnels réduisent cet écart ; l'hypothèse est donc formulée à titre exploratoire.

Ces hypothèses seront testées dans le cadre d'un RCT à trois conditions dont le plan expérimental est détaillé dans le chapitre suivant.

Chapitre 3

Méthodologie

Le cadre des complémentarités développé au chapitre 2 prédit que l'IA générative et les mécanismes organisationnels d'encadrement sont des compléments au sens de Milgrom & Roberts (1995), et qu'aucun ne suffit isolément. Le présent chapitre décrit le dispositif méthodologique conçu pour tester cette hypothèse à travers quatre hypothèses opérationnelles.

3.1 Plan expérimental

Justification du plan hybride

L'expérience adopte un plan hybride combinant une phase de référence (*baseline*) en mesures répétées intra-sujets (*within-subject*) et une phase expérimentale en inter-sujets (*between-subjects*) à trois conditions, avec une tâche par participant dans la phase expérimentale. Ce choix résulte de la mise en balance de deux considérations : la validité interne et la puissance statistique.

Le choix du plan inter-sujets pour la comparaison des trois conditions est justifié par trois arguments de Charness, Gneezy & Kuhn (2012). L'exposition successive à plusieurs conditions génère des effets de demande expérimentale (un participant comparerait l'IA libre et l'IA guidée et ajusterait son comportement, contaminant la mesure de la surconfiance) et des effets de report d'autant plus problématiques que l'exposition à une condition modifie durablement l'attitude envers l'IA (Parasuraman & Manzey, 2010) ; or ces deux biais sont précisément les plus sévères pour les tâches de jugement (*judgment-based*), ce qui correspond au cas présent où la variable d'intérêt est le comportement de confiance envers les productions de l'IA.

La phase de référence intra-sujets ne souffre pas de ces limitations puisqu'elle précède toute exposition aux conditions expérimentales. Chaque participant réalise une première tâche sans accès à l'IA, établissant une mesure individuelle de sa capacité de base. Cette mesure sert ensuite de covariable dans l'analyse de covariance (ANCOVA), une stratégie que Charness et al. (2012) recommandent explicitement dans leur conclusion comme le moyen d'« accéder aux avantages des deux méthodes », fournissant « le double de l'information pour une taille d'échantillon donnée ».

L'analyse principale utilise une analyse de covariance (ANCOVA) plutôt qu'une ANOVA simple, en introduisant la performance de référence (Phase 1) comme covariable : en contrôlant statistiquement les différences individuelles préexistantes, l'ANCOVA isole l'effet propre de la condition et réduit le bruit. Van Breukelen (2006) démontre que, dans un plan randomisé, l'ANCOVA avec la performance de référence comme covariable est strictement plus puissante que l'ANOVA simple ou l'analyse des scores de changement ; par rapport à cette dernière, pour une corrélation entre la référence et la tâche expérimentale de $r = 0,50$, elle atteint la même puissance avec environ 25 % de participants en moins.

Phases de l'expérience

L'expérience se déroule en quatre phases séquentielles au sein d'une même session en ligne.

Phase	Contenu	Plan
Phase 0 : Questionnaire pré-tâche	Consentement éclairé, données sociodémographiques, expérience préalable avec l'IA, ancienneté professionnelle, familiarité avec les types de tâches	Tous les participants
Phase 1 : Référence	Tâche rédactionnelle réalisée sans accès à l'IA ni à internet	Intra-sujets (tous les participants)
Phase 2 : Randomisation	Assignation aléatoire à C1 (contrôle), C2 (IA libre) ou C3 (IA guidée)	Minimisation marginale stratifiée par expérience IA et familiarité avec la tâche
Phase 3 : Tâche expérimentale	Une tâche de rédaction analytique réalisée dans la condition assignée	Inter-sujets
Phase 4 : Questionnaire post-tâche	Performance perçue, confiance envers l'IA, effort cognitif, sous-échelles de l'échelle de dépendance à l'IA générative (Hou et al., 2025)	Tous les participants

En condition C3, la tâche se répartit en deux étapes successives (voir section 3.4) : une étape A de production initiale sans IA (minimum imposé de 5 minutes et de 100 mots rédigés), puis une étape B de critique-révision en mode sounding board, qui occupe le temps restant jusqu'au budget indicatif de 20 minutes.

Calcul de puissance a priori

Le calcul de puissance repose sur les conventions de Cohen (1992) pour une ANOVA à trois groupes. Pour un effet moyen ($f = 0,25$, $\eta^2 \approx 0,06$), $\alpha = 0,05$ et une puissance de $1 - \beta = 0,80$, il faut 52 participants par groupe (156 au total ; Cohen, 1992, Table 2) ; pour un effet grand ($f = 0,40$), 21 par groupe (63 au total). Le seuil de 150 constitue donc l'idéal théorique pour les effets moyens, mais reste difficilement atteignable par échantillonnage de convenance sans compensation. L'objectif réaliste a donc été fixé à environ 90 sessions complètes (une trentaine par groupe), en assumant un plan avant tout puissant pour les effets grands ; la collecte a atteint 97 sessions complètes (85 analysables après exclusions), dépassant cet objectif.

Ce dimensionnement est cohérent avec les tailles d'effet de la littérature : $d = 0,45$ sur la qualité chez Noy & Zhang (2023), $d = 0,36$ pour la réduction de surconfiance chez Buçinca et al. (2021), V de Cramér de 0,19 chez Ghosh et al. (2026). Les effets attendus se situent donc dans la fourchette petite à moyenne ($d = 0,30$ à $0,50$), soit $f \approx 0,15$ à $0,25$ en ANOVA omnibus.

Deux facteurs atténuent la contrainte de puissance. Premièrement, l'utilisation de la performance de référence comme covariable dans l'ANCOVA réduit la variance résiduelle et augmente la puissance effective de l'ordre de 25 % par rapport à l'analyse des scores de changement (Van Breukelen, 2006). Deuxièmement, la stratification de la randomisation réduit la variance inter-groupes due aux caractéristiques individuelles.

Ces considérations impliquent que le dispositif est dimensionné pour détecter des effets moyens à grands avec une puissance adéquate, mais non les effets de petite taille ($f < 0,15$). Les comparaisons par paires (par exemple C2 vs. C3) requièrent 64 participants par groupe pour un $d = 0,50$ à 80 % de puissance (Cohen, 1992) : la puissance reste donc inférieure à 80 % à l'effectif atteint (une trentaine par groupe),

limitation traitée dans la section 3.10. Le rapport systématique des tailles d'effet (d de Cohen, η^2 partiel) et des intervalles de confiance à 95 % (Lakens, 2013) permettra d'interpréter les résultats indépendamment de la significativité statistique, une prudence d'autant plus nécessaire que la puissance est limitée (Button et al., 2013).

Procédure d'assignation : minimisation de Pocock-Simon (équilibre marginal)

La randomisation entre les trois conditions (C1, C2, C3) est gérée automatiquement par la plateforme expérimentale immédiatement après la soumission de la tâche de référence (voir section 3.8) et repose sur la méthode de minimisation marginale de Pocock & Simon (1975).

La stratification repose sur deux facteurs retenus pour leur pouvoir prédictif sur la qualité du texte. Le premier est la familiarité déclarée avec les tâches de rédaction analytique, meilleur indicateur disponible avant la randomisation du niveau rédactionnel du participant et plus fort prédicteur de la qualité finale selon la littérature (Noy & Zhang, 2023; Chen & Chan, 2024). Le second est l'expérience déclarée avec l'IA générative, qui conditionne la façon dont les participants interagissent avec l'outil en C2 et C3, et donc l'ampleur de l'effet du traitement (Dell'Acqua et al., 2023; Cui et al., 2025). Ces deux facteurs couvrent deux dimensions distinctes et respectent la recommandation de l'ICH E9 (§2.3.2), selon laquelle recourir à plus de deux ou trois facteurs de stratification est rarement nécessaire. Les autres variables mesurées (genre, niveau d'études, ancienneté professionnelle, âge) sont utilisées comme covariables ou dans des analyses de sensibilité (voir section 3.7), conformément à Kernan et al. (1999), qui recommandent de réserver la stratification aux facteurs à fort effet pronostique et de traiter les autres variables par ajustement analytique (alternative dont la perte de puissance est négligeable).

Le principe de la minimisation marginale, par opposition à l'équilibre cellule-par-cellule, est d'équilibrer les comptes par condition au sein de chaque niveau de chaque facteur pris séparément plutôt qu'au sein de chaque combinaison croisée. Avec deux facteurs binaires, l'équilibre croisé conduit à quatre cellules qui, pour un échantillon modeste ($N \approx 60-90$), restent peu remplies; l'équilibre marginal opère directement sur quatre marges, chacune contenant davantage d'observations et restant efficace tout au long de la collecte. C'est la méthode recommandée par Pocock & Simon (1975) et Kernan, Viscoli, Makuch, Brass & Horwitz (1999) pour les essais à taille modérée. Concrètement, à l'arrivée d'un participant, la plateforme calcule pour chaque condition candidate le déséquilibre hypothétique total (somme, sur les deux facteurs, de l'étendue des comptes par condition aux niveaux partagés par le participant), sélectionne la condition qui le minimise et tranche les égalités au hasard, ce qui préserve une composante de randomisation. La procédure est entièrement automatisée et reproductible à partir de l'historique des arrivées.

3.2 Participants

Profil et recrutement

Les participants sont recrutés par échantillonnage de convenance auprès de jeunes adultes francophones, étudiants ou en activité professionnelle, dans des domaines variés. Le recrutement cible explicitement une population diversifiée (domaine d'études ou d'activité, niveau d'expérience avec l'IA, parcours de formation) afin de maximiser la variance sur les variables de contrôle et d'éviter un échantillon monolithique.

L'ancienneté professionnelle (en mois) et le niveau d'études sont mesurés dans le questionnaire pré-tâche et utilisés comme variables de contrôle dans les analyses de sensibilité. Cette stratégie repose sur le

principe selon lequel, dans un plan inter-sujets randomisé, il est préférable de maximiser l'hétérogénéité de l'échantillon et de contrôler statistiquement les différences individuelles par covariables plutôt que de restreindre l'inclusion et de perdre en généralisabilité, principe que Cui et al. (2025) appliquent dans leur analyse d'hétérogénéité par ancienneté.

Aucune compensation monétaire n'est offerte ; les participants reçoivent un retour personnalisé sur leur performance relative (percentile au sein de leur condition) et un résumé des résultats de l'étude à l'issue de l'analyse. L'absence de compensation, qui peut induire un biais de sélection vers les individus intrinsèquement motivés, est reprise parmi les biais d'échantillon ci-dessous et discutée comme limite de validité externe (section 5.2.2).

L'expérience se déroule intégralement en ligne, un format cohérent avec les pratiques numériques de cette population et avec les protocoles de Noy & Zhang (2023) et de Ghosh et al. (2026), qui recrutent via Prolific et Amazon MTurk. Ce format implique des mesures de contrôle de la qualité : le temps de complétion en condition C1 est enregistré (un temps anormalement court pouvant signaler une ressource externe non autorisée), et la procédure surrecrute pour compenser l'attrition attendue.

Stratégie de recrutement

Le recrutement a reposé sur le réseau personnel de l'auteur, par échantillonnage de convenance, et a abouti à 97 sessions complètes.

Biais d'échantillon et généralisabilité

L'échantillon présente quatre biais de sélection qui limitent la généralisabilité : l'échantillonnage de convenance, non représentatif des travailleurs du savoir ; une population jeune (âge médian 24 ans), éduquée et familière des outils numériques, proche des premiers adoptants (*early adopters*) ; l'absence de compensation, qui favorise les individus intrinsèquement motivés ; et la restriction au français, qui limite la comparabilité avec les études anglophones. Ces biais sont partiellement communs à la littérature : Noy & Zhang (2023) recrutent des professionnels auto-sélectionnés via Prolific, Dell'Acqua et al. (2023) des consultants BCG atypiquement qualifiés, Bastani et al. (2025) des lycéens d'un établissement privé, sans qu'aucune ne revendique une représentativité populationnelle. La validité externe de la présente étude repose donc non sur la représentativité de l'échantillon mais sur la réplication conceptuelle des mécanismes documentés : retrouver les mêmes schémas de surconfiance et d'efficacité des garde-fous dans un échantillon francophone de jeunes adultes renforce la robustesse des mécanismes sous-jacents plutôt que la généralisabilité de la magnitude des effets. Ces limites sont discutées au chapitre 5 (section 5.2.2).

3.3 Tâches expérimentales

Le dispositif requiert deux tâches : une tâche de référence (Phase 1, sans IA, identique pour tous) et une tâche expérimentale (Phase 3, dans la condition assignée). Les tâches doivent satisfaire quatre critères simultanément : être réalisables en 15 à 20 minutes, être accessibles à de jeunes adultes de profils variés sans présupposer d'expertise sectorielle, contenir des éléments factuels vérifiables pour mesurer la fiabilité factuelle, et permettre une évaluation objective de la qualité via une grille standardisée. Les tâches proposées sont détaillées ci-dessous et reproduites intégralement en annexe B.

Tâche de référence : note de synthèse diagnostique

La tâche de référence demande de rédiger une note de synthèse de 250 à 400 mots à l'attention du directeur d'une médiathèque publique : à partir d'un dossier chiffré documentant le déclin de fréquentation, les participants identifient les deux à trois causes principales et formulent une recommandation argumentée. Le dossier comprend un paragraphe de contexte, trois séries de données longitudinales (usagers actifs, emprunts physiques et numériques entre 2022 et 2025) et six données complémentaires (âge des usagers, absence d'événements culturels, occupation des salles collaboratives, canaux de communication, horaires, enquête communale auprès des non-usagers 18-35 ans). Les participants ne disposent d'aucune ressource extérieure. La longueur indicative tient compte du temps imparti de 15 minutes, qui couvre la lecture, la réflexion analytique et la rédaction.

Cette tâche remplit deux fonctions : elle calibre la capacité rédactionnelle et analytique de chaque participant avant l'exposition à la condition, fournissant la covariable de l'ANCOVA, et familiarise les participants avec le format et l'interface. Le format « diagnostic à partir d'un dossier factuel » est délibérément parallèle à celui de la tâche expérimentale (auto-école Starter, voir ci-dessous), ce qui maximise la validité du covariat (Van Breukelen, 2006). Le contexte non commercial (service public culturel) évite le biais de report sectoriel et la charge idéologique qu'aurait un sujet polarisant comme un débat de société. Les données permettent de faire émerger plusieurs causes plausibles (décalage générationnel, absence d'événements, tournant numérique, horaires inadaptés, déficit de communication vers les jeunes publics), ce qui oblige à une hiérarchisation analytique plutôt qu'à la restitution d'un verbatim directif.

Tâche expérimentale : évaluation d'une stratégie de l'auto-école Starter

La tâche expérimentale demande aux participants d'évaluer une stratégie proposée par le gérant d'une auto-école indépendante (Starter) confrontée à une baisse de ses inscriptions. Le gérant envisage de baisser ses prix de 15 % pour s'aligner sur la concurrence, et les participants rédigent une note de 350 à 500 mots répondant à trois questions : (1) la baisse de prix est-elle la bonne réponse au problème, et pourquoi ; (2) quels risques comporte-t-elle ; (3) que recommanderaient-ils à la place ou en complément. Le dossier comprend un paragraphe de contexte, un encadré présentant la stratégie envisagée (forfait 20 heures abaissé de 960 à 815 euros, contre 890 euros en moyenne chez les concurrents), un tableau de trois indicateurs longitudinaux (inscriptions, taux de réussite au permis, note Google entre 2022 et 2025), un verbatim d'ancien élève issu d'une enquête interne et six données complémentaires (concurrence avec PermisRapide, tarifs et taux de réussite comparés, départ de moniteurs et délais d'attente, carnet de progression personnalisé, taux d'abandon, présence digitale). La longueur indicative tient compte de la densité du livrable et du budget de 20 minutes ; une boîte de dialogue avertit le participant en deçà de 250 mots, sans bloquer la soumission.

Le dossier est volontairement construit de sorte que plusieurs hypothèses causales soient plausibles simultanément, et la stratégie proposée par le gérant constitue elle-même un test de jugement critique : le participant doit déterminer si elle répond au bon problème ou traite un symptôme sans adresser les causes structurelles. Il comporte ainsi une fausse piste (le concurrent PermisRapide, dont l'arrivée est postérieure au début de la baisse), un dilemme prix/qualité (Starter plus cher mais au meilleur taux de réussite), une chaîne causale délais-abandon constituant le facteur structurel le mieux étayé (départ de moniteurs, allongement des délais, abandons précoces), une force cachée non exploitée par le brouillon type (le carnet de progression, fortement recommandé), et des données digitales ambivalentes (davantage d'avis Google mais une note en baisse et aucune présence sociale). Le verbatim d'ancien élève, volontairement non diagnostique, décrit un symptôme sans désigner de cause. Le format « évaluation d'une

stratégie proposée » plutôt que « diagnostic ouvert » présente trois avantages méthodologiques : il évite le transfert de stratégie depuis la tâche de référence, force le participant à prendre position et à justifier son jugement plutôt qu'à énumérer des causes, et différencie le livrable tout en conservant le même matériau analytique sous-jacent.

Cette tâche est de nature analytique et rédactionnelle : elle requiert simultanément la synthèse d'informations chiffrées, la structuration d'un argumentaire et l'exercice d'un jugement personnel sur les priorités stratégiques. L'IA est compétente en synthèse et en rédaction (Dell'Acqua et al., 2023 ; Noy & Zhang, 2023), mais la qualité dépend aussi de la profondeur analytique et de l'originalité du jugement, sur lesquelles le copier-coller d'une réponse générique devrait être détectable par les évaluateurs. C'est sur ces dimensions que la condition C3, en forçant l'engagement cognitif préalable et la révision critique, devrait produire des productions de qualité supérieure à celles de la condition C2.

Des éléments factuels vérifiables sont intégrés dans le dossier (nombre de moniteurs, délais d'attente, tarifs, taux de réussite, taux d'abandon) que les participants doivent mentionner avec exactitude. Ces éléments permettent de mesurer la fiabilité factuelle des productions (VD3) indépendamment de la qualité analytique globale.

3.4 Conditions expérimentales

Condition C1 : Contrôle (sans IA)

Les participants de la condition C1 réalisent la tâche expérimentale sans accès au chatbot d'IA. Ils disposent uniquement du dossier fourni (texte de contexte, tableau de données, retour client et données complémentaires, reproduits intégralement en annexe B) et d'un éditeur de texte intégré à la plateforme. L'accès à internet n'est pas techniquement bloqué (le format en ligne ne le permet pas de manière fiable), mais les instructions demandent explicitement de ne pas utiliser de ressources extérieures, IA générative comprise. La mesure de contrôle conservée est l'enregistrement du temps de complétion : un temps anormalement court peut signaler l'utilisation d'un outil externe et constitue un critère opérationnel d'exclusion (cf. section 3.7).

La condition C1 établit la performance de référence humaine sans assistance, permettant de tester H1 et de calibrer l'ampleur des gains de C2 et C3. Son maintien dans un plan à trois bras est délibéré : la comparaison centrale C2 vs. C3 pourrait être testée à deux bras, mais sans C1 il serait impossible de vérifier que C2 améliore la performance par rapport à l'absence d'IA, condition préalable pour interpréter cette comparaison.

Condition C2 : IA libre (sans encadrement)

Les participants de la condition C2 réalisent la tâche avec un accès libre au chatbot : interface minimaliste (champ de saisie, zone de réponses, bouton de soumission), sans aucune instruction, modèle de prompt ni *system prompt*, le modèle fonctionnant avec son comportement par défaut, ce qui reproduit l'expérience d'un utilisateur ouvrant ChatGPT pour la première fois. Cette condition correspond à celle de Noy & Zhang (2023), où les participants accèdent librement à ChatGPT sans encadrement, et à la condition « GPT Only » de Dell'Acqua et al. (2023), qui donne accès à GPT-4 avec les paramètres par défaut.

Condition C3 : IA guidée (architecture Production puis Critique-révision)

Les participants de la condition C3 réalisent la tâche expérimentale en deux étapes imposées, dont la durée totale (20 minutes) est identique à celle de C2 ; seule l'allocation interne diffère. Cette architecture séquentielle réplique fidèlement les interventions empiriquement validées, à des moments distincts du flux de travail. Elle s'inscrit dans la logique de Lu & Zhang (2024), pour qui la complémentarité humain-machine ne se réalise que sous plusieurs conditions simultanées, et de Milgrom & Roberts (1995), pour qui l'efficacité d'un système de complémentarités repose sur la cohérence des composantes plutôt que sur leur nombre. La figure 3.1 schématise cette architecture en deux étapes.




FIGURE 3.1. Architecture en deux étapes de la condition C3 (IA guidée) : une production initiale obligatoire sans IA, suivie d'une étape de critique-révision en mode sounding board.

Étape A : Production initiale (sans accès au chatbot). Le participant rédige une première version de sa réponse, l'éditeur ouvert mais le chatbot verrouillé. Une durée minimale de 5 minutes est imposée avant l'activation du bouton « Passer à l'étape B », afin de garantir un engagement cognitif réel et de laisser le temps de lire le dossier et de rédiger un premier jet substantiel ; au-delà, le participant choisit librement quand soumettre sa version à la critique de l'IA. La version de fin d'étape A est sauvegardée automatiquement et n'est plus modifiable telle quelle (les révisions se font en étape B).

Cette étape opérationnalise la fonction de forçage cognitif *Update* de Buçinca et al. (2021), qui impose une décision indépendante avant toute exposition à la suggestion de l'IA, et réplique la modalité *sounding board* de Chen & Chan (2024), où l'humain produit avant que l'IA n'intervienne. L'engagement préalable est, selon Lu & Zhang (2024), la condition nécessaire à l'activation du Système 2 et au processus de *rethinking*.

Étape B : Critique et révision en mode sounding board. Le chatbot se déverrouille et la version initiale est automatiquement transmise au système. Le system prompt force l'IA à agir comme un critique structuré et exigeant, non comme un rédacteur ; il inclut le dossier intégral de la tâche afin que les critiques soient pertinentes par rapport au matériau fourni, tout en maintenant l'interdiction de rédiger à la place du participant. L'IA produit une critique structurée en réponse à la version initiale, puis adopte un ton conversationnel et concis pour les échanges suivants. Le participant peut à tout moment dialoguer avec l'IA et modifier sa version, la tâche prenant fin lorsqu'il soumet sa version finale. Le budget indicatif de 20 minutes (étapes A et B confondues) est rappelé dans les consignes mais n'est pas imposé, afin

de ne pas tronquer les réponses en cours de rédaction et de préserver la vitesse (VD2) comme variable mesurée. Le system prompt déployé, reproduit intégralement en annexe B.3, inclut le dossier complet et instruit l'IA d'agir comme un critique structuré : une relecture initiale (hypothèses implicites, faiblesses argumentatives, éléments du dossier non exploités, affirmations à étayer suivies de questions), puis un refus de toute rédaction copiable, l'utilisateur étant renvoyé vers les données non exploitées.

L'inclusion du dossier dans le system prompt s'inspire de Bastani et al. (2025), qui intègrent la solution correcte dans le prompt du GPT Tutor : ici, l'IA ne reçoit pas la « bonne réponse » mais le matériau de la tâche, ce qui lui permet de vérifier la cohérence factuelle des affirmations du participant sans produire la réponse à sa place.

Ce prompt intègre plusieurs interventions empiriquement validées (cf. section 2.3) : l'interdiction de rédiger reproduit le principe du GPT Tutor de Bastani et al. (2025), qui annule l'effet béquille ; l'identification des hypothèses implicites correspond à la fonction de forçage cognitif *Assumptions* de Ghosh et al. (2026), la plus efficace de leur étude ; le signalement des affirmations à vérifier abaisse le coût cognitif de la vérification (Vasconcelos et al., 2023) ; et la posture de questionnement maintient la modalité *sounding board* de Chen & Chan (2024). La révision intervenant dans la même étape que la critique, le participant alterne librement entre dialogue et modification de son texte, reproduisant le *rethinking* que Lu & Zhang (2024) identifient comme le mécanisme central de la complémentarité humain-machine.

Le *system prompt* résulte d'un processus de calibration itératif : une première version, bien qu'interdisant à l'IA de rédiger à la place du participant, produisait des formulations assez élaborées pour être collées telles quelles, neutralisant le forçage cognitif visé ; quatre itérations ont été nécessaires. Chaque version a été éprouvée contre un protocole de 20 scénarios couvrant les questions de compréhension (auxquelles le chatbot répond par des explications), les demandes de délégation (qu'il refuse en renvoyant aux données non exploitées) et les tentatives de contournement (face auxquelles il maintient sa posture). La version finale a été retenue lorsque les 20 scénarios ont produit des réponses conformes ; ils sont reproduits, avec les réponses du modèle, en annexe C.

Avantage analytique unique de cette architecture. Le dispositif en deux étapes permet de mesurer une variable comportementale absente de C1 et de C2 : l'écart entre la version initiale (fin de l'étape A) et la version finale. Plutôt que de re-noter la qualité de versions intermédiaires, cet écart est opérationnalisé par la similarité textuelle (distance de Damerau-Levenshtein normalisée), ce qui distingue les participants ayant effectivement révisé leur texte après la critique de l'IA (similarité inférieure à 0,95) de ceux l'ayant soumis inchangé. Cette analyse de l'engagement intra-C3 est rapportée au chapitre 4 et mobilisée pour interpréter l'effet de C3 sur la qualité.

Choix du modèle d'IA

Le chatbot expérimental utilise GPT-4o d'OpenAI via l'API, avec des paramètres standardisés (température = 0,7, *top-p* = 1, longueur maximale = 4 096 tokens). Ce choix repose sur quatre considérations : GPT-4o est le modèle de Ghosh et al. (2026), l'étude la plus directement comparable ; la famille GPT est la plus familière au grand public (plus de 900 millions d'utilisateurs actifs hebdomadaires de ChatGPT en février 2026, OpenAI, 2026), ce qui réduit l'effet de nouveauté ; l'API permet le contrôle granulaire des paramètres (system prompt, température, logging) nécessaire au dispositif ; et les études fondatrices utilisent toutes des modèles GPT (GPT-3.5 chez Noy & Zhang, 2023 ; GPT-4 chez Dell'Acqua et al., 2023, et Bastani et al., 2025 ; GPT-4o chez Ghosh et al., 2026), ce qui facilite la comparabilité.

Le choix d'un modèle unique pour toutes les conditions (C2 et C3) garantit que les différences observées

entre conditions sont attribuables aux mécanismes organisationnels et non aux capacités intrinsèques du modèle. Les paramètres sont fixés et identiques entre C2 et C3 : seuls le system prompt et les éléments d'interface diffèrent.

3.5 Opérationnalisation des variables

Variables dépendantes

Quatre variables dépendantes sont mesurées, dont une primaire et trois secondaires. La VD primaire est définie avant le recueil des données.

VD1 : Qualité globale (primaire). Chaque production a été évaluée en aveugle de la condition expérimentale sur une échelle de 1 (insuffisant) à 4 (excellent), selon quatre dimensions, par deux évaluateurs (l'auteur du mémoire et un camarade) ayant noté l'intégralité des productions. La VD primaire est le score composite calculé en deux étapes : moyenne arithmétique des quatre dimensions pour chaque production, puis moyenne des deux notations.

Les ancrs comportementales utilisées pour chacune des quatre dimensions sont dérivées des Written Communication et Critical Thinking VALUE Rubrics de l'Association of American Colleges and Universities (AAC&U, 2009), un standard d'évaluation en enseignement supérieur développé par consensus d'experts universitaires représentant des centaines d'institutions américaines. Ces rubrics fournissent des descripteurs comportementaux explicites sur quatre niveaux de performance, mobilisés ici tels quels et adaptés en français aux deux tâches du mémoire (médiathèque pour la tâche de référence, auto-école Starter pour la tâche expérimentale). Le choix d'une échelle à quatre niveaux ancrés plutôt qu'une échelle à sept niveaux à ancrs extrêmes s'appuie sur Jonsson & Svingby (2007) qui, dans leur revue de soixante-quinze études sur les rubrics, établissent qu'à nombre de niveaux moindre correspond un meilleur accord inter-évaluateurs, et que les rubrics analytiques complétés par des ancrs descriptives concrètes et observables produisent une fiabilité supérieure à celle des rubrics holistiques, en concentrant l'attention de l'évaluateur sur des comportements précis plutôt que sur un jugement global. La grille complète des seize ancrs (quatre dimensions $\times$ quatre niveaux) est reproduite en annexe D.

L'évaluation repose sur deux évaluateurs humains, l'auteur du mémoire et un camarade, tous deux étudiants en deuxième année de Master à Solvay, notant en aveugle de la condition et selon la même grille ; ce sont leurs notations qui alimentent la VD primaire et le coefficient ICC (cf. « Modèle ICC » plus bas). Le choix de deux sources humaines, plutôt qu'une notation incluant GPT-4o, est délibéré : faire évaluer par GPT-4o des productions produites avec GPT-4o introduirait une circularité méthodologique difficilement défendable. Le choix de quatre dimensions analytiques s'inspire de Noy & Zhang (2023), qui en évaluent trois (qualité rédactionnelle, qualité du contenu, originalité) ; la quatrième (fiabilité factuelle) est ajoutée pour tester spécifiquement H2, qui prédit que C3 améliore la fiabilité factuelle par rapport à C2.

Justification de l'aveugle strict des évaluateurs. Le choix d'évaluer les productions en aveugle de la condition suit la recommandation de Schulz & Grimes (2002, p. 699) : « *blinding of outcome assessors is often possible and advisable, even in open trials. We recommend placing greater credence in results when someone unaware of treatment assignments judges outcome measures.* » Elle prend une importance particulière ici, où le critère de jugement (qualité globale) est mesuré sur échelle subjective : pour ce type de configuration, Hróbjartsson et al. (2013), dans une méta-analyse de seize essais randomisés, documentent un biais d'observateur moyen de 0,23 SD (exagération relative de 68 %) lorsque les évaluateurs ne sont pas en aveugle.

Calibration préalable. Avant l'évaluation du bloc principal, les deux évaluateurs ont mené une session de calibration sur quinze productions strictement identiques (huit tâches de référence, sept tâches expérimentales, sélectionnées de manière déterministe parmi les participants non signalés *excluded*, en aveugle de la condition), notés chacun dans un ordre randomisé propre puis confrontés dimension par dimension avec retour aux ancrs comportementales pour trancher les cas limites. L'objectif était un ICC d'au moins 0,60 (seuil « good » de Cicchetti, 1994) avant déblocage; l'ICC composite obtenu (0,85, « excellent ») a dépassé ce seuil dès la première itération, permettant le déblocage sans révision substantielle de la grille. Cette procédure suit la recommandation de Hallgren (2012, p. 25) sur le seuil de fiabilité fixé a priori (*training benchmark*). Les scores de calibration sont conservés dans l'analyse au même titre que les autres; les participants signalés *excluded* (cf. section 3.7) restent inclus dans le bloc principal et notés en aveugle au même titre que les autres.

Productions évaluées. Seules les productions des participants ayant complété l'entièreté de l'expérience (phase 5 atteinte : tâche de référence, tâche expérimentale et questionnaire post-tâche soumis) sont présentées à la notation. Les participants arrêtés en cours de route sont écartés : leur tâche de référence serait orpheline dans l'ANCOVA (covariable sans VD à laquelle être appariée) et leurs données ne contribuent à aucune des hypothèses testées. Parmi les participants ayant complété l'expérience, toutes les productions ont été évaluées par les deux évaluateurs, y compris celles des participants signalés *excluded* (cf. section 3.7). Cette inclusion est délibérée : elle permet l'analyse de sensibilité ITT (échantillon complet) versus PP (échantillon analysable) explicitement demandée par le promoteur (cf. chapitre 4), qui serait impossible sans la notation des productions *excluded*. Les productions de référence fournissent la covariable de l'ANCOVA, apport central du plan hybride, et celles de la tâche expérimentale servent aux comparaisons inter-conditions; la moyenne des deux notes constitue la valeur de la VD1 pour chaque production.

Indépendance des notations. Chaque évaluateur a réalisé l'intégralité de ses notations sans accéder à celles de l'autre, les notes n'étant consolidées qu'après clôture. L'ordre de présentation des productions a été randomisé séparément par évaluateur via un seed déterministe (hash de l'identifiant de l'évaluateur et de la production), ce qui garantit à la fois la stabilité de l'ordre en cas de reprise et l'absence de corrélation d'ordre entre les deux évaluateurs : une éventuelle dérive temporelle (fatigue, recalibration progressive) ne peut ainsi se transférer mécaniquement de l'un à l'autre. Les notations soumises sont verrouillées et ne peuvent plus être révisées, ce qui prévient toute dérive par re-visite.

Quantification des désaccords forts. À l'issue du bloc principal, un indicateur descriptif est rapporté au chapitre 4 : le nombre de productions pour lesquelles l'écart entre les deux évaluateurs atteint deux points (sur quatre) sur au moins une dimension. La VD primaire reste la moyenne des deux évaluateurs sans révision a posteriori, l'alignement étant assuré en amont par la phase de calibration (ICC d'au moins 0,60 avant le déblocage du bloc principal). La robustesse des conclusions aux désaccords résiduels est testée par une analyse de sensibilité écartant les productions signalées, conjointement avec la gestion des valeurs aberrantes de la section 3.7 (règle de Tukey $3 \times \text{IQR}$ sur la VD primaire). Ce principe de quantifier et de tester la robustesse plutôt que de réviser les notations a posteriori suit les recommandations sur le traitement des désaccords entre évaluateurs dans les rubrics analytiques (Jonsson & Svingby, 2007; Hallgren, 2012).

Modèle ICC. La fiabilité inter-évaluateurs est mesurée par un coefficient de corrélation intraclasse de type *two-way mixed, consistency, average-measures* (modèle mixte à deux facteurs, de cohérence, sur mesures moyennes) à $k = 2$ (Hallgren, 2012, Table 8), calculé sur les deux évaluateurs ayant noté l'intégralité des productions. Le choix des paramètres tient à ce que les deux mêmes juges fixés notent

l'ensemble des productions (*two-way mixed*), qu'un biais systématique entre eux est acceptable tant que leurs classements convergent, propriété pertinente pour l'ANCOVA (*consistency*), et que la VD est la moyenne des deux notes (*average-measures*). Les seuils de Cicchetti (1994, p. 286) sont appliqués (« poor » < 0,40; « fair » 0,40-0,59; « good » 0,60-0,74; « excellent » ≥ 0,75), un ICC inférieur à 0,40 imposant une révision du protocole. L'ICC composite obtenu (0,85, « excellent ») satisfait ce critère; le détail par dimension est rapporté au chapitre 4. Hallgren (2012, p. 26) souligne qu'une faible fiabilité réduit la puissance des analyses subséquentes; Hróbjartsson et al. (2013) rappellent toutefois qu'une bonne fiabilité ne garantit pas l'absence de biais d'observateur (leur exemple-type présente un ICC de 0,87 et le plus fort biais documenté), ce qui justifie le maintien d'un aveugle strict tout au long de la notation.

Consigne sur l'orthographe. Les fautes d'orthographe et de syntaxe ne doivent être pénalisées que lorsqu'elles affectent la compréhension; la dimension *Qualité rédactionnelle* cible la structure, la clarté et le registre, non la mécanique de surface. Cette instruction neutralise l'asymétrie de polissage entre les conditions, les productions de C2 produites avec GPT-4o pouvant bénéficier d'une qualité mécanique supérieure à celles de C1 et C3, rédigées par l'humain. Elle est conforme à la pratique de Noy & Zhang (2023) et de Dell'Acqua et al. (2023), qui font porter l'évaluation sur le contenu et la qualité argumentative plutôt que sur la correction grammaticale.

VD2 : Vitesse (secondaire). Le temps de complétion est mesuré selon deux opérationnalisations, toutes deux conservées en base. Le *temps horloge* (différence entre la soumission et le premier chargement de la page) est directement comparable à Noy & Zhang (2023), Dell'Acqua et al. (2023) et Cui et al. (2025). Le *temps actif* est l'agrégat des secondes pendant lesquelles l'onglet est visible (`document.visibilityState === "visible"`), excluant les périodes en arrière-plan, en veille ou écran verrouillé; il approche plus fidèlement le temps effectivement passé sur la tâche en contexte non supervisé, où le temps horloge peut être inflé par des interruptions sans contrepartie cognitive. Le temps d'interaction avec le chatbot est mesuré séparément (du premier au dernier message) pour distinguer réflexion autonome et interaction avec l'IA. Le temps actif a été retenu comme mesure principale (cf. chapitre 4 §4.2.1) et le temps horloge comme test de robustesse, sa variance très élevée en contexte non supervisé rendant l'inférence sensible aux valeurs extrêmes.

VD3 : Fiabilité factuelle (secondaire). La liste des éléments factuels vérifiables couvre l'intégralité du dossier fourni (douze éléments pour la tâche de référence, quatorze pour la tâche expérimentale; critère exhaustif documenté en annexe E). La pertinence analytique de ces éléments relève de la VD1 et n'intervient pas dans la VD3, qui mesure la seule fiabilité de la restitution factuelle. Pour chaque production, l'extraction manuelle en aveugle de la condition compte les vrais positifs (TP, éléments cités correctement), les faux positifs (FP, cités incorrectement ou inventés) et les faux négatifs (FN, non mentionnés), puis la fiabilité est opérationnalisée par le **F1-Score** (van Rijsbergen, 1979), moyenne harmonique de la précision et du rappel :

$$F1 = 2 \times \text{Précision} \times \text{Rappel} / (\text{Précision} + \text{Rappel}) = 2 \times TP / (2 \times TP + FP + FN)$$

où Précision = $TP / (TP + FP)$ mesure l'exactitude des mentions et Rappel = $TP / (TP + FN)$ leur couverture. Le F1-Score, borné dans [0, 1], est maximal lorsque tous les éléments sont mentionnés correctement. Son choix est justifié par son statut de standard en classification et en vérification des faits (Sokolova & Lapalme, 2009) et par la sensibilité de la moyenne harmonique aux faibles valeurs : un participant doit satisfaire simultanément les deux dimensions (citer beaucoup et citer correctement) pour obtenir un score élevé. Le détail de la grille et des conventions est reproduit en annexe E.

VD4 : Variance inter-participants (secondaire). L'écart-type des scores de qualité au sein de chaque

condition est la variable d'intérêt pour tester l'effet d'égalisation. L'hypothèse, dérivée de Noy & Zhang (2023) et de Brynjolfsson et al. (2023), est que l'IA comprime la distribution de performance. Cette variable n'est pas analysée au niveau individuel mais au niveau du groupe, via un test de Levene (ou son équivalent robuste, le test de Brown-Forsythe) comparant les variances des trois conditions.

Variables de contrôle

Les variables suivantes sont mesurées dans le questionnaire pré-tâche (Phase 0) et utilisées comme co-variables dans les analyses de robustesse.

Variable	Mesure	Justification
Performance de référence	Score de qualité à la tâche de référence (Phase 1)	Covariable ANCOVA primaire. Réduit la variance résiduelle (Van Breukelen, 2006).
Expérience avec l'IA générative	Échelle à 5 niveaux (de « jamais utilisé » à « utilisation quotidienne professionnelle ») + question ouverte sur les outils utilisés	Noy & Zhang (2023) contrôlent cette variable ; Cui et al. (2025) trouvent une hétérogénéité de l'effet selon l'ancienneté d'utilisation.
Ancienneté professionnelle	Nombre de mois d'expérience (stages inclus)	Brynjolfsson et al. (2023) trouvent que les gains sont plus élevés pour les agents récemment embauchés ; Cui et al. (2025) montrent une hétérogénéité par ancienneté.
Niveau d'études	Dernier diplôme obtenu (Bachelior, Master, autre) et domaine	Covariable dans l'analyse de sensibilité S2 (cf. section 3.7).
Familiarité avec l'écriture argumentative et synthétique	Auto-évaluation sur une échelle à 5 niveaux (de « jamais » à « quotidiennement ») mesurant la fréquence à laquelle le participant rédige des textes où il doit argumenter ou synthétiser des informations (rapports, notes, recommandations) dans son travail ou ses études.	Contrôle pour l'expertise spécifique au type d'écriture testé, distincte de l'expertise professionnelle générale. Le libellé de l'item volontairement générique évite de nommer les formats exacts des tâches expérimentales, qui reposent sur du vocabulaire de conseil (« notes de synthèse », « recommandations stratégiques ») peu familier aux participants de formations non managériales.

Variables du questionnaire post-tâche

Le questionnaire post-tâche (Phase 4) mesure trois construits pertinents pour les hypothèses H3 et H4.

Performance perçue. Le participant estime sur une échelle de 0 à 100 la qualité de chacune de ses productions. La surconfiance (H4) est opérationnalisée par les résidus d'une régression de la performance perçue sur la performance réelle (score des évaluateurs) : un résidu positif indique une perception supérieure à ce que la performance réelle prédit. Le recours aux résidus plutôt qu'à un écart brut est imposé par la non-commensurabilité des deux échelles (0-100 et 1-4) et isole la part de la perception indépendante de la performance. Cette logique rejoint celle d'Ehrlinger & Dunning (2003), dont les régressions multiples montrent que les estimations de performance sont en partie déterminées par des facteurs indépendants de la performance réelle. Les deux variables brutes sont aussi rapportées par condition, à fin de transparence. Fernandes et al. (2026), avec un instrument comparable, documentent une surestimation d'environ 20 % dans le groupe IA ($d = 0,93$), biais significativement plus marqué que dans les données sans IA de Jansen et al. (2021, $d = 0,29$).

Mode d’interaction avec l’IA. Quatre items de la sous-échelle d’usage irréfléchi (*Thoughtless Use*) de la GenAI Reliance Scale (Hou et al., 2025) sont administrés aux conditions C2 et C3, captant le mode substitutif (par exemple « J’ai copié l’énoncé directement dans le chatbot » ou « J’ai adopté les suggestions du chatbot sans les remettre en question »), et quatre items de la sous-échelle d’usage prudent (*Cautious Use*) captant le mode complémentaire (par exemple « J’ai repéré des erreurs dans les réponses du chatbot » ou « J’ai complété certaines parties sans recourir au chatbot »). Tous sont notés sur une échelle de Likert à 5 points (de « pas du tout d’accord » à « tout à fait d’accord »); l’adaptation de l’ancrage de fréquence original de Hou et al. (2025) à un ancrage d’accord est justifiée par le fait que les items portent ici sur une tâche unique plutôt que sur des comportements récurrents. Le contraste entre les deux sous-échelles opérationnalise l’hypothèse H3 sur le mode substitutif vs. complémentaire.

Effort cognitif perçu. Un item unique issu de la NASA Task Load Index (Hart & Staveland, 1988) mesure l’effort mental perçu (« Quel niveau d’effort mental cette tâche a-t-elle exigé ? ») sur une échelle de 1 à 7. Ghosh et al. (2026) montrent que les fonctions de forçage cognitif efficaces ne génèrent pas de surcharge cognitive significative ($H = 2,99$, $p = 0,39$ sur le NASA-TLX entre les quatre conditions), un résultat important pour la validité écologique de C3.

Données comportementales issues des logs

Les interactions avec le chatbot (conditions C2 et C3) sont automatiquement enregistrées avec horodatage (*timestamp*). Deux métriques comportementales objectives sont extraites des logs.

Métrique	Définition	Pertinence
Nombre de messages envoyés	Total des prompts envoyés au chatbot par tâche	Volume objectif d’interaction avec l’IA.
Taux de rétention textuelle	Proportion du texte de l’IA conservée telle quelle dans le texte final produit, mesurée par la distance de Damerau-Levenshtein normalisée entre le texte final soumis et la réponse de l’IA la plus similaire (sur l’ensemble des réponses produites au cours de la session), suivant la formulation exacte de Dell’Acqua et al. (2023).	Mesure objective utilisée par Dell’Acqua et al. (2023, mode $\approx 0,87$). Un taux de rétention plus élevé en C2 qu’en C3 (autrement dit, des participants C2 qui modifient moins le texte produit par l’IA) indiquerait un mode substitutif en C2 et un mode complémentaire en C3, opérationnalisant directement H3.

Métrique additionnelle pour C3 : révision entre version initiale et version finale. Comme introduit en section 3.4, l’architecture en deux étapes permet de mesurer l’écart entre la version de fin d’étape A et la version finale, opérationnalisé par la similarité textuelle (distance de Damerau-Levenshtein normalisée; une similarité inférieure à 0,95 signale une révision effective après la critique de l’IA). Cette mesure définit le sous-groupe des participants C3 ayant effectivement mobilisé l’IA, sur lequel une analyse stratifiée de la qualité est conduite au chapitre 4.

3.6 Hypothèses opérationnalisées

Les quatre hypothèses dérivées du cadre théorique (section 2.4) sont reformulées en termes de comparaisons statistiques testables.

Hypothèse	Comparaison statistique	VD	Test
H1 : L'accès libre à l'IA (C2) réduit le temps de complétion par rapport au contrôle (C1).	Temps C2 < Temps C1	VD2 (vitesse)	ANCOVA, contraste C2 vs. C1, covariable = performance de référence
H2 : L'IA encadrée par des mécanismes organisationnels (C3) améliore la qualité et la fiabilité factuelle par rapport à l'IA libre (C2).	Qualité C3 > Qualité C2 ET Fiabilité factuelle C3 > Fiabilité factuelle C2	VD1 (qualité), VD3 (fiabilité factuelle)	ANCOVA, contraste C3 vs. C2, covariable = performance de référence
H3 : L'IA libre (C2) est dominée par un mode substitutif (copier-coller), tandis que l'IA encadrée (C3) favorise un mode complémentaire (engagement cognitif actif).	usage irréfléchi C2 > usage irréfléchi C3 ET usage prudent C3 > usage prudent C2 ET Taux de rétention textuelle C2 > Taux de rétention textuelle C3	Sous-échelles de l'échelle de dépendance à l'IA générative (Hou et al., 2025), taux de rétention textuelle, nombre de messages	Tests t ou Mann-Whitney sur les métriques comportementales et auto-rapportées
H4 (exploratoire) : L'écart entre la performance perçue et la performance réelle est plus grand en C2 qu'en C3.	Résidus de la régression perçue ~ réelle plus élevés en C2 qu'en C3	Surconfiance (résidus de calibration)	Test t sur les résidus ; présentation parallèle des deux variables brutes ; analyse exploratoire (pas de correction pour comparaisons multiples)

3.7 Plan d'analyse statistique

Analyse principale

L'analyse principale utilise une ANCOVA à un facteur avec la qualité globale (VD1) comme variable dépendante, la condition (C1, C2, C3) comme facteur fixe, et trois covariables pré-spécifiées : la performance de référence, la familiarité avec les tâches de rédaction analytique et l'expérience avec l'IA générative. Le modèle s'écrit :

$$\text{Qualité}_i = \beta_0 + \beta_1(\text{Condition}_i) + \beta_2(\text{Baseline}_i) + \beta_3(\text{Familiarité}_i) + \beta_4(\text{ExpérienceIA}_i) + \varepsilon_i$$

Les deux dernières covariables correspondent aux facteurs de stratification et doivent être incluses dans le modèle d'analyse pour préserver la validité de l'inférence (Kahan & Morris, 2012). La performance de référence est la covariable principale ; les deux autres absorbent la variance résiduelle liée à la compétence rédactionnelle et à la familiarité avec l'outil. Les contrastes planifiés C2 vs. C1 et C3 vs. C2 testent respectivement H1 et H2.

Les hypothèses du modèle (normalité des résidus, homogénéité des variances, linéarité de la relation avec les covariables) sont vérifiées graphiquement et par les tests de Shapiro-Wilk et de Levene. En cas de violation, des alternatives non paramétriques (Kruskal-Wallis pour l'omnibus, Mann-Whitney avec correction de Bonferroni pour les paires) sont rapportées en parallèle.

Analyses de sensibilité

Quatre analyses de sensibilité testent la robustesse de l'estimation de l'effet de condition à l'ajustement pour des variables de contrôle supplémentaires, chacune reprenant le modèle principal :

- **S1** : ajout du *genre* comme covariable ;
- **S2** : ajout du *niveau d'études* (dichotomisé Master et plus vs. Bachelor ou moins) ;
- **S3** : ajout de l'*ancienneté professionnelle* (en mois), répliquant l'analyse d'hétérogénéité par ancienneté de Cui et al. (2025) ;
- **S4** : restriction aux participants de 35 ans ou moins, soit la population cible explicite de l'étude (« jeunes adultes francophones »).

La convergence des quatre analyses avec l'analyse principale est interprétée comme une preuve de robustesse ; une divergence entraîne une discussion spécifique au chapitre 5.

Engagements méthodologiques et critères d'exclusion

Cinq engagements méthodologiques structurent l'analyse afin d'en garantir la transparence et la défendabilité.

Premièrement, la VD primaire (qualité globale, score composite des quatre dimensions) est spécifiée avant le recueil des données. Les VD secondaires (vitesse, fiabilité factuelle, variance) sont clairement identifiées comme secondaires.

Deuxièmement, les trois comparaisons par paires (C1 vs. C2, C2 vs. C3, C1 vs. C3) sont toutes rapportées, y compris les résultats non significatifs.

Troisièmement, les résultats sont rapportés avec et sans la covariable de référence, afin que le lecteur puisse apprécier l'apport de l'ajustement.

Quatrièmement, la règle d'arrêt a été fixée avant le recueil : les données devaient être collectées jusqu'à atteindre la cible de complétions valides ou l'épuisement du bassin de recrutement, sans inspection intérimaire des résultats. La collecte a été close après épuisement du réseau personnel, à 97 sessions complètes (échantillon analysable principal de 85 participants après application des critères d'exclusion).

Cinquièmement, deux critères opérationnels d'exclusion sont appliqués automatiquement à la tâche de référence : un seuil d'engagement minimal (temps actif inférieur à 3 minutes, mesuré sur le temps actif plutôt que sur le temps horloge conformément à la section 3.5, ce dernier pouvant être inflé par des pauses sans contrepartie cognitive) et un seuil de débit de frappe (au-delà de 78 mots par minute, soit le 90e percentile de la distribution mesurée par Dhakal, Feit, Kristensson & Oulasvirta, 2018, sur 168 000 participants, vitesse physiologiquement incompatible avec la composition d'un texte analytique). Leur finalité est opérationnelle et non analytique : empêcher les cas flagrants de non-engagement de polluer les marges de randomisation des participants suivants. Sur la tâche expérimentale, ils ne sont pas appliqués aux conditions C2 et C3, où le mode substitutif (copier-coller depuis l'IA) est un comportement modal hypothétisé par H3 et non une violation. Ils sont en revanche étendus à la seule condition contrôle C1, dépourvue d'IA : une production expérimentale anormalement rapide y signale non un usage de l'IA, mais un désengagement ou le recours à une IA externe non autorisée. Les résultats sont rapportés avec et sans application de ces critères.

Sixièmement, une troisième couche d'exclusion statistique post-notation cible les valeurs véritablement aberrantes sur la VD primaire, selon la règle de l'écart interquartile de Tukey (1977) au seuil de la

barrière externe (*outer fence*) à $3 \times \text{IQR}$ (et non la barrière interne, *inner fence*, à $1,5 \times \text{IQR}$ des valeurs aberrantes modérées) : une valeur est extrême si elle se situe en deçà de $Q1 - 3 \times \text{IQR}$ ou au-delà de $Q3 + 3 \times \text{IQR}$. Ce seuil conservateur, formellement analysé par Hoaglin, Iglewicz & Tukey (1986), isole les valeurs aberrantes « far out » tout en préservant la variabilité naturelle de l'échantillon. Les conclusions sont rapportées avec et sans application de cette exclusion.

Analyses secondaires et exploratoires

Les analyses secondaires portent sur les VD secondaires (vitesse, fiabilité factuelle, variance) avec les mêmes modèles. L'analyse principale (VD1, qualité globale) est testée au seuil $\alpha = 0,05$ sans correction, puisqu'il s'agit de la VD primaire ; les VD secondaires sont rapportées à titre informatif, avec une correction de Holm-Bonferroni sur les trois comparaisons par paires au sein de chaque VD, moins conservatrice qu'une correction globale tout en contrôlant le taux d'erreur familywise par famille. Les comparaisons de variances entre conditions (effet d'égalisation) utilisent le test de Brown-Forsythe, plus robuste que le test de Levene lorsque les distributions ne sont pas parfaitement normales.

Les analyses exploratoires comprennent l'hétérogénéité de l'effet de traitement selon l'expérience IA (interaction Condition $\times$ Expérience IA), les métriques comportementales issues des logs (comparaison C2 vs. C3 sur les deux métriques définies en section 3.5), l'engagement intra-C3 (révision entre version initiale et version finale) et le test de H4 sur la surconfiance. Ces analyses sont étiquetées comme exploratoires et ne font pas l'objet de corrections pour comparaisons multiples.

3.8 Plateforme expérimentale

La plateforme expérimentale est une application web dédiée, conçue pour gérer l'ensemble du protocole (consentement, questionnaires, randomisation, tâches, chatbot, logging) dans une interface unifiée.

La plateforme est une application web développée avec Next.js (TypeScript), hébergée sur Vercel, utilisant Supabase (Postgres) pour le stockage des données et l'API OpenAI pour le chatbot. Les dossiers des tâches et le system prompt de la condition C3 sont reproduits intégralement en annexe B.

La plateforme satisfait plusieurs spécifications fonctionnelles essentielles à la validité du protocole (les détails techniques d'implémentation sont documentés séparément). La randomisation par minimisation marginale (cf. section 3.1) est déclenchée automatiquement après la soumission de la tâche de référence, avant l'accès à la tâche expérimentale : ce moment garantit que la tâche de référence est rédigée sans que le participant connaisse sa condition, écartant tout ajustement d'effort en anticipation du bras assigné. Le chatbot fonctionne sans system prompt en C2, avec le system prompt de réviseur critique en C3, et reste inaccessible en C1. Les éléments d'interface propres à C3 (verrouillage du chatbot pendant l'étape A, déverrouillage conditionné à 5 minutes et 100 mots rédigés, transmission automatique de la version initiale au chatbot en étape B) ne sont activés que pour cette condition, et l'état de progression est persisté pour survivre à un rafraîchissement accidentel. Toutes les interactions avec le chatbot sont enregistrées côté serveur (message, horodatage, rôle), ce qui permet d'extraire les métriques comportementales de la section 3.5. Le temps de complétion est mesuré selon les deux opérationnalisations de la section 3.5 (temps horloge et temps actif via la condition `document.visibilityState === "visible"`), un chronomètre ascendant du temps actif étant affiché sans limite imposée afin de ne pas tronquer les réponses. Le contenu en cours est sauvegardé automatiquement, en local et côté serveur, pour prévenir toute perte y compris en cas de changement d'appareil. Les productions et interactions sont stockées sous un identifiant pseudonyme (UUID), l'adresse email n'étant conservée que dans la table des par-

participants. Enfin, le flux est strictement séquentiel : les participants ne peuvent pas revenir à une phase antérieure, ce qui garantit que la covariable de référence n'est pas contaminée par une exposition aux conditions expérimentales.

3.9 Protocole éthique

L'étude respecte les principes éthiques de la recherche impliquant des sujets humains : consentement éclairé recueilli en début de session, caractère volontaire de la participation et droit de retrait mentionnés explicitement, données pseudonymisées dès la collecte par un identifiant alphanumérique (aucune donnée nominative n'est conservée dans la base de recherche). Un compte rendu complet, expliquant le dispositif expérimental et les conditions distinctes, est envoyé par email à l'issue de l'étude.

3.10 Limites méthodologiques

Le dispositif présente plusieurs limites, énumérées ici et discutées en détail au chapitre 5 (section 5.2), où elles sont mises en regard des résultats. La plus déterminante tient à la tâche unique retenue, située à l'intérieur de la frontière technologique de l'IA : le dispositif ne teste pas l'interaction entre les mécanismes d'encadrement et le type de tâche, ce qui conditionne l'interprétation du résultat central (section 5.2.4). Une tâche *outside frontier* fiable au sens de Dell'Acqua et al. (2023) n'a pu être construite de manière satisfaisante avec les modèles actuels, dont la capacité à intégrer des informations contradictoires a nettement progressé depuis 2023, et avec une population non experte.

Les autres limites relèvent de quatre registres. Sur le plan de la validité interne, l'impossibilité de bloquer techniquement l'accès à une IA externe en condition C1 expose à une contamination du contrôle (commune aux essais en ligne ; Noy & Zhang, 2023, 10 à 20 % du groupe contrôle), le dispositif séquentiel tâche de référence puis tâche expérimentale introduit un risque d'effet d'ordre et de fatigue différentielle inhérent à la covariable ANCOVA, et la mono-opérationnalisation des mécanismes de C3, dont l'architecture combine production initiale, critique en mode *sounding board* et révision, ne permet d'isoler ni la contribution de chaque composante ni celle de la structuration temporelle elle-même (choix délibéré au regard de la théorie des complémentarités, qui porte sur l'effet du système et non de chaque mécanisme isolé ; Milgrom & Roberts, 1995). Sur le plan de la puissance, le dimensionnement pour les effets grands mais non pour les effets moyens (cf. §3.1) implique qu'un résultat non significatif ne vaut pas preuve d'absence d'effet et que la magnitude des effets significatifs est probablement surestimée (malédiction du vainqueur, *winner's curse* ; Button et al., 2013). La validité externe est restreinte par l'échantillon de convenance (jeunes adultes francophones non rémunérés) et par la conditionnalité au modèle GPT-4o, dont le profil d'erreurs spécifique pourrait interagir différemment avec les mécanismes de C3 ; la validité écologique l'est par le caractère artificiel et la brièveté des tâches (effet Hawthorne commun aux conditions, absence de suivi longitudinal des effets d'apprentissage, écart laboratoire-terrain documenté par Cui et al., 2025). Enfin, l'évaluation repose sur deux juges non experts (le niveau 4 de la grille reflète la meilleure qualité observée dans l'échantillon, non la meilleure qualité professionnelle possible) et la mesure du temps de travail par le temps actif reste une approximation en contexte non supervisé ; la portée de ces deux limites de mesure est atténuée par la triangulation des conclusions au moyen d'indicateurs objectifs indépendants du jugement des évaluateurs (F1-Score de fiabilité factuelle, traces d'usage de l'IA, similarité inter-productions, calibration confiance-performance).

Chapitre 4

Résultats

Ce chapitre rapporte les résultats du protocole expérimental décrit au chapitre 3. La présentation suit l'ordre des quatre hypothèses (H1 à H4) et adopte la convention du rapport systématique des tailles d'effet et de leurs intervalles de confiance (Lakens, 2013), indépendamment des seuils de significativité.

Conventions d'échantillonnage. L'analyse principale suit le principe en intention de traiter (*intent-to-treat*, ITT) : sont inclus tous les participants ayant complété l'intégralité du protocole (phase 5 atteinte, c'est-à-dire tâche de référence (*baseline*) soumise, tâche expérimentale soumise et questionnaire post-tâche soumis), indépendamment du respect strict des consignes. Une analyse de sensibilité per-protocole (*per-protocol*, PP) restreint l'échantillon aux participants n'ayant pas été signalés *excluded* selon les critères opérationnels d'engagement minimal définis au chapitre 3 §3.7 (cf. tableau 4.2 et §4.1.3 ci-dessous pour le détail des exclusions). Cette double analyse, recommandée par le promoteur dans son retour du 24/04/2026, permet de vérifier que les conclusions sont robustes à la stratégie de gestion des cas de non-engagement.

4.1 Description de l'échantillon

4.1.1 Recrutement et attrition

Le recrutement s'est déroulé du 17 avril au 10 mai 2026 via le réseau personnel de l'auteur, sans rémunération. L'objectif réaliste d'environ 90 sessions complètes (cf. chapitre 3 §3.1) a été atteint et dépassé. Au total, 254 personnes ont saisi leur adresse électronique, 215 ont rempli le questionnaire pré-tâche, 115 ont soumis la tâche de référence et 97 ont complété l'intégralité du protocole (taux conditionnels : 45 % depuis la saisie d'email, 84 % depuis la tâche de référence). La figure 4.1 illustre la cascade d'attrition.




FIGURE 4.1. Attrition par phase du protocole.

La principale source d'attrition se situe entre le questionnaire pré-tâche et la tâche de référence (perte de 100 participants, 46,5 %), un filtrage typique des protocoles en ligne sans rémunération, où l'effort de la première rédaction sépare les participants motivés des curieux. Au-delà de la tâche de référence, le taux de complétion atteint 84 %, signe que les participants engagés conduisent le protocole jusqu'à son terme.

4.1.2 Caractéristiques de l'échantillon analysable

Sur les 97 participants ayant complété la session, 12 sont signalés *excluded* selon les critères opérationnels d'engagement minimal du chapitre 3 §3.7. L'échantillon analysable principal (PP) comprend donc 85 participants, répartis comme indiqué au tableau 4.1.

TABLE 4.1. Répartition des participants par condition (échantillon phase 5, n = 97).

Condition	Analysables (PP)	Signalés <i>excluded</i>	Total (ITT)
C1, contrôle (sans IA)	25	5	30
C2, IA libre	31	3	34
C3, IA encadrée	29	4	33
Total	85	12	97

Sur le plan sociodémographique, l'échantillon est composé majoritairement de jeunes adultes francophones résidant en Belgique (75 sur 85 ; 88,2 %), avec une représentation marginale de la France (5 ; 5,9 %) et du Maroc (5 ; 5,9 %). L'âge médian est de 24 ans (IQR 22 à 28), la répartition par genre de 53 % de femmes et 47 % d'hommes. Le niveau d'études est concentré sur les diplômes universitaires (45 % en Master en cours ou obtenu, 45 % en Bachelier, 10 % autres), et l'ancienneté professionnelle médiane de 12 mois (IQR 0 à 48), reflétant la prépondérance des étudiants et jeunes professionnels dans le réseau de recrutement.

L'exposition à l'IA générative est particulièrement élevée : 60 % des participants déclarent une utilisation quotidienne et 24 % une utilisation hebdomadaire d'outils d'IA générative (ChatGPT, Copilot, Claude, etc.), soit 84 % à un usage régulier, contre 16 % d'occasionnels ou novices. Cette caractéristique, à mettre en regard de l'estimation d'Eloundou et al. (2024, mesure β) selon laquelle 80 % de la main-d'œuvre américaine pourrait voir au moins 10 % de ses tâches affectées par les grands modèles de langage, fait de l'échantillon un panel d'utilisateurs actuels plutôt qu'une population générale, ce qui renforce la pertinence de tester des mécanismes d'encadrement sur une population déjà familière de l'outil. La familiarité avec la rédaction argumentative et synthétique est plus hétérogène (30 % quotidiennement, 33 % chaque semaine, 26 % occasionnellement, 11 % rarement ou jamais).

4.1.3 Détail des participants signalés *excluded*

Les 12 participants signalés *excluded* relèvent des critères opérationnels documentés au chapitre 3 §3.7.

(a) Temps actif inférieur à 180 secondes sur la tâche de référence (n = 9 : 2 en C1, 3 en C2, 4 en C3). Ces participants ont soumis leur tâche de référence en moins de trois minutes de temps effectif d'engagement, incompatible avec la lecture d'un dossier et la rédaction de 250 à 400 mots ; les valeurs s'échelonnent de 36 à 177 secondes (un cas à 3 mots produits).

(b) Débit de frappe supérieur à 78 mots par minute sur la tâche de référence ($n = 1$) : une participante en C1 atteint 226,7 mots/min, seuil correspondant au 90e percentile de la distribution de Dhakal, Feit, Kristensson & Oulasvirta (2018) au-delà duquel la composition d'un texte original est physiologiquement improbable (profil compatible avec un collage de texte préparé ailleurs).

(c) Critères étendus à la tâche expérimentale pour la seule condition contrôle C1 ($n = 2$; cf. chapitre 3 §3.7) : un participant dépasse 78 mots par minute (112 mots/min) et une participante reste sous 180 secondes de temps actif (105 secondes). En l'absence d'IA en C1, ces profils signalent un recours à une IA externe ou un désengagement, et non le mode substitutif attendu en C2 et C3.

À ce stade, aucun autre participant n'apparaît comme candidat manifeste à l'exclusion opérationnelle. Quelques cas marginaux (deux participants C2 ou C3 ayant soumis la production expérimentale en moins de 180 secondes mais avec un usage du chatbot conforme au protocole, le mode substitutif étant explicitement prévu par H3 en C2) sont conservés dans l'analyse principale.

4.1.4 Vérification de l'équilibre de la randomisation

La randomisation par minimisation marginale de Pocock-Simon (cf. chapitre 3 §3.1) vise à équilibrer les trois conditions sur les deux facteurs pronostiques retenus : l'expérience IA et la familiarité avec la tâche de rédaction analytique. Le tableau 4.2 rapporte les comptes par condition sur chaque marge, ainsi que les tests du χ^2 d'indépendance correspondants.

TABLE 4.2. Équilibre de la randomisation sur les facteurs stratifiés (échantillon PP, $n = 85$).

Facteur	C1	C2	C3	$\chi^2(2)$	p
Expérience IA, élevée (hebdomadaire ou plus)	21 / 25 (84 %)	26 / 31 (84 %)	25 / 29 (86 %)	0,08	0,962
Familiarité tâche, élevée (hebdomadaire ou plus)	14 / 25 (56 %)	19 / 31 (61 %)	17 / 29 (59 %)	0,16	0,923

L'équilibre est excellent sur les deux marges ($p > 0,92$), confirmant que la minimisation a opéré comme attendu. Les covariables non stratifiées, utilisées dans les analyses de sensibilité S1 à S4 (chapitre 3 §3.7), ne diffèrent pas non plus significativement entre conditions : genre ($\chi^2(4) = 2,89$; $p = 0,577$), niveau d'études dichotomisé Master+ vs. inférieur ($\chi^2(2) = 1,08$; $p = 0,583$), âge (Kruskal-Wallis $H(2) = 1,78$; $p = 0,411$) et ancienneté professionnelle ($H(2) = 3,95$; $p = 0,139$). La covariable centrale de l'ANCOVA, la qualité de la production de référence, est elle aussi parfaitement équilibrée (moyennes de 2,53 en C1, 2,54 en C2 et 2,45 en C3; ANOVA $p = 0,84$), ce qui confirme l'absence de différence de compétence préexistante et valide l'usage de cette covariable. Aucun déséquilibre systématique n'est à signaler : les analyses inférentielles peuvent procéder sans risque de confusion démographique.

4.2 Vitesse de complétion (H1)

L'hypothèse H1 prédit que l'accès libre à l'IA (C2) réduit le temps de complétion de la tâche expérimentale par rapport au contrôle sans IA (C1).

4.2.1 Choix de la mesure : temps actif et non temps horloge

Le chapitre 3 §3.5 conserve deux opérationnalisations de la vitesse, l'une principale (temps actif) et l'autre de robustesse (temps horloge). À l'issue de la collecte, la mesure principale retenue est exclusivement le temps actif : cumul des secondes pendant lesquelles l'onglet de la plateforme était visible à l'écran (condition `document.visibilityState === "visible"`). Trois constats imposent cette décision.

D'abord, le temps horloge intègre toutes les périodes hors-tâche (onglet en arrière-plan, machine en veille, absence momentanée du participant), d'une amplitude considérable en contexte non supervisé : le tableau 4.3 montre un temps horloge expérimental maximal de 121 heures en C1, et l'écart-type y dépasse 25 heures, ce qui rendrait l'inférence extrêmement sensible aux valeurs extrêmes et imposerait une transformation logarithmique ou une troncature ad hoc. Ensuite, les deux mesures convergent fortement sur la direction de l'effet (Spearman $\rho = 0,84$; $p < 0,001$), mais le temps actif circonscrit la mesure à la fenêtre d'engagement effectif et constitue une opérationnalisation plus défendable de la VD vitesse.

TABLE 4.3. Comparaison des deux opérationnalisations du temps de complétion expérimental (ITT, $n = 97$).

Condition	Temps actif médian (min)	Temps horloge médian (min)	Maximum temps horloge (heures)
C1	18,8	26,6	121,2
C2	5,3	6,6	20,4
C3	17,4	22,4	77,2

4.2.2 Statistiques descriptives

La figure 4.2 illustre la distribution du temps actif expérimental par condition. Le tableau 4.4 rapporte les statistiques descriptives associées.




FIGURE 4.2. Temps actif de complétion de la tâche expérimentale par condition.

TABLE 4.4. Temps actif de complétion de la tâche expérimentale par condition (ITT, n = 97).

Condition	n	Médiane (min)	IQR (min)	Moyenne (min)	SD (min)
C1, contrôle	30	18,8	10,0 à 32,4	23,9	20,4
C2, IA libre	34	5,3	2,5 à 11,2	9,7	14,9
C3, IA encadrée	33	17,4	9,3 à 26,7	19,7	11,4

Le schéma descriptif est sans ambiguïté : les participants de C2 complètent la tâche en environ un quart du temps actif de ceux de C1 ou C3, dont les distributions sont très proches entre elles. Cette compression du temps en C2 est cohérente avec l’hypothèse H3 d’un mode d’interaction substitutif (examiné plus loin) : un participant qui copie l’énoncé dans le chatbot et soumet la réponse renvoyée par l’IA achève la tâche en quelques minutes, indépendamment de la durée indicative de 20 minutes.

4.2.3 Analyse de covariance

L’analyse principale est une ANCOVA à un facteur (condition à trois niveaux) avec le temps actif sur la tâche de référence comme covariable principale, et la familiarité avec la tâche et l’expérience IA comme covariables additionnelles (cf. chapitre 3 §3.7). Les facteurs de stratification sont inclus dans le modèle conformément à Kahan & Morris (2012). Le tableau 4.5 rapporte les résultats sur l’échantillon ITT (n = 97).

La figure 4.3 visualise la relation entre temps actif sur la tâche de référence et temps actif expérimental, séparément par condition.




FIGURE 4.3. Temps actif expérimental vs. tâche de référence, par condition.

TABLE 4.5. ANCOVA sur le temps actif de la tâche expérimentale (ITT, $n = 97$). Sommes des carrés de type III. Les valeurs ajustées (*estimated marginal means*) tiennent compte des covariables.

Effet	F	df	p	η^2 partiel
Condition	11,3	2, 91	< 0,001	0,17
Temps actif sur la tâche de référence	32,7	1, 91	< 0,001	0,29
Familiarité tâche	0,00	1, 91	0,989	< 0,001
Expérience IA	0,02	1, 91	0,880	< 0,001

L'effet de la condition est statistiquement significatif et de magnitude grande (η^2 partiel = 0,17, soit $f \approx 0,45$ dans la métrique de Cohen, 1992, au-delà du seuil conventionnel d'effet large fixé à $f = 0,40$). Le temps actif sur la tâche de référence est également un prédicteur significatif (les participants plus lents à la tâche de référence restent plus lents en tâche expérimentale, à condition égale), ce qui valide la pertinence de l'ANCOVA. Les facteurs de stratification, comme attendu après vérification de leur équilibre, n'apportent pas de variance résiduelle exploitable au-delà du contrôle par la randomisation.

Les contrastes planifiés (chapitre 3 §3.6; correction de Holm pour les comparaisons par paires) sont rapportés au tableau 4.6.

TABLE 4.6. Contrastes planifiés sur le temps actif expérimental (ANCOVA, ajustement Holm).

Contraste	Estimation (secondes)	SE	$t(91)$	p (Holm)
C2 vs. C1 (H1)	-875	204	-4,29	< 0,001
C3 vs. C2	+770	201	3,83	< 0,001
C3 vs. C1	-105	208	-0,51	0,614

H1 est fortement confirmée : l'accès libre à l'IA (C2) réduit le temps actif moyen de 875 secondes (environ 14,6 minutes) par rapport au contrôle, après ajustement pour la performance de référence et les facteurs de stratification. Le contraste C3 vs. C2 indique que l'encadrement coûte 770 secondes

(environ 12,8 minutes), partiellement attribuable à la durée minimale de 5 minutes imposée à l'étape A. Le contraste C3 vs. C1 n'est en revanche pas significatif : l'IA encadrée ne procure pas de gain de vitesse mesurable par rapport au contrôle, contrairement à l'IA libre. L'analyse PP ($n = 85$ après restriction aux non-signalés) renforce le résultat avec une estimation plus grande (C2 vs. C1 : $-1\,045$ secondes, p (Holm) $< 0,001$; η^2 partiel condition = $0,22$; $f \approx 0,53$), les participants signalés *excluded* tirant légèrement vers le bas le contraste observé sur l'échantillon ITT global.

La distribution du temps actif étant fortement asymétrique, la robustesse de ce résultat aux valeurs extrêmes a été vérifiée par trois voies (chapitre 3 §3.7) : aucune observation n'exerce d'influence dépassant nettement le seuil conventionnel (distance de Cook maximale d'environ $0,50$), et l'effet est confirmé par des analyses immunisées contre les valeurs extrêmes, à savoir un test de Kruskal-Wallis ($p < 0,001$), un test de Mann-Whitney sur le contraste C2 vs. C1 ($p < 0,001$) et une ANCOVA sur le temps actif log-transformé (contraste C2 vs. C1 toujours significatif, $p < 0,001$). Le gain de vitesse de l'IA libre n'est donc pas un artefact de quelques durées atypiques.

4.3 Mode d'interaction avec l'IA, mesures objectives (H3, partie 1)

L'hypothèse H3 prédit que l'IA libre (C2) est dominée par un mode substitutif (l'IA produit, l'humain copie) tandis que l'IA encadrée (C3) favorise un mode complémentaire (l'humain produit, l'IA critique). Deux métriques objectives, extraites des logs du chatbot, opérationnalisent cette hypothèse : le taux de rétention textuelle entre les réponses du chatbot et le texte finalement soumis, et le nombre de messages utilisateur délibérés.

4.3.1 Sémantique du nombre de messages selon la condition

Un point méthodologique doit être précisé en préalable. En condition C2, chaque message utilisateur des logs est délibéré. En condition C3, en revanche, le premier message transmis au chatbot est automatique : la plateforme envoie la version de fin d'étape A au système pour déclencher la critique de l'IA, de sorte que tout message supplémentaire est le seul indicateur d'un dialogue délibéré après la critique. Le nombre de messages utilisateur délibérés est donc le nombre brut de messages pour C2, et le nombre brut moins le message initial automatique pour C3.

Sur les 34 participants C2 phase 5, 6 (18 %) n'ont jamais ouvert le chatbot et sont donc absents de l'analyse de rétention textuelle (échantillon C2 effectif = 28). En condition C3, sur les 33 participants phase 5, 18 (54,5 %) n'ont envoyé aucun message au-delà de la transmission automatique : ils ont reçu la critique de l'IA sans engager de dialogue.

4.3.2 Définition opérationnelle de l'« usage effectif » de l'IA en C3

L'analyse comparative C2/C3 bénéficie de distinguer, au sein de C3, les participants ayant effectivement utilisé l'IA de ceux n'ayant fait que recevoir la critique. Deux critères sont envisageables : le dialogue (au moins un message délibéré après la critique automatique) et la révision (modification du texte entre la fin de l'étape A et la soumission). Le critère retenu est la révision (similarité Damerau-Levenshtein entre version initiale et finale inférieure à $0,95$), car c'est l'effet du retour critique sur la production, et non l'intensité du dialogue, qui importe pour la complémentarité : un participant qui dialogue sans modifier son texte ne tire pas de bénéfice mesurable du chatbot, tandis qu'une révision substantielle en témoigne même sans dialogue ultérieur.

Sur les 33 participants C3, 14 (42,4 %) satisfont ce critère et constituent le sous-groupe « ayant utilisé l'IA » sur lequel les analyses stratifiées de §4.3.3, §4.4 et §4.6 s'appuient. Les 19 participants restants (57,6 %) soumettent un texte virtuellement identique à leur version de fin d'étape A et sont qualifiés de non-utilisateurs effectifs.

4.3.3 Taux de rétention textuelle

La métrique de rétention textuelle suit la formulation de Dell'Acqua et al. (2023, p. 49). Pour chaque réponse soumise a par le participant, on calcule

$$\text{retention}(a) = 1 - \text{RDL}(a, r^*) / \max(|a|, |r^*|)$$

où r^* est la réponse du chatbot la plus similaire au texte soumis (sur l'ensemble des réponses assistant produites au cours de la session) et RDL la distance restreinte de Damerau-Levenshtein. Une valeur proche de 1 indique que le texte soumis est virtuellement identique à une réponse du chatbot (mode substitutif), une valeur proche de 0 indique l'indépendance des deux textes. Dell'Acqua et al. (2023) rapportent un mode de rétention d'environ 0,87 dans leur étude de consultants BCG utilisant GPT-4, ce qui leur permet de qualifier le comportement modal de copier-coller.

Le tableau 4.7 rapporte les statistiques par condition sur l'échantillon ayant interagi avec le chatbot. La figure 4.4 illustre la distribution.




FIGURE 4.4. Taux de rétention textuelle, C2 vs. C3.

TABLE 4.7. Taux de rétention textuelle (RDL normalisé), C2 et C3 (PP).

Sous-échantillon	n	Médiane	Moyenne (SD)
C2 (a ouvert le chatbot)	28	0,986	0,871 (0,242)
C3 (tous)	33	0,265	0,276 (0,048)
C3 (a effectivement utilisé l'IA, critère révision)	14	0,262	0,274 (0,069)

La différence est massive : en C2, la médiane de 0,99 signifie que la moitié des participants ont soumis un texte virtuellement identique à une réponse de GPT-4o, conformément au mode substitutif décrit par Dell'Acqua et al. (2023) ; en C3, la médiane tombe à 0,26, le system prompt en mode *sounding board* (qui refuse de rédiger et oblige le participant à formuler) produisant un découplage marqué entre le contenu généré par l'IA et le texte soumis. La rétention reste basse que les participants C3 aient ou non effectivement utilisé l'IA, ce qui confirme que la mécanique de C3 (verrou pendant l'étape A, system prompt qui refuse de rédiger) produit son effet structurel indépendamment de l'intensité d'engagement.

Le test unilatéral $C2 > C3$ conduit à Cohen's $d = 3,55$ [2,73 ; 4,36] sur l'échantillon ITT (tous les participants C2/C3 phase 5 ayant interagi avec le chatbot) et à $d = 3,43$ [2,60 ; 4,25] en restriction PP. En restreignant le sous-groupe C3 aux participants ayant effectivement utilisé l'IA (critère révision), Cohen's $d = 2,94$ [2,02 ; 3,84]. La figure 4.5 décompose la distribution de C3 selon que les participants ont effectivement utilisé l'IA (révision) ou non.




FIGURE 4.5. Rétention textuelle stratifiée par usage effectif du chatbot en C3.

4.3.4 Nombre de messages utilisateur délibérés

Le tableau 4.8 rapporte la distribution du nombre de messages utilisateur délibérés par condition. Le schéma principal est en deux temps : (i) les participants C2 envoient en médiane 1 message délibéré (IQR 1 à 3), c'est-à-dire qu'ils interagissent typiquement par une transmission unique de l'énoncé puis

soumettent la réponse reçue ; (ii) les participants C3 envoient en médiane 0 message délibéré, c’est-à-dire que la majorité reçoit la critique automatique et ne dialogue pas davantage avant de soumettre.

TABLE 4.8. Nombre de messages utilisateur délibérés par condition (ITT phase 5).

Condition	n	Part ayant ouvert le chatbot (C2) ou dialogué (C3)	Messages délibérés (médiane, IQR)
C2	34	28 / 34 (82 %)	1 (1 à 3)
C3	33	15 / 33 (45 %)	0 (0 à 2)

Le test de Mann-Whitney sur le nombre de messages délibérés ne révèle pas de différence significative entre C2 et C3 ($U = 366,5$; $p = 0,50$). Ce résultat est attendu : la fréquence d’interaction n’est pas la dimension qui différencie les deux conditions, c’est la nature du contenu échangé (mesurée par la rétention textuelle) et l’usage qui en est fait par le participant.

4.4 Mode d’interaction avec l’IA, auto-rapport (H3, partie 2)

L’hypothèse H3 reçoit également un test sur la base des sous-échelles d’usage irréfléchi (*Thoughtless Use*) et d’usage prudent (*Cautious Use*) de l’échelle de dépendance à l’IA générative (Hou et al., 2025, quatre items par sous-échelle), administrées en post-tâche aux conditions C2 et C3 (cf. chapitre 3 §3.5). La cohérence interne des deux sous-échelles est très bonne (α de Cronbach = 0,83 pour l’usage irréfléchi et 0,81 pour l’usage prudent, $n = 67$). Le tableau 4.9 rapporte les scores moyens (quatre items chacun, échelle 1 à 5) et la figure 4.6 illustre la distribution.




FIGURE 4.6. Sous-échelles d’usage déclaré de l’IA (Hou et al., 2025).

TABLE 4.9. Sous-échelles d'usage déclaré de l'IA (Hou et al., 2025), C2 et C3 (PP).

Sous-échelle	Échantillon	C2 moy. (SD)	C3 moy. (SD)	<i>t</i> (Welch)	<i>p</i>	Cohen's <i>d</i> [IC 95 %]
Usage irréfléchi (substitutif)	PP, tous (n = 60)	3,80 (1,26)	2,04 (0,86)	6,35	< 0,001	1,62 [1,03 ; 2,20]
Usage irréfléchi	PP, a utilisé l'IA (n = 42)	4,08 (0,95)	2,18 (0,83)	6,68	< 0,001	2,09 [1,30 ; 2,87]
Usage prudent (complémentaire)	PP, tous (n = 60)	1,88 (0,81)	3,55 (0,71)	8,49	< 0,001	2,18 [1,53 ; 2,82]
Usage prudent	PP, a utilisé l'IA (n = 42)	1,94 (0,82)	3,73 (0,59)	8,10	< 0,001	2,38 [1,54 ; 3,20]

Le sous-groupe « a utilisé l'IA » (n = 42) réunit les participants C2 ayant ouvert le chatbot et les participants C3 ayant effectivement révisé leur texte (n = 14).

Les deux sous-échelles produisent un schéma parfaitement convergent : les participants de C2 déclarent davantage de comportements substitutifs (copier l'énoncé, accepter les suggestions sans modification, déléguer la réflexion) et ceux de C3 davantage de comportements complémentaires (repérer des erreurs, écarter des suggestions, compléter sans recourir au chatbot). Les tailles d'effet sont exceptionnellement grandes (au-delà de $d = 1,5$ dans tous les cas, et dépassant $d = 2$ chez les participants ayant effectivement utilisé l'IA selon le critère de révision). La corrélation négative attendue entre les deux sous-échelles est confirmée au niveau individuel ($r = -0,555$; $p < 0,001$; C2 et C3 PP combinés), ce qui valide la cohérence interne théorique du contraste.

Effort cognitif

L'item NASA-TLX d'effort mental perçu (échelle 1 à 7) varie significativement entre les trois conditions (Kruskal-Wallis $\chi^2(2) = 25,4$; $p < 0,001$) : l'effort médian est de 2 en C2 (moyenne 2,38), contre 4 en C1 (moyenne 4,37) et 4 en C3 (moyenne 4,15). Les comparaisons par paires (Holm) indiquent un effort perçu significativement plus faible en C2 qu'en C1 ($p < 0,001$) et qu'en C3 ($p < 0,001$), tandis que C1 et C3 ne diffèrent pas ($p = 0,247$). Ce schéma (figure 4.7), où l'encadrement organisationnel ramène l'effort cognitif au niveau du contrôle sans IA, réplique Ghosh et al. (2026), qui ne trouvent aucune différence d'effort cognitif (NASA-TLX) entre leurs quatre conditions de forçage cognitif ($H = 2,99$; $p = 0,39$). C'est un argument favorable à la viabilité écologique de C3 : le coût cognitif n'est pas plus élevé que celui de la rédaction sans IA, alors que les bénéfices comportementaux (réduction du mode substitutif) sont substantiels.

Effort cognitif perçu par condition (item NASA-TLX)

Échelle 1 (très faible) à 7 (très élevé)




FIGURE 4.7. Effort cognitif perçu par condition.

Performance perçue

La performance perçue (échelle 0 à 100, item unique) ne diffère pas significativement entre conditions (Kruskal-Wallis $\chi^2(2) = 1,66$; $p = 0,437$; médianes C1 = 65, C2 = 72, C3 = 65). La figure 4.8 illustre la distribution. On note toutefois une dispersion considérablement plus grande en C2 (SD = 29,8) qu'en C1 (SD = 17,6) ou C3 (SD = 19,6), suggérant un découplage entre confiance déclarée et performance objective qui est analysé dans le cadre de H4 (surconfiance, §4.8).




FIGURE 4.8. Performance perçue par condition.

4.5 Engagement intra-condition C3 (analyse exploratoire)

L'architecture en deux étapes de la condition C3 (production initiale obligatoire puis critique-révision) permet une mesure complémentaire absente de C1 et C2 : la différence textuelle entre la version de fin d'étape A et la version finale soumise, qui objective le degré d'intégration de la critique du chatbot par le participant. Sur les 33 participants C3 ayant complété la session, la distribution des comportements de révision est rapportée au tableau 4.10.

TABLE 4.10. Distribution des comportements de révision entre la version fin d'étape A et la version finale soumise, condition C3 (n = 33).

Catégorie	n	%
Texte strictement identique (aucune modification)	19	57,6 %
Révision modérée (+10 à +50 %)	2	6,1 %
Révision substantielle (+50 % ou plus)	11	33,3 %
Raccourcissement substantiel	1	3,0 %

Un constat saillant émerge : plus de la moitié des participants de C3 (19 sur 33, soit 57,6 %) soumettent un texte rigoureusement identique à leur version de fin d'étape A. Ces participants n'ont effectué aucune modification après réception de la critique de l'IA, malgré le déverrouillage du chatbot. À l'inverse, environ un tiers des participants (33,3 %) procèdent à une révision substantielle, augmentant la longueur de leur texte d'au moins 50 % en réponse à la critique.

Le croisement de cette mesure avec l'indicateur de dialogue (envoi d'au moins un message après la

critique automatique) clarifie le tableau (figure 4.9) :




FIGURE 4.9. Croisement dialogue × révision en C3.

- **17 participants C3 (51,5 %)** n'ont ni dialogué avec l'IA ni révisé leur texte : ils ont reçu la critique et soumis leur version initiale à l'identique ;
- **2 participants (6,1 %)** ont dialogué sans réviser leur texte ;
- **1 participant (3,0 %)** a révisé son texte sans dialogue supplémentaire ;
- **13 participants (39,4 %)** ont dialogué et révisé leur texte, profil pleinement actif sur les deux dimensions.

Cette gradation interne suggère que l'architecture C3 force la mécanique du protocole (production initiale, exposition à la critique) sans garantir l'*usage effectif* du retour critique, ce qui pourrait diluer l'effet C3 vs. C2 sur la qualité globale : on s'attend à ce que les participants C3 ayant effectivement révisé ($n = 14$) tirent un bénéfice de la critique, tandis que les C3 « identiques » se rapprochent des C1 sans IA. Cette gradation est examinée en §4.6.6 et interprétée au chapitre 5.

4.6 Qualité globale (H2)

L'hypothèse H2 prédit que l'IA encadrée (C3) améliore la qualité globale et la fiabilité factuelle par rapport à l'IA libre (C2). La présente section porte sur la qualité globale (VD1) ; la fiabilité factuelle est traitée en §4.7.

4.6.1 Fiabilité inter-évaluateurs

La qualité globale est le score composite des quatre dimensions (échelle 1 à 4), moyenné sur les deux évaluateurs. La fiabilité inter-évaluateurs, mesurée par un coefficient de corrélation intraclasse two-way mixed, consistency, average-measures (Hallgren, 2012), est excellente au sens de Cicchetti (1994) : ICC = 0,848 [0,798 ; 0,885] sur les 194 productions, confirmée sur le sous-ensemble de calibration (ICC = 0,85 sur 15 productions) comme sur le bloc principal seul (ICC = 0,853 sur 179). Par dimension, l'accord va de bon à excellent : qualité rédactionnelle 0,810, qualité analytique 0,721, fiabilité factuelle 0,754, et

jugement et nuance 0,598 (seule dimension sous le seuil « excellent », au niveau « bon »). La VD1 peut donc être considérée comme une mesure fiable.

4.6.2 Statistiques descriptives et analyse de covariance

Le tableau 4.11 rapporte la qualité globale par condition. La figure 4.10 illustre la distribution.




FIGURE 4.10. Qualité globale de la production expérimentale par condition.

TABLE 4.11. Qualité globale de la production expérimentale par condition (ITT, n = 97 ; échelle 1 à 4).

Condition	n	Moyenne	SD
C1, contrôle	30	2,74	0,68
C2, IA libre	34	3,01	0,61
C3, IA encadrée	33	2,53	0,66

Le schéma descriptif est l'inverse de celui prédit par H2 : c'est l'IA libre (C2) qui obtient la qualité la plus élevée, et l'IA encadrée (C3) la plus basse, en deçà même du contrôle sans IA. L'ANCOVA (qualité ~ condition + qualité de référence + familiarité + expérience IA) confirme un effet significatif de la condition, $F(2, 91) = 6,22$, $p = 0,003$, η^2 partiel = 0,13. Les contrastes planifiés (correction de Holm) sont rapportés au tableau 4.12.

TABLE 4.12. Contrastes planifiés sur la qualité globale (ANCOVA, ITT ; estimations en points sur l'échelle 1 à 4).

Contraste	Estimation	$t(91)$	p (Holm)
C3 vs. C2 (H2)	-0,45	-3,50	0,002
C2 vs. C1	+0,27	2,06	0,085
C3 vs. C1	-0,18	-1,35	0,182

H2 n'est pas confirmée : elle est inversée. Le contraste C3 vs. C2, qui teste directement l'hypothèse, est significativement négatif ($-0,45$ point, $p = 0,002$) : l'IA encadrée produit des productions notées plus bas que l'IA libre. L'analyse PP ($n = 85$) donne un résultat identique en direction et en magnitude (C3 vs. C2 = $-0,43$, $p = 0,004$; η^2 partiel = $0,11$). Le contraste C2 vs. C1 est positif mais non significatif après correction ($+0,27$, $p = 0,085$), et C3 vs. C1 ne diffère pas de zéro : l'IA encadrée ramène la qualité au niveau de la rédaction sans IA.

Restreindre la condition C3 aux seuls participants ayant effectivement révisé leur texte après la critique (sous-groupe « révision », $n = 14$, cf. §4.5) ne renverse pas ce résultat : le contraste C3 vs. C2 reste significativement négatif ($-0,45$, $p = 0,026$ en ITT ; $-0,44$, $p = 0,023$ en PP). L'effet n'est donc pas un simple artefact de la conformité superficielle de la majorité des participants C3.

4.6.3 Décomposition par dimension : un avantage de surface

La figure 4.11 décompose la qualité par dimension et par condition.




FIGURE 4.11. Qualité par dimension et par condition.

L'avantage de C2 sur C3 ne se distribue pas uniformément sur les quatre dimensions (ANCOVA par dimension, PP, contraste C3 vs. C2) : il est marqué sur la qualité rédactionnelle ($-0,61$, $p = 0,001$) et la qualité analytique ($-0,59$, $p = 0,0004$), mais non significatif sur la fiabilité factuelle ($-0,31$, $p = 0,11$)

et sur le jugement et nuance ($-0,23$, $p = 0,23$). Le seul avantage significatif de C2 sur C1 concerne d'ailleurs la qualité rédactionnelle ($+0,48$, $p = 0,009$). Autrement dit, la supériorité de C2 se concentre sur la forme (structure, fluidité, organisation de l'argumentation) et s'efface sur les dimensions de fond que sont l'exactitude factuelle et le jugement critique.

4.6.4 Le rôle de la longueur

Une explication partielle de l'avantage de C2 réside dans la longueur des productions (figure 4.12) : celles de C2 comptent en moyenne 562 mots (SD 433), contre 331 pour C1 et C3, et la longueur est fortement corrélée à la qualité notée (Spearman $r = 0,76$). Lorsque le nombre de mots de la production expérimentale est introduit comme covariable additionnelle dans l'ANCOVA, l'avantage de C2 sur C1 disparaît (contraste C2 vs. C1 = $+0,09$, $p = 0,52$), tandis que le déficit de C3 par rapport à C2 se réduit mais demeure significatif ($-0,33$, $p = 0,037$). Une part substantielle de la « supériorité » de C2 est donc une prime à la verbosité que la grille récompense ; le déficit de C3 n'est, lui, pas qu'une question de longueur.




FIGURE 4.12. Longueur des productions expérimentales par condition.

4.6.5 Robustesse et égalisation

Le résultat est robuste au traitement des valeurs aberrantes : aucune valeur aberrante n'est détectée sur la VD1, quel que soit le seuil (Tukey $1,5 \times \text{IQR}$, $3 \times \text{IQR}$, ou MAD robuste), et aucune observation n'exerce d'influence induite sur le modèle (distance de Cook maximale = 0,13). Les quatre analyses de sensibilité confirment la stabilité du contraste C3 vs. C2, qui reste compris entre $-0,42$ et $-0,45$ ($p < 0,004$) avec l'ajout du genre (S1), du niveau d'études (S2) ou de l'ancienneté (S3) comme covariable, et en restriction aux participants de 35 ans ou moins (S4).

Le test de Brown-Forsythe ne révèle aucune différence de variance de la qualité entre conditions ($p = 0,48$; écarts-types C1 0,68, C2 0,61, C3 0,66), et l'interaction condition $\times$ qualité de référence n'est

pas significative ($p = 0,46$) : l'effet d'égalisation documenté par Noy & Zhang (2023) et Brynjolfsson et al. (2023) ne se retrouve donc pas sur la dispersion des scores de qualité. Une trace en demeure au niveau descriptif : le gain de qualité par rapport à la référence est plus élevé en C2 (+0,46 point) qu'en C1 (+0,24) ou en C3 (+0,05), le tertile le plus faible en référence bénéficiant davantage de C2 (qualité moyenne 2,66 contre 2,39 en C1), et la pente de régression référence $\rightarrow$ expérimentale est la plus plate en C3 (0,28, contre 0,59 en C1 et 0,49 en C2).

4.6.6 Qui révise, et avec quel effet ?

Une régression logistique sur les seuls participants C3 prédisant la révision effective (similarité $< 0,95$) montre que ce sont les participants à meilleure qualité de référence ($\beta = 2,24$, $p = 0,028$) et à plus forte expérience de l'IA ($\beta = 2,22$, $p = 0,040$) qui révisent leur texte après la critique : le garde-fou est donc mobilisé par les plus compétents et les plus familiers de l'outil, et délaissé par ceux qui en bénéficieraient le plus. Au sein de C3, les réviseurs obtiennent une qualité moyenne supérieure aux non-réviseurs (2,80 contre 2,45), sans atteindre le seuil de significativité au vu de la petite taille des sous-groupes ($d = 0,60$, $p = 0,11$), les non-réviseurs se situant même légèrement sous le contrôle C1 ($d = -0,61$, $p = 0,09$). Conformément à l'anticipation formulée en §4.5, la révision active rapproche de C2 sans l'atteindre, tandis que le désengagement ramène au niveau du sans-IA.


Enfin, la qualité notée est positivement corrélée au mode substitutif : $r = 0,64$ avec le score d'usage irréfléchi et $r = 0,47$ avec le taux de rétention textuelle (Spearman). Plus un participant délègue à l'IA, mieux sa production est notée, ce qui éclaire le caractère inversé de H2 et sera interprété au chapitre 5.

4.7 Fiabilité factuelle (VD3)

La fiabilité factuelle est opérationnalisée par le F1-Score (van Rijsbergen, 1979 ; Sokolova & Lapalme, 2009) calculé sur la grille exhaustive des éléments factuels du dossier (26 codes, annexe E), à partir des comptages de vrais positifs, faux positifs et faux négatifs extraits par l'auteur en aveugle de la condition. Le tableau 4.13 rapporte les résultats sur la tâche expérimentale (PP). La figure 4.13 illustre la distribution.

Fiabilité factuelle (F1-Score) de la production expérimentale par condition

F1 sur les 26 éléments factuels du dossier ; aucune différence significative entre conditions



Précision élevée et homogène entre conditions ; la variation de F1 reflète surtout la couverture (rappel). ITT n = 97.

FIGURE 4.13. Fiabilité factuelle (F1-Score) par condition.

TABLE 4.13. Fiabilité factuelle de la production expérimentale par condition (PP).

Condition	n	F1 moyen	Précision	Rappel
C1, contrôle	25	0,547	1,00	0,40
C2, IA libre	31	0,591	0,94	0,46
C3, IA encadrée	29	0,502	0,99	0,36

Aucune différence significative n'oppose les trois conditions sur la fiabilité factuelle (Kruskal-Wallis $p = 0,094$; ANCOVA, contraste C3 vs. C2 = $-0,12$, $p = 0,076$ après Holm) : le second volet de H2 n'est pas soutenu. Deux constats méritent attention. D'abord, la précision est très élevée et homogène entre conditions (de 0,94 à 1,00) : lorsqu'un participant énonce un fait du dossier, il est presque toujours exact, quelle que soit la condition ; la variation de F1 est portée par le rappel, modeste partout (0,36 à 0,46) et légèrement supérieur en C2. Ensuite, le compteur de faits inventés est nul dans toutes les conditions ($fp_inventes = 0$, aucun fait présenté comme issu du dossier alors qu'il en est absent) : la délégation à GPT-4o n'a introduit aucune fabrication de ce type, contrairement à ce que la crainte d'une surconfiance hallucinatoire pourrait laisser attendre.

La dimension « fiabilité factuelle » de la grille de qualité (VD1, jugée par les évaluateurs) et le F1-Score (VD3, extrait par codage) constituent deux opérationnalisations indépendantes de la même propriété ; leur forte corrélation (Spearman $r = 0,80$) constitue une preuve de validité convergente. Six des vingt-six codes ne sont jamais couverts par aucun participant (taux de vrais positifs nul) ; les retirer relève la valeur absolue du F1 (C1 0,64, C2 0,69, C3 0,59) sans modifier le classement entre conditions ni la conclusion, de sorte que la grille exhaustive est conservée comme mesure principale.

4.8 Surconfiance (H4)

L'hypothèse exploratoire H4 prédit un écart performance perçue – performance réelle plus grand en C2 qu'en C3. Les deux variables étant mesurées sur des échelles non commensurables (0 à 100 pour la perception, 1 à 4 pour la qualité), la surconfiance est opérationnalisée par les résidus d'une régression de la performance perçue sur la performance réelle. Le tableau 4.14 rapporte les deux variables brutes par condition (présentation parallèle). La figure 4.14 illustre la relation.




FIGURE 4.14. Performance perçue vs. performance réelle, par condition.

TABLE 4.14. Performance perçue et réelle par condition (PP).

Condition	Perçue (0-100), moyenne (SD)	Réelle (1-4), moyenne
C1, contrôle	62,7 (17,6)	2,84
C2, IA libre	63,9 (29,8)	3,02
C3, IA encadrée	60,2 (19,6)	2,62

La performance perçue ne diffère pas significativement entre conditions (Kruskal-Wallis $p = 0,437$), et les résidus de calibration ne diffèrent pas en moyenne entre C2 et C3 ($d = 0,08$ à $0,15$ selon l'échantillon, $p > 0,26$) : H4 n'est pas soutenue en moyenne. Le signal se situe dans la dispersion : l'écart-type des résidus de calibration est nettement plus élevé en C2 (30 points) qu'en C1 (17) ou C3 (19), schéma déjà visible sur la performance perçue brute (SD 29,8 en C2). L'IA libre ne rend pas les participants surconfiants en moyenne, mais découple leur confiance de leur performance réelle, certains se montrant très surconfiants et d'autres très sous-confiants.

Une analyse exploratoire précise ce découplage. La corrélation entre performance perçue et réelle, modérément positive dans le contrôle sans IA (Spearman $r = 0,25$), s'annule en IA libre ($r = -0,10$) et reste quasi nulle en IA encadrée ($r = 0,08$) : la confiance des participants assistés ne suit plus leur performance. Le détail par tertile de compétence de base est plus frappant : en condition libre, les plus faibles à la tâche de référence se déclarent les plus confiants (performance perçue moyenne de 75 sur 100 dans le tertile inférieur, contre 55 dans le même tertile du contrôle). L'IA libre gonfle donc spécifiquement la confiance des moins performants, prolongeant le constat de Fernandes et al. (2026) sur le brouillage de

la calibration métacognitive. Compte tenu des effectifs réduits, ce résultat est exploratoire et interprété au chapitre 5.

4.9 Homogénéisation des productions et contenu des interactions

Au-delà de la qualité individuelle, l'effet de l'IA sur la diversité collective des productions a été mesuré en suivant Doshi & Hauser (2024) : la similarité cosinus moyenne entre paires de productions d'une même condition (sur les fréquences de mots) indexe le degré d'homogénéisation. La figure 4.15 illustre les distributions.




FIGURE 4.15. Similarité intra-condition des productions.

La similarité moyenne intra-condition est de 0,445 en C1, 0,673 en C2 et 0,453 en C3 : les productions réalisées avec l'IA libre se ressemblent nettement plus entre elles que celles produites sans IA ou avec l'IA encadrée (C2 vs. C1 et C2 vs. C3, $p < 0,001$; intervalles de confiance bootstrap non chevauchants). L'IA libre homogénéise fortement les productions, là où l'IA encadrée préserve la diversité au niveau du sans-IA. Ce résultat réplique Doshi & Hauser (2024, $b = 0,871$, $p < 0,001$ pour l'effet d'homogénéisation) et met en évidence un coût de l'IA libre invisible au niveau de la qualité individuelle.

L'analyse du contenu des prompts éclaire ce contraste. En C2, le premier message compte en médiane 620 mots, reprend le dossier dans 86 % des cas et constitue une demande directe de rédaction dans 79 %, signature d'un collage de l'énoncé suivi d'une délégation ; en C3, le premier message délibéré compte en médiane 17 mots et relève d'une question ciblée (20 % reprennent le dossier, 7 % demandent une rédaction). Ce contraste réplique, en l'amplifiant, l'opposition entre messages superficiels de Bastani et al. (2025, 67 % contre 37 %). Enfin, au sein de C2, une rétention textuelle plus élevée est associée à une meilleure qualité notée ($r = 0,52$, $p = 0,005$) : sur cette tâche, le copier-coller de GPT-4o est une stratégie efficace, cohérent avec Dell'Acqua et al. (2023), pour qui une rétention élevée améliore la performance sur les tâches situées à l'intérieur de la frontière technologique.

4.10 Synthèse des résultats

Les résultats du présent chapitre conduisent aux constats suivants.

1. La randomisation par minimisation de Pocock-Simon a produit un équilibrage excellent sur les facteurs de stratification et les covariables non stratifiées ; les analyses procèdent sans risque de confusion démographique.
2. **H1 (vitesse) est fortement confirmée** : l'IA libre réduit le temps actif d'environ 15 minutes par rapport au contrôle (-875 secondes en ITT, $-1\,045$ en PP ; η^2 partiel = 0,17 à 0,22), tandis que l'IA encadrée n'apporte aucun gain de vitesse.
3. **H3 (mode d'interaction) est très fortement confirmée** : la rétention textuelle oppose radicalement C2 (médiane 0,99) et C3 (médiane 0,26 ; $d = 3,55$), de même que les sous-échelles d'usage irréfléchi ($d = 1,62$) et d'usage prudent ($d = 2,18$) ; l'effort cognitif, plus faible en C2 mais identique en C3 et C1, réplique Ghosh et al. (2026) et atteste de la viabilité écologique de C3.
4. **H2 (qualité) est infirmée, et même inversée** : la qualité est la plus élevée en C2 (3,01) et la plus basse en C3 (2,53 ; contraste C3 vs. C2 = $-0,45$, $p = 0,002$), C3 ne se distinguant pas du contrôle. L'avantage de C2 se concentre toutefois sur la forme (rédactionnel, analytique), tient pour partie à la longueur des productions, et s'efface sur la fiabilité factuelle et le jugement.
5. **La fiabilité factuelle (VD3) ne diffère pas entre conditions** (précision de 0,94 à 1,00, aucune fabrication factuelle) : le second volet de H2 n'est pas soutenu.
6. **H4 (surconfiance) n'est pas soutenue en moyenne**, mais l'IA libre découple la confiance de la performance (variance des résidus de calibration deux fois plus élevée en C2).
7. **L'IA libre homogénéise les productions** (similarité intra-condition 0,67 contre 0,45), là où l'IA encadrée préserve la diversité au niveau du sans-IA : un coût collectif invisible au niveau individuel.
8. La condition C3 force la mécanique du protocole sans garantir l'usage effectif du retour critique (57,6 % de textes inchangés après la critique), et le garde-fou est davantage mobilisé par les participants les plus compétents et expérimentés.

Le chapitre 5 interprète ces résultats à la lumière de la littérature et en discute les limites.

Chapitre 5

Discussion

Le chapitre précédent a établi une configuration de résultats nette, mais en partie contraire à l'hypothèse de départ. Les deux hypothèses portant sur l'accès libre à l'IA et sur le processus d'interaction sont confirmées avec des effets de grande magnitude : l'IA libre accélère massivement le travail (H1) et installe un mode d'interaction substitutif que l'encadrement transforme en mode complémentaire (H3). En revanche, l'hypothèse centrale du mémoire, selon laquelle cet encadrement améliorerait la qualité et la fiabilité factuelle (H2), n'est pas confirmée, et se trouve même inversée sur la qualité notée : la condition encadrée (C3) obtient le score le plus bas des trois et l'IA libre (C2) le plus élevé. Cet écart ne traduit cependant pas une supériorité générale de l'usage libre : il porte sur les dimensions visibles du texte (rédaction, structure, longueur) et s'efface, comme on le verra, sur la fiabilité factuelle et le jugement ; de plus, si la surconfiance ne diffère pas en moyenne, l'IA libre découple la confiance de la performance. L'IA libre optimise donc le livrable selon certains critères, sans que l'on puisse en conclure qu'elle produit un travail de meilleure qualité. Le présent chapitre interprète cette configuration à la lumière de la littérature (section 5.1), puis en discute les limites méthodologiques (section 5.2).

5.1 Interprétation des résultats à la lumière de la littérature

5.1.1 La vitesse et le mode d'interaction : des effets attendus, de magnitude exceptionnelle

Le gain de vitesse de l'IA libre (H1) réplique le résultat le plus convergent de la littérature. La réduction d'environ quinze minutes de temps actif par rapport au contrôle (η^2 partiel de 0,17 à 0,22) s'inscrit dans la lignée des baisses documentées par Noy & Zhang (2023, -37 %), Brynjolfsson, Li & Raymond (2023, +15 % de productivité) et Cui et al. (2025, +26 % de tâches complétées). L'encadrement annule ce gain : la condition C3 ne complète pas la tâche plus vite que le contrôle, ce qui était attendu puisque son architecture impose une production initiale sans assistance d'au moins cinq minutes avant tout accès à l'IA. La vitesse n'est donc un bénéfice de l'IA que dans sa version non encadrée.

Le mode d'interaction (H3) confirme avec une force remarquable la distinction théorique qui structure le mémoire. En condition libre, le taux de rétention textuelle atteint une médiane de 0,99 : la moitié des participants soumettent un texte virtuellement identique à une réponse de GPT-4o, valeur qui dépasse le mode de 0,87 de Dell'Acqua et al. (2023) et rejoint le constat de Noy & Zhang (2023) selon lequel 68 % des participants soumettent le texte de l'IA sans le modifier. Le contenu des messages le confirme : en condition libre, le premier message reprend massivement l'énoncé, signature d'une délégation intégrale, là où la condition encadrée fait tomber la rétention à 0,26 et ne suscite que des questions ciblées. Les sous-échelles auto-rapportées de Hou et al. (2025) corroborent ce contraste avec des tailles d'effet supérieures à deux écarts-types. L'encadrement a donc atteint son objectif comportemental, substituant au mode *ghostwriter* (l'IA produit, l'humain copie) le mode *sounding board* (l'humain produit, l'IA critique) que Chen & Chan (2024) identifient comme supérieur, et sans surcoût cognitif, l'effort perçu en C3 étant identique à celui du contrôle sans IA, ce qui réplique Ghosh et al. (2026) et atteste de la viabilité écologique de C3.

En somme, la condition C3 fonctionne exactement comme elle a été conçue au niveau du processus. C'est sur le résultat que le dispositif déçoit.

5.1.2 Le paradoxe central : un encadrement qui transforme le comportement sans améliorer la qualité (H2)

La théorie des complémentarités de Milgrom & Roberts (1995), transposée au niveau micro-comportemental, prédisait que le couplage de l'IA et de mécanismes d'encadrement produirait une qualité supérieure à celle de l'IA sans encadrement, comme Bughin & van Zeebroeck (2021) le montrent pour l'investissement digital associé au renouvellement stratégique. Les résultats contredisent cette prédiction : non seulement C3 n'améliore pas la qualité par rapport à C2 (contraste de $-0,45$ point, $p = 0,002$), mais elle la ramène au niveau du contrôle sans IA, constat que ni la restriction aux réviseurs effectifs ni les quatre analyses de sensibilité ne renversent.

Ce résultat est d'autant plus frappant qu'il coexiste avec la confirmation éclatante de H3 : l'encadrement a bien déplacé le comportement du mode substitutif vers le mode complémentaire, mais sans gain de qualité. La logique du mémoire supposait que le mode substitutif dégradait la qualité et que restaurer l'engagement cognitif l'améliorerait ; les données indiquent l'inverse, puisque sur cette tâche c'est le mode substitutif qui est associé à la meilleure qualité notée. Les corrélations positives entre la qualité et le score de mode substitutif ($r = 0,64$) comme le taux de rétention textuelle ($r = 0,47$) le confirment : plus un participant délègue à l'IA, mieux son travail est évalué.

5.1.3 Pourquoi l'encadrement n'améliore pas la qualité : trois explications convergentes

Trois mécanismes, tous documentés dans la littérature, rendent compte de ce paradoxe.

Le premier est la position de la tâche sur la frontière technologique de l'IA. Dell'Acqua et al. (2023) montrent que, sur les tâches à l'intérieur de la frontière, un taux de rétention élevé est associé à une meilleure performance : le copier-coller y est une stratégie rationnelle, non une abdication. La tâche du mémoire, l'évaluation d'une stratégie d'entreprise à partir d'un dossier structuré, en relève manifestement, et la fiabilité factuelle le confirme (précision de 0,94 à 1,00, aucun fait inventé) : GPT-4o ne se trompe pratiquement pas. Or tout l'édifice des mécanismes d'encadrement, des fonctions de forçage cognitif de Buçinca et al. (2021) au tuteur contraint de Bastani et al. (2025) et à l'identification des hypothèses implicites de Ghosh et al. (2026), repose sur l'hypothèse que l'IA commet des erreurs que l'utilisateur doit apprendre à détecter, ou qu'un effort cognitif supplémentaire améliore le résultat. Lorsque l'IA produit d'emblée un texte complet et bien structuré, forcer l'humain à produire puis réviser ajoute de l'effort sans contrepartie sur le livrable.

Le deuxième mécanisme est la nature largement formelle de l'avantage de l'IA libre. La décomposition par dimension est décisive : la supériorité de C2 sur C3 est significative sur la qualité rédactionnelle et analytique, mais s'efface sur la fiabilité factuelle et le jugement critique ; de plus, l'introduction de la longueur comme covariable fait disparaître l'avantage de C2 sur le contrôle et réduit nettement son avantage sur C3. GPT-4o produit des textes plus longs, plus complets et mieux organisés, et la grille d'évaluation récompense cette complétude formelle sans qu'elle reflète nécessairement une supériorité du raisonnement sous-jacent. L'avantage de C2 n'est donc pas une pensée plus profonde, mais un polissage et une exhaustivité sur lesquels l'humain encadré, contraint d'écrire lui-même en un temps limité, ne peut rivaliser.

Le troisième mécanisme est la conformité superficielle au dispositif d'encadrement. Plus de la moitié

des participants de C3 (57,6 %) ont soumis un texte rigoureusement identique à leur version de fin d'étape A, sans aucune modification après la critique de l'IA : l'architecture a forcé la mécanique du protocole (production initiale, exposition à la critique) sans garantir l'usage effectif du retour critique. Ce phénomène fait écho à Jackson & Schneider (2015), chez qui la conformité à la checklist plafonne à 30 % et son effet disparaît dès que le suivi est retiré, et prolonge le constat de Buçinca et al. (2021) selon lequel les fonctions de forçage cognitif réduisent l'excès de confiance sans l'éliminer (de 64 % à 48 %). La conformité de façade n'équivaut pas à l'appropriation. Même les participants ayant effectivement révisé leur texte n'ont toutefois pas atteint le niveau de C2, ce qui indique que la conformité superficielle n'explique qu'une partie du déficit, le reste tenant aux deux premiers mécanismes.

5.1.4 Les coûts cachés de l'IA libre : homogénéisation et découplage de la confiance

Si l'IA libre optimise le livrable individuel sur ses dimensions visibles, elle entraîne des coûts invisibles à l'échelle de chaque production. Le premier est l'homogénéisation : la similarité moyenne entre paires de productions d'une même condition passe de 0,45 sans IA à 0,67 avec l'IA libre, tandis que l'encadrement la maintient au niveau du sans-IA. Ce résultat réplique Doshi & Hauser (2024), qui mesurent une hausse de similarité lorsque les rédacteurs accèdent à des idées générées par l'IA, et Dell'Acqua et al. (2023), qui rapportent une réduction marquée de la variabilité des productions assistées. Au niveau collectif, l'IA libre appauvrit la diversité, là où l'encadrement la préserve : un coût invisible pour qui n'évalue que des productions isolées, mais réel pour une organisation qui dépend de la variété de ses analyses pour innover. C'est ici que la condition C3 démontre une valeur mesurable, non sur la qualité individuelle mais sur la diversité collective.

Le second coût concerne la calibration. H4 prédisait une surconfiance plus marquée en condition libre : en moyenne, elle n'est pas confirmée, l'écart entre performance perçue et réelle ne différant pas significativement entre conditions. Le signal est dans la dispersion, la variance des résidus de calibration étant environ deux fois plus élevée en condition libre : l'IA libre ne rend pas les utilisateurs systématiquement surconfiants, mais découple leur confiance de leur performance effective, certains se croyant bien meilleurs qu'ils ne sont et d'autres l'inverse. Ce découplage prolonge Becker et al. (2025), pour qui des développeurs ralentis par l'IA se croient accélérés, et Lee et al. (2025), pour qui la confiance en l'IA est le plus fort prédicteur de la non-mobilisation de la pensée critique, et s'inscrit dans la tradition de la complaisance face à l'automatisation (Parasuraman & Manzey, 2010). L'encadrement, en imposant une production autonome préalable, semble réancrer la confiance sur une base personnelle plus stable.

Ces deux coûts, additionnés à la substitution cognitive intégrale documentée par H3, dessinent une image que les seuls scores de qualité masquent : l'IA libre maximise le livrable immédiat, mais au prix d'un appauvrissement de la diversité collective, d'un découplage de l'autoévaluation et d'une absence totale d'engagement cognitif. Le coût de l'IA libre ne se loge dans aucune production prise isolément ; il se loge dans le processus et dans le collectif.

5.1.5 Égalisation et équité : qui bénéficie, qui s'engage

La littérature documente un effet d'égalisation par lequel l'IA bénéficie surtout aux travailleurs les moins performants (Noy & Zhang, 2023 ; Brynjolfsson et al., 2023 ; Dell'Acqua et al., 2023). Les données du mémoire en portent une trace descriptive : le gain de qualité par rapport à la performance de base est plus élevé en condition libre, et le tertile de participants les plus faibles en bénéficie davantage. Toutefois, cet effet ne se traduit pas par une compression de la variance des scores de qualité, contrairement à ce qu'observent Noy & Zhang. L'égalisation, ici, est partielle et fragile.

Un résultat plus net, et plus préoccupant, concerne l'équité de l'encadrement lui-même. La régression logistique montre que ce sont les participants à la meilleure performance de base et à la plus grande expérience de l'IA qui révisent effectivement leur texte après la critique : le garde-fou est mobilisé par ceux qui en ont le moins besoin et délaissé par ceux qui en bénéficieraient le plus, les non-réviseurs se situant au niveau du contrôle sans IA. Ce constat inverse la promesse d'égalisation : loin de niveler, un dispositif reposant sur l'engagement volontaire risque de creuser l'écart entre utilisateurs compétents et novices, ces derniers se contentant de la version produite sans assistance. Il rejoint l'avertissement de Kreitmeir & Raschky (2024), pour qui les novices peuvent paradoxalement mieux performer sans IA, et la mise en garde de Bastani et al. (2025) sur la béquille cognitive qui appauvrit l'apprentissage des plus dépendants.

5.1.6 Retour au cadre des complémentarités : une hypothèse conditionnelle à la frontière technologique

Faut-il conclure que la théorie des complémentarités est invalidée au niveau micro-comportemental ? La réponse est négative, mais impose une reformulation importante. Lu & Zhang (2024) ont montré que la complémentarité humain-machine est conditionnelle : elle n'émerge que lorsque deux conditions sont réunies simultanément, une information suffisamment complexe et des explications structurées de la machine, et non lorsque la machine seule traite déjà la tâche avec compétence. Schemmer et al. (2023) ont par ailleurs établi qu'un recours approprié suppose que l'humain résiste aux mauvais conseils de l'IA, ce qui n'a de sens que si l'IA en émet. Or la tâche du mémoire, située à l'intérieur de la frontière technologique, ne réunit pas ces conditions : l'IA y est compétente, ne se trompe pas, et l'apport d'un engagement humain supplémentaire est marginal sur le livrable. Le couplage technologie plus organisation n'a pas produit de gain parce que la technologie seule suffisait déjà à produire un livrable de qualité.

L'hypothèse de complémentarité demeure donc plausible, mais conditionnelle au type de tâche. Sur une tâche située à l'extérieur de la frontière, où l'IA produit des recommandations erronées que l'utilisateur non encadré tend à adopter, dégradant sa performance par rapport au contrôle (le résultat le plus documenté de Dell'Acqua et al., 2023), le mécanisme d'encadrement aurait toutes les raisons de produire l'effet attendu, en forçant la vérification et le jugement là où l'IA libre échoue. Le mémoire ne peut pas le vérifier : concevoir une tâche sur laquelle l'IA se trompe de façon fiable s'est avéré hors d'atteinte, les modèles actuels comme GPT-4o étant désormais assez performants pour traiter correctement ce type de tâche, même lorsqu'elle mêle des informations contradictoires (cf. section 5.2). La contribution du travail est dès lors de délimiter le domaine de validité de l'hypothèse de complémentarité : l'encadrement organisationnel de l'IA n'améliore pas la qualité lorsque l'IA est déjà compétente sur la tâche ; sa valeur attendue se concentre sur les tâches où l'IA est faillible, et sur les dimensions de processus et de diversité collective plutôt que sur le livrable individuel.

5.1.7 L'encadrement comme capacité organisationnelle, non comme simple consigne

Un dernier enseignement, transversal, mérite d'être dégagé. L'effet estimé de la condition encadrée doit être lu pour ce qu'il est : l'effet d'un dispositif tel qu'il a été effectivement approprié par les participants, et non d'une supervision humaine pleinement exercée. Il faut à cet égard distinguer deux quantités que l'expérience ne mesure pas de la même manière. La première est l'effet de l'assignation : que produit-on en imposant cette architecture à des participants réels, avec leur degré réel d'effort et d'engagement ? C'est ce que capture l'analyse principale en intention de traiter. La seconde est l'effet de l'usage effectif : que produit le dispositif chez ceux qui lisent, acceptent et exploitent réellement la critique de l'IA ? C'est ce qu'approche l'analyse restreinte aux participants ayant effectivement révisé leur texte.

La distinction est ici décisive, parce que l'appropriation a été partielle. Imposer le dispositif a transformé le comportement, l'engagement se substituant à la délégation (H3), mais sans être universellement investi : 57,6 % des participants encadrés ont soumis leur version initiale inchangée après la critique. L'effet d'assignation que mesure l'analyse principale est donc, pour une large part, celui d'un dispositif imposé mais non utilisé ; et, sur cette tâche, même le sous-groupe qui se l'est approprié n'a pas dépassé le niveau de l'IA libre. L'encadrement ne produit donc pas mécaniquement de la réflexion : il ne devient effectif que s'il est adopté, compris et investi par celui qui s'en sert. La supervision humaine n'est pas une propriété du dispositif, mais une capacité de l'utilisateur.

Ce constat déplace la question de recherche : non plus seulement savoir si l'encadrement « fonctionne » ou « échoue », mais si la supervision humaine relève d'une capacité organisationnelle, qui se construit, s'apprend et s'entretient, ou d'une simple consigne qu'il suffirait d'édicter pour qu'elle produise ses effets. Les données plaident pour la première lecture, et rejoignent le cœur de la théorie des complémentarités (Milgrom & Roberts, 1995 ; Bughin & van Zeebroeck, 2021) : un complément ne produit de valeur qu'intégré et réellement mobilisé, non par sa seule présence formelle dans le système. De même que l'investissement digital ne rend que couplé à un renouvellement stratégique effectivement conduit, le dispositif d'encadrement ne rend que couplé à un engagement effectivement consenti par l'utilisateur. Cette lecture est prolongée, au chapitre suivant, dans ses implications managériales et réglementaires.

5.2 Limites méthodologiques

Les résultats précédents doivent être interprétés à la lumière de plusieurs limites, organisées selon les trois formes classiques de validité, complétées par la limite la plus déterminante de ce travail.

5.2.1 Validité interne

La principale menace pour la validité interne tient à la conformité superficielle en condition C3 : 57,6 % des participants n'ayant pas révisé leur texte, le traitement effectivement reçu s'écarte du traitement prévu. Cette dilution a été traitée par une double analyse, en intention de traiter et en restreignant aux réviseurs effectifs, qui conduisent à la même conclusion ; l'effet estimé est donc celui d'une offre d'encadrement, non d'un encadrement pleinement utilisé. Une seconde menace tient à la contamination possible du contrôle : le format en ligne ne permet pas de bloquer techniquement l'accès à une IA externe, et une fraction des participants C1 a pu enfreindre la consigne, comme le rapportent Noy & Zhang (2023) pour 10 à 20 % de leur groupe contrôle, risque que les critères opérationnels d'exclusion atténuent sans l'éliminer. Le dispositif séquentiel introduit par ailleurs un risque d'effet d'ordre, et l'avantage formel de C2 tient pour partie à la longueur des productions, ce qui rappelle que la grille d'évaluation comporte ses propres biais de mesure. À cet égard, l'évaluation repose sur deux juges non experts et la mesure du temps de travail reste une approximation en contexte non supervisé ; ces limites sont atténuées par la triangulation des conclusions avec des indicateurs objectifs indépendants du jugement des évaluateurs (F1-Score de fiabilité factuelle, traces d'usage de l'IA, similarité inter-productions, calibration confiance-performance), qui convergent avec les notes attribuées. Enfin, l'architecture de C3 combinant plusieurs mécanismes et sa structuration temporelle propre, aucun effet de la condition ne peut être attribué à une composante isolée plutôt qu'au système, choix délibéré au regard de la théorie des complémentarités.

5.2.2 Validité externe

L'échantillon, recruté par convenance dans le réseau personnel de l'auteur, n'est pas représentatif de la population des travailleurs du savoir : jeune, hautement éduqué et surtout exceptionnellement fami-

lier de l'IA générative (84 % en font un usage au moins hebdomadaire), c'est un échantillon d'utilisateurs avancés plutôt qu'une main-d'œuvre générale, ce qui peut accentuer le mode substitutif observé en condition libre ; l'absence de rémunération a en outre pu sélectionner des participants intrinsèquement motivés. L'effectif atteint, suffisant pour détecter les effets de grande taille effectivement observés, reste sous-puissant pour les effets moyens, de sorte qu'un résultat non significatif, comme celui de la fiabilité factuelle, ne peut être interprété comme une absence d'effet ; symétriquement, les effets significatifs détectés, tous de grande magnitude, sont vraisemblablement surestimés (malédiction du vainqueur, *winner's curse* ; Button et al., 2013). Enfin, les résultats sont conditionnels au modèle GPT-4o, dont un profil d'erreurs différent pourrait modifier l'interaction avec les mécanismes d'encadrement.

5.2.3 Validité écologique

Les tâches, bien que conçues pour être réalistes, demeurent des exercices courts réalisés en session unique et en ligne, sans les enjeux, les ressources contextuelles ni la durée d'une situation de travail réelle. Cui et al. (2025) soulignent l'écart systématique entre les gains mesurés en laboratoire et ceux observés sur le terrain. Le caractère expérimental de la situation a pu, par effet Hawthorne, accroître l'effort et la vigilance dans toutes les conditions, sans toutefois biaiser les comparaisons inter-conditions.

5.2.4 La limite décisive : une tâche située à l'intérieur de la frontière technologique

La limite la plus importante, déjà annoncée, conditionne l'interprétation de l'ensemble. Le résultat central, l'inversion de H2, est solidaire d'une tâche que GPT-4o exécute avec compétence ; il ne peut être généralisé aux tâches situées à l'extérieur de la frontière technologique, sur lesquelles l'IA se trompe et où la valeur d'un mécanisme forçant la vérification et le jugement serait, en principe, maximale. Construire une telle tâche n'a toutefois pas été possible dans le cadre de ce mémoire, les capacités d'intégration d'informations contradictoires des modèles récents ayant nettement progressé depuis les expériences fondatrices de Dell'Acqua et al. (2023). Cette limite délimite précisément le domaine au sein duquel les conclusions valent, et elle ouvre la principale piste de recherche future, développée au chapitre suivant. Enfin, le dispositif transversal, limité à une session unique, ne permet pas de mesurer les effets d'apprentissage à moyen terme : le désengagement de 57,6 % des participants de C3 est un indicateur de processus, non un résultat d'apprentissage retenu, et la question de savoir si l'encadrement préserve les compétences à long terme, à laquelle Bastani et al. (2025) répondent positivement pour leur tuteur contraint, reste ouverte pour le dispositif testé ici.

Chapitre 6

Conclusion

Ce mémoire est parti d'une hypothèse simple, transposée de la théorie des complémentarités de Milgrom & Roberts (1995) au niveau du comportement individuel : l'IA générative ne produirait des gains durables que couplée à des mécanismes organisationnels d'encadrement, de la même manière que l'investissement digital ne produit de rendement que couplé au renouvellement stratégique (Bughin & van Zeebroeck, 2021). L'essai contrôlé randomisé a confirmé que l'encadrement transforme profondément le comportement, mais a infirmé qu'il améliore le livrable : sur une tâche que l'IA traite avec compétence, c'est l'accès libre qui obtient la qualité évaluée la plus élevée, et l'encadrement qui la ramène au niveau du travail sans assistance ; cet avantage porte toutefois sur les dimensions visibles du livrable, non sur la fiabilité factuelle ni sur le jugement (section 6.1). Plutôt que de résumer ces résultats, déjà synthétisés au terme du chapitre 4, ce chapitre final en dégage les conséquences pratiques : des recommandations pour les organisations qui déploient l'IA (section 6.1), des enseignements pour la gouvernance européenne de l'IA (section 6.2), puis les pistes de recherche que ce travail ouvre (section 6.3).

6.1 Implications managériales

La configuration des résultats invite à dépasser la question binaire « faut-il encadrer l'usage de l'IA ? » au profit d'une question conditionnelle : « pour quelles tâches et quels objectifs l'encadrement crée-t-il de la valeur, et pour lesquels en détruit-il ? ». Quatre recommandations en découlent.

Calibrer l'encadrement sur la faillibilité de l'IA pour la tâche, non sur un principe général. L'encadrement n'améliore pas la qualité du livrable lorsque l'IA est déjà compétente sur la tâche : sur l'évaluation stratégique étudiée, la précision factuelle est élevée et homogène (de 0,94 à 1,00) et aucune invention factuelle n'a été détectée, de sorte que forcer l'humain à produire puis réviser ajoute de l'effort et du temps (environ treize minutes de plus qu'en accès libre) sans contrepartie sur le résultat noté. La littérature sur les garde-fous suppose au contraire un usage non encadré coûteux, soit parce que l'IA commet des erreurs que l'utilisateur doit détecter (Buçinca et al., 2021), soit parce que la délégation se substitue à l'engagement cognitif dont dépendent la performance et l'apprentissage (Bastani et al., 2025 ; Ghosh et al., 2026). L'implication managériale est directe : les dispositifs coûteux en temps et en effort doivent être réservés aux tâches où l'IA est faillible, situées à l'extérieur de sa frontière technologique (Dell'Acqua et al., 2023), aux décisions à enjeux élevés et aux situations exigeant une vérification factuelle critique. Sur les tâches que l'IA maîtrise, l'accès libre maximise la vitesse et obtient la qualité évaluée la plus élevée sur les dimensions visibles du livrable, et l'encadrement représente un coût net.

Ne pas confondre qualité du livrable et valeur du travail. L'avantage de l'accès libre s'est révélé largement formel : il se concentre sur la qualité rédactionnelle et analytique, s'efface sur la fiabilité factuelle et le jugement critique, et tient pour une part substantielle à la longueur des productions (il disparaît sur le contrôle une fois la longueur ajustée). Toute grille d'évaluation analytique récompense la complétude et le polissage, précisément les dimensions où l'IA excelle. Les organisations qui évaluent le travail sur la base de livrables soignés risquent donc de surévaluer le travail délégué à l'IA et de récompenser la verbosité au détriment de la profondeur du raisonnement. La recommandation est de

distinguer explicitement, dans l'évaluation, la forme (que l'IA produit aisément) du jugement et de la pertinence contextuelle (qu'elle ne garantit pas), sans inférer la qualité du raisonnement de celle de la rédaction.

Surveiller les coûts collectifs que le livrable individuel masque. L'accès libre optimise la production isolée mais entraîne deux coûts invisibles à cette échelle. Le premier est l'homogénéisation : la similarité moyenne entre productions d'une même condition passe de 0,45 sans IA à 0,67 avec l'IA libre, tandis que l'encadrement la maintient au niveau du sans-IA (réplication de Doshi & Hauser, 2024) ; une organisation qui dépend de la diversité de ses analyses pour innover la voit s'appauvrir sans que les indicateurs individuels le signalent. Le second est le découplage entre confiance et performance : la confiance des utilisateurs assistés cesse de suivre leur performance, et ce sont les moins performants qui se déclarent les plus confiants. Ces deux coûts ne deviennent visibles qu'au niveau de l'équipe et du processus. La recommandation est de compléter les indicateurs individuels par un suivi de la diversité des productions au niveau collectif et par des retours reliant la confiance déclarée à la performance effective, afin de réancrer la calibration des collaborateurs.

Anticiper l'inéquité d'un encadrement reposant sur l'engagement volontaire. Le dispositif testé n'a été pleinement mobilisé que par une minorité : plus de la moitié des participants encadrés ont soumis leur production initiale sans la réviser, et ce sont les participants à la meilleure performance de base et à la plus forte expérience de l'IA qui ont effectivement révisé, les moins compétents s'en tenant à leur première version. Un garde-fou laissé à l'initiative de l'utilisateur est donc mobilisé par ceux qui en ont le moins besoin et délaissé par ceux qui en bénéficieraient le plus, ce qui inverse la promesse d'égalisation (Noy & Zhang, 2023 ; Brynjolfsson et al., 2023) et rejoint l'avertissement de Kreitmeir & Raschky (2024) sur la dépendance des novices. Un mécanisme d'encadrement efficace ne peut donc reposer sur la seule bonne volonté : il doit être structurellement contraignant, intégré au flux de travail pour rendre l'engagement incontournable, comme le montrent Jackson & Schneider (2015) pour les checklists dont l'effet disparaît dès que le suivi est retiré.

Ces quatre recommandations se synthétisent en un principe directeur : l'encadrement organisationnel de l'IA n'est pas un bien en soi, mais un investissement dont le rendement dépend de la tâche et de l'objectif poursuivi. Pour la vitesse et pour la qualité visible du livrable sur des tâches que l'IA maîtrise, l'accès libre est préférable. Pour la préservation du jugement, de la diversité des analyses, de la calibration des collaborateurs et de leurs compétences à long terme, ainsi que pour les tâches où l'IA est faillible, l'encadrement conserve une valeur que les seuls indicateurs de qualité du livrable ne capturent pas.

6.2 Implications pour la gouvernance de l'IA

Le cadre européen de régulation de l'IA (Règlement (UE) 2024/1689) consacre, à son article 14, une obligation de surveillance humaine : les systèmes à haut risque doivent pouvoir être effectivement supervisés par des personnes physiques, afin de prévenir ou de réduire les risques pour la santé, la sécurité et les droits fondamentaux. Les résultats de ce mémoire éclairent une difficulté centrale de cette exigence. Le dispositif testé est précisément une forme de supervision humaine structurée : produire d'abord par soi-même, puis soumettre son travail à une critique avant de le finaliser. Or, s'il a effectivement transformé le comportement, il n'a garanti ni la qualité du résultat ni, surtout, l'usage effectif de la supervision, plus de la moitié des utilisateurs encadrés ayant soumis leur production inchangée après la critique. Imposer la présence d'un humain dans la boucle ne garantit donc pas son engagement.

Cette dissociation entre la présence formelle d'une supervision et son exercice effectif est directement

pertinente pour la mise en œuvre du Règlement. Une obligation conçue comme une exigence formelle, vérifiable par la seule existence d'une étape de validation, risque de produire une conformité de façade : un humain qui valide sans examiner satisfait la lettre de l'obligation sans en remplir l'intention. La complaisance face à l'automatisation, documentée de longue date (Parasuraman & Manzey, 2010) et confirmée pour l'IA générative (Lee et al., 2025, pour qui la confiance en l'IA est le plus fort prédicteur de la non-mobilisation de la pensée critique), rend ce risque d'autant plus probable que l'IA est performante et inspire confiance. La gouvernance gagnerait donc à cibler l'usage effectif de la supervision, par exemple en exigeant des traces d'un examen substantiel plutôt qu'une simple validation. Autrement dit, la supervision humaine doit être traitée comme une capacité organisationnelle, qui se construit, se forme et se soutient, et non comme une simple consigne dont l'édiction suffirait à garantir le résultat (cf. chapitre 5, section 5.1.7).

Un second enseignement concerne le périmètre pertinent de la supervision. Nos résultats montrent qu'elle n'apporte pas de valeur mesurable sur le livrable lorsque l'IA est compétente sur la tâche, sa valeur attendue se concentrant sur les tâches où l'IA est faillible, celles qui correspondent le plus souvent aux usages à haut risque que le Règlement entend précisément encadrer. Loin de contredire sa logique, ce constat en fournit une justification empirique. L'article 14 dispose lui-même que les mesures de surveillance doivent être proportionnées aux risques, au niveau d'autonomie et au contexte d'utilisation : l'intensité de la supervision devrait donc être calibrée sur la faillibilité de l'IA pour la tâche, exigeante là où l'IA se trompe et risque d'induire l'utilisateur en erreur, allégée là où elle est fiable. Cette logique de calibration prolonge la thèse des complémentarités validée par Bughin & van Zeebroeck (2021) : un mécanisme organisationnel ne produit de valeur que couplé à un usage effectif, non imposé comme une formalité. La supervision humaine est ainsi un complément de la technologie au sens de Milgrom & Roberts (1995), dont l'efficacité dépend de sa cohérence avec la tâche et de son appropriation, non de sa simple présence.

6.3 Pistes de recherche futures

Les limites de ce travail, exposées au chapitre 5, dessinent en creux un programme de recherche dont cinq directions paraissent prioritaires.

Tester l'hypothèse de complémentarité sur une tâche où l'IA est faillible. C'est la piste la plus importante, car elle conditionne l'interprétation de l'ensemble des résultats. L'inversion de l'hypothèse de qualité est solidaire d'une tâche que l'IA traite avec compétence ; sur une tâche située hors de la frontière technologique, où l'IA produit des recommandations erronées que l'utilisateur non encadré tend à adopter, dégradant sa performance par rapport à un groupe sans assistance (Dell'Acqua et al., 2023), le mécanisme d'encadrement aurait toutes les raisons de produire le gain attendu, en forçant la vérification là où l'IA libre échoue. La difficulté, qui a empêché de construire une telle tâche ici, tient au progrès des modèles, dont la capacité d'intégration d'informations contradictoires a nettement augmenté depuis 2023 : une recherche future devra calibrer rigoureusement la tâche sur le modèle utilisé et recourir vraisemblablement à des professionnels experts capables de surpasser l'IA sur des jugements contextuels. C'est là que la théorie des complémentarités, non réfutée mais bornée par ce mémoire, pourrait recevoir sa confirmation.

Mesurer les effets d'apprentissage à moyen terme. Le dispositif transversal mesure le livrable et non l'apprentissage retenu, le désengagement d'une majorité des utilisateurs encadrés n'étant qu'un indicateur de processus. Un protocole longitudinal comportant un test différé sans assistance, à la manière de Bastani et al. (2025), déterminerait si l'encadrement préserve les compétences à long terme ou si ses effets disparaissent au retrait des garde-fous, comme le suggèrent Jackson & Schneider (2015) pour les

checklists.

Isoler les mécanismes de l'encadrement par un plan factoriel. La condition encadrée combine plusieurs interventions (production initiale, critique en mode *sounding board*, cycle de révision), de sorte qu'aucun effet ne peut être attribué à une composante particulière. Un plan factoriel croisant la présence ou l'absence de chaque mécanisme identifierait lequel porte l'effet comportemental observé et lequel pourrait être allégé sans perte, au prix d'un échantillon considérablement plus large.

Étendre la validité externe : population, rémunération et modèle d'IA. L'échantillon de jeunes adultes francophones, familiers de l'IA et non rémunérés, limite la généralisation. Une réplication sur un échantillon professionnel rémunéré, plus représentatif de la main-d'œuvre, et avec d'autres modèles que GPT-4o, dont le profil d'erreurs diffère, vérifierait la robustesse des mécanismes et préciserait la dépendance des conclusions au modèle employé.

Ériger la diversité collective en variable dépendante à part entière. L'homogénéisation des productions est apparue comme le coût le plus tangible de l'IA libre et le bénéfice le plus net de l'encadrement, mais n'a été mesurée ici qu'à titre exploratoire. Les recherches futures gagneraient à traiter la diversité des productions au niveau collectif comme une variable dépendante centrale, et non comme un sous-produit de la qualité individuelle. C'est à cette échelle, celle de l'organisation et de sa capacité d'innovation, que se jouent les effets de l'IA que les indicateurs de productivité individuelle ne captent pas, et que reste ouvert le débat macroéconomique sur la traduction des gains micro en gains agrégés (Acemoglu, 2024 ; Brynjolfsson, Rock & Syverson, 2021).

En définitive, ce mémoire conclut que le couplage de l'IA et de mécanismes organisationnels d'encadrement ne garantit pas, à lui seul, un meilleur livrable. Il déplace le comportement de l'utilisateur de la délégation vers l'engagement, préserve la diversité des productions et contient le découplage entre confiance et performance que produit l'usage libre, mais ces bénéfices ne se traduisent en gain sur le livrable que là où l'IA est faillible. La valeur de l'encadrement ne réside donc pas dans la qualité immédiate du travail produit, mais dans la préservation de ce que l'usage non encadré de l'IA érode silencieusement : le jugement, la diversité et la lucidité de celui qui s'en sert.

Déclaration sur l'utilisation de l'IA générative

Je soussigné, Sallah Dassy, déclare par la présente avoir utilisé des technologies d'IA générative dans le processus de rédaction de ce mémoire.

Je certifie que :

- l'utilisation de ces technologies a été effectuée conformément aux directives académiques et éthiques en vigueur ;
- après avoir utilisé ces outils, j'ai révisé et édité le contenu généré ;
- j'assume l'entière responsabilité de cette publication.

Les détails des outils d'IA utilisés, leur utilisation spécifique et les sections du mémoire concernées sont présentés dans le tableau ci-dessous.

Outil d'IA utilisé (nom, version, date de consultation)	Utilisation de l'outil	Sections du mémoire concernées
Claude (Anthropic), Claude Opus 4.5 à 4.8, consulté en 2026	Aide à la recherche et à la synthèse de la littérature ; assistance à la structuration ; aide au codage et à la vérification des analyses statistiques (R) ; relecture et mise en forme. L'ensemble des contenus générés a été vérifié, révisé et validé par l'auteur.	Ensemble du mémoire (introduction, revue de littérature, méthodologie, résultats, discussion, conclusion)
Codex (OpenAI), GPT-5.4 et GPT-5.5, consulté en 2026	Revue du code de la plateforme expérimentale (assistance technique au développement de l'outil de collecte de données).	Méthodologie : plateforme expérimentale (chapitre 3 ; code en annexe le cas échéant)

Citation en bibliographie. Selon les consignes données, une citation en bibliographie n'est requise que si la sortie d'un outil d'IA est traitée comme une source dans le mémoire (analysée, citée, utilisée comme information ou interprétation). Ces outils ayant servi d'aide au travail et non de source citée, seule la présente déclaration est requise.

Note. Le modèle GPT-4o (OpenAI) ne figure pas dans ce tableau car il n'a pas servi d'outil d'aide à la rédaction : il constitue l'objet même de l'étude, c'est-à-dire l'outil d'IA mis à la disposition des participants au cours de l'expérience. Son rôle, ses paramètres et son utilisation sont décrits dans le chapitre 3 (méthodologie).

Bibliographie

- Acemoglu, D. (2024). *The simple macroeconomics of AI* (NBER Working Paper No. 32487). National Bureau of Economic Research.
- Association of American Colleges and Universities. (2009). *Critical thinking VALUE rubric*. AAC&U. <https://www.aacu.org/value/rubrics/critical-thinking>
- Association of American Colleges and Universities. (2009). *Written communication VALUE rubric*. AAC&U. <https://www.aacu.org/value/rubrics/written-communication>
- Autor, D. H., Levy, F., & Murnane, R. J. (2003). The skill content of recent technological change : An empirical exploration. *The Quarterly Journal of Economics*, 118(4), 1279-1333.
- Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, O., & Mariman, R. (2025). Generative AI without guardrails can harm learning : Evidence from high school mathematics. *Proceedings of the National Academy of Sciences (PNAS)*, 122(26), e2422633122. <https://doi.org/10.1073/pnas.2422633122>
- Becker, J., Rush, N., Barnes, E., & Rein, D. (2025). *Measuring the impact of early-2025 AI on experienced open-source developer productivity* (arXiv :2507.09089). METR.
- Brynjolfsson, E., Li, D., & Raymond, L. R. (2023). *Generative AI at work* (NBER Working Paper No. 31161). National Bureau of Economic Research.
- Brynjolfsson, E., Rock, D., & Syverson, C. (2019). Artificial intelligence and the modern productivity paradox : A clash of expectations and statistics. In A. Agrawal, J. Gans, & A. Goldfarb (Eds.), *The economics of artificial intelligence : An agenda* (pp. 23-60). University of Chicago Press.
- Brynjolfsson, E., Rock, D., & Syverson, C. (2021). The productivity J-curve : How intangibles complement general purpose technologies. *American Economic Journal : Macroeconomics*, 13(1), 333-372.
- Buçinca, Z., Malaya, M. B., & Gajos, K. Z. (2021). To trust or to think : Cognitive forcing functions can reduce overreliance on AI in AI-assisted decision-making. *Proceedings of the ACM on Human-Computer Interaction*, 5(CSCW1), Article 188. <https://doi.org/10.1145/3449287>
- Bughin, J., & van Zeebroeck, N. (2021). *The entrepreneurial returns to incumbents' digital transformation* (iCite Working Paper No. 2021-048). Université libre de Bruxelles, iCite.
- Button, K. S., Ioannidis, J. P. A., Mokrysz, C., Nosek, B. A., Flint, J., Robinson, E. S. J., & Munafò, M. R. (2013). Power failure : Why small sample size undermines the reliability of neuroscience. *Nature Reviews Neuroscience*, 14(5), 365-376. <https://doi.org/10.1038/nrn3475>
- Charness, G., Gneezy, U., & Kuhn, M. A. (2012). Experimental methods : Between-subject and within-subject design. *Journal of Economic Behavior & Organization*, 81(1), 1-8.
- Chen, Z., & Chan, J. (2024). Large language model in creative work : The role of collaboration modality and user expertise. *Management Science*, 70(12), 9101-9117. <https://doi.org/10.1287/mnsc.2023.03014>
- Cicchetti, D. V. (1994). Guidelines, criteria, and rules of thumb for evaluating normed and standardized assessment instruments in psychology. *Psychological Assessment*, 6(4), 284-290. <https://doi.org/10.1037/1040-3590.6.4.284>
- Cohen, J. (1992). A power primer. *Psychological Bulletin*, 112(1), 155-159.
- Cui, K. Z., Demirer, M., Jaffe, S., Musolff, L., Peng, S., & Salz, T. (2025). The effects of generative AI

- on high-skilled work : Evidence from three field experiments with software developers. *Management Science*. <https://doi.org/10.1287/mnsc.2025.00535>
- David, P. A. (1990). The dynamo and the computer : An historical perspective on the modern productivity paradox. *The American Economic Review*, 80(2), 355-361.
- Dell'Acqua, F., McFowland, E., III, Mollick, E. R., Lifshitz-Assaf, H., Kellogg, K., Rajendran, S., Kraye, L., Candelon, F., & Lakhani, K. R. (2023). *Navigating the jagged technological frontier : Field experimental evidence of the effects of AI on knowledge worker productivity and quality* (Harvard Business School Working Paper No. 24-013).
- Dhokal, V., Feit, A. M., Kristensson, P. O., & Oulasvirta, A. (2018). Observations on typing from 136 million keystrokes. In *Proceedings of the 2018 CHI Conference on Human Factors in Computing Systems* (pp. 1-12). <https://doi.org/10.1145/3173574.3174220>
- Doshi, A. R., & Hauser, O. P. (2024). Generative AI enhances individual creativity but reduces the collective diversity of novel content. *Science Advances*, 10(28), eadn5290.
- Ehrlinger, J., & Dunning, D. (2003). How chronic self-views influence (and potentially mislead) estimates of performance. *Journal of Personality and Social Psychology*, 84(1), 5-17.
- Eloundou, T., Manning, S., Mishkin, P., & Rock, D. (2024). GPTs are GPTs : Labor market impact potential of LLMs. *Science*, 384(6702), 1306-1308.
- Felten, E., Raj, M., & Seamans, R. (2023). *Occupational heterogeneity in exposure to generative AI*. SSRN. <https://doi.org/10.2139/ssrn.4414065>
- Fernandes, D., Villa, S., Nicholls, S., Haavisto, O., Buschek, D., Schmidt, A., Kosch, T., Shen, C., & Welsch, R. (2026). AI makes you smarter but none the wiser : The disconnect between performance and metacognition. *Computers in Human Behavior*, 175, Article 108779. <https://doi.org/10.1016/j.chb.2025.108779>
- Ghosh, A., Sarkar, A., Lindley, S., & Poelitz, C. (2026). *An experimental comparison of cognitive forcing functions for execution plans in AI-assisted writing : Effects on trust, overreliance, and perceived critical thinking* (arXiv :2601.18033).
- Hallgren, K. A. (2012). Computing inter-rater reliability for observational data : An overview and tutorial. *Tutorials in Quantitative Methods for Psychology*, 8(1), 23-34.
- Halpern, D. F. (1998). Teaching critical thinking for transfer across domains. *American Psychologist*, 53(4), 449-455.
- Halpern, D. F. (2013). *Thought and knowledge : An introduction to critical thinking* (5th ed.). Psychology Press.
- Hart, S. G., & Staveland, L. E. (1988). Development of NASA-TLX (Task Load Index) : Results of empirical and theoretical research. In P. A. Hancock & N. Meshkati (Eds.), *Human mental workload* (pp. 139-183). North-Holland.
- Haynes, A. B., Weiser, T. G., Berry, W. R., Lipsitz, S. R., Breizat, A.-H. S., Dellinger, E. P., Herbosa, T., ...Gawande, A. A. (2009). A surgical safety checklist to reduce morbidity and mortality in a global population. *New England Journal of Medicine*, 360(5), 491-499. <https://doi.org/10.1056/NEJMsa0810119>
- Hoaglin, D. C., Iglewicz, B., & Tukey, J. W. (1986). Performance of some resistant rules for outlier labeling. *Journal of the American Statistical Association*, 81(396), 991-999. <https://doi.org/10.1080/01621459.1986.1047>
- Hou, C., Zhu, G., Sudarshan, V., Lim, F. S., & Ong, Y. S. (2025). Measuring undergraduate students' reliance on generative AI during problem-solving : Scale development and validation. *Computers &*

Education, 234, Article 105329. <https://doi.org/10.1016/j.compedu.2025.105329>

- Hróbjartsson, A., Thomsen, A. S. S., Emanuelsson, F., Tendal, B., Hilden, J., Boutron, I., Ravaut, P., & Brorson, S. (2013). Observer bias in randomized clinical trials with measurement scale outcomes : A systematic review of trials with both blinded and nonblinded assessors. *CMAJ*, 185(4), E201-E211. <https://doi.org/10.1503/cmaj.120744>
- International Council for Harmonisation. (1998). *ICH harmonised tripartite guideline E9 : Statistical principles for clinical trials*.
- Jackson, C. K., & Schneider, H. S. (2015). Checklists and worker behavior : A field experiment. *American Economic Journal : Applied Economics*, 7(4), 136-168.
- Jansen, R. A., Rafferty, A. N., & Griffiths, T. L. (2021). A rational model of the Dunning-Kruger effect supports insensitivity to evidence in low performers. *Nature Human Behaviour*, 5(6), 756-763.
- Jonsson, A., & Svingby, G. (2007). The use of scoring rubrics : Reliability, validity and educational consequences. *Educational Research Review*, 2(2), 130-144. <https://doi.org/10.1016/j.edurev.2007.05.002>
- Kahan, B. C., & Morris, T. P. (2012). Improper analysis of trials randomised using stratified blocks or minimisation. *Statistics in Medicine*, 31(4), 328-340. <https://doi.org/10.1002/sim.4431>
- Kahneman, D. (2011). *Thinking, fast and slow*. Farrar, Straus and Giroux.
- Kernan, W. N., Viscoli, C. M., Makuch, R. W., Brass, L. M., & Horwitz, R. I. (1999). Stratified randomization for clinical trials. *Journal of Clinical Epidemiology*, 52(1), 19-26.
- Kreitmeir, D., & Raschky, P. A. (2024). *The heterogeneous productivity effects of generative AI* (arXiv :2403.01964).
- Lakens, D. (2013). Calculating and reporting effect sizes to facilitate cumulative science : A practical primer for t-tests and ANOVAs. *Frontiers in Psychology*, 4, Article 863. <https://doi.org/10.3389/fpsyg.2013.00863>
- Lee, H.-P., Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R., & Wilson, N. (2025). The impact of generative AI on critical thinking : Self-reported reductions in cognitive effort and confidence effects from a survey of knowledge workers. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*.
- Lu, T., & Zhang, Y. (2024). 1 + 1 > 2 ? Information, humans, and machines. *Information Systems Research*. <https://doi.org/10.1287/isre.2023.0305>
- Milgrom, P., & Roberts, J. (1995). Complementarities and fit : Strategy, structure, and organizational change in manufacturing. *Journal of Accounting and Economics*, 19(2-3), 179-208.
- Noy, S., & Zhang, W. (2023). Experimental evidence on the productivity effects of generative artificial intelligence. *Science*, 381(6654), 187-192.
- OpenAI. (2026, février). *Scaling AI for everyone*. <https://openai.com/fr-FR/index/scaling-ai-for-everyone/>
- Parasuraman, R., & Manzey, D. H. (2010). Complacency and bias in human use of automation : An attentional integration. *Human Factors*, 52(3), 381-410. <https://doi.org/10.1177/0018720810376055>
- Peng, S., Kalliamvakou, E., Cihon, P., & Demirer, M. (2023). *The impact of AI on developer productivity : Evidence from GitHub Copilot* (arXiv :2302.06590).
- Pocock, S. J., & Simon, R. (1975). Sequential treatment assignment with balancing for prognostic factors in the controlled clinical trial. *Biometrics*, 31(1), 103-115.
- Règlement (UE) 2024/1689 du Parlement européen et du Conseil du 13 juin 2024 établissant des règles harmonisées concernant l'intelligence artificielle (règlement sur l'intelligence artificielle). (2024).

- Journal officiel de l'Union européenne*, L, 2024/1689. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>
- Rijsbergen, C. J. van. (1979). *Information retrieval* (2e éd.). Butterworths.
- Schemmer, M., Kühl, N., Benz, C., Bartos, A., & Satzger, G. (2023). Appropriate reliance on AI advice : Conceptualization and the effect of explanations. In *Proceedings of the 28th International Conference on Intelligent User Interfaces (IUI '23)* (pp. 410-422).
- Schulz, K. F., & Grimes, D. A. (2002). Blinding in randomised trials : Hiding who got what. *The Lancet*, 359(9307), 696-700. [https://doi.org/10.1016/S0140-6736\(02\)07816-9](https://doi.org/10.1016/S0140-6736(02)07816-9)
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427-437. <https://doi.org/10.1016/j.ipm.2009.03.002>
- Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.
- Van Breukelen, G. J. P. (2006). ANCOVA versus change from baseline had more power in randomized studies and more bias in nonrandomized studies. *Journal of Clinical Epidemiology*, 59(9), 920-925.
- Vasconcelos, H., Jörke, M., Grunde-McLaughlin, M., Gerstenberg, T., Bernstein, M. S., & Krishna, R. (2023). Explanations can reduce overreliance on AI systems during decision-making. *Proceedings of the ACM on Human-Computer Interaction*, 7(CSCW1), Article 129.

Annexe A

Tableaux de synthèse de la revue de littérature

A.1 Essais contrôlés randomisés sur la productivité avec IA générative

Le tableau ci-dessous synthétise les principaux essais contrôlés randomisés sur la productivité avec IA générative discutés au chapitre 2, classés par taille d'échantillon décroissante ; les tailles d'effet sont rapportées dans l'unité originale de chaque étude.

Auteurs (année)	N	Population	Tâche	Outil IA	Effet principal	Effet d'égalisation
Cui et al. (2025)	4 867	Développeurs (3 entreprises)	Programmation	GitHub Copilot	+26 % de <i>pull requests</i> complétées	Plus fort chez les développeurs de faible ancienneté (27-39 % vs 8-13 %)
Brynjolfsson et al. (2023)	5 172	Agents support client	Résolution de cas	GPT fine-tuné	+15 % de productivité, -25 % d'escalades	Très marqué : +36 % au quintile inférieur, ≈ 0 au supérieur
Noy & Zhang (2023)	444	Professionnels qualifiés	Rédaction professionnelle	ChatGPT	-37 % de temps, +0,45 σ de qualité	Marqué : pente de régression réduite de 0,49 à 0,25
Dell'Acqua et al. (2023)	758	Consultants stratégie BCG	Conception produit / analyse	GPT-4	+42,5 % qualité (<i>inside frontier</i>), -24 pp (<i>outside frontier</i>)	Marqué : +43 % chez le demi inférieur, +17 % chez le demi supérieur
Bastani et al. (2025)	$\approx 1\,000$	Lycéens turcs	Mathématiques	GPT-4 (Base et Tutor)	GPT Base : +48 % aidé, -17 % examen ; GPT Tutor : +127 % aidé, $\approx$ contrôle examen	Non testé directement
Doshi & Hauser (2024)	293 + 600	Rédacteurs / évaluateurs	Écriture créative	GPT-4	Créativité individuelle accrue ; homogénéisation des productions	Très marqué : les moins créatifs égalent les plus créatifs
Becker et al. (2025)	16	Développeurs experts open-source	Programmation sur leurs propres dépôts	IA générative	+19 % de temps (l'IA ralentit les experts) ; perception : -20 % de temps	Inversé : les experts perdent
Chen & Chan (2024)	355	Annonceurs	Publicités évaluées par clics réels	GPT-4	<i>Sounding board</i> > <i>Ghostwriter</i> ; égalisation experts/non-experts en <i>sounding board</i>	<i>Sounding board</i> comble l'écart
Ghosh et al. (2026)	214	Rédacteurs en ligne	Tâches de rédaction structurée	GPT-4o	Taux de surconfiance : Assumptions 63 % < contrôle 70,6 % < WhatIf 80,7 %	Non testé directement
Kreitmeir & Raschky (2024)	36 + 358	Développeurs GitHub (Italie)	Programmation exploitation du ban ChatGPT	ChatGPT	Novices : +10 % d'activité productive et qualité supérieure pendant le ban	Inversé : les novices gagnent à ne pas avoir l'IA

A.2 Interventions testées et efficacité empirique

Le tableau ci-dessous récapitule les principales interventions testées dans la littérature (chapitre 2) et leur efficacité empirique pour réduire la surconfiance ou améliorer la complémentarité humain-IA.

Type d'intervention	Étude principale	Mécanisme	Résultat	Efficacité
Fonctions de forçage cognitif (Update, Wait, On-demand)	Buçinca et al. (2021)	Interrompre l'automatisme cognitif avant la suggestion IA	Surconfiance 64 % → 48 % (d = 0,36)	Modérée mais significative
Fonction de forçage Assumptions	Ghosh et al. (2026)	Forcer l'identification des hypothèses implicites	Surconfiance 63 % vs contrôle 70,6 % (vs WhatIf 80,7 %)	Modérée, la plus efficace de l'étude
Modification du <i>system prompt</i> (GPT Tutor)	Bastani et al. (2025)	IA refuse de donner directement la réponse	Annule l'effet béquille de -17 % à l'examen	Forte
Modalité <i>sounding board</i> (humain produit, IA critique)	Chen & Chan (2024)	Inverser l'ordre de la collaboration	Égalise non-experts et experts ; supprime l'ancrage créatif	Forte
Explications structurées + complexité informationnelle	Lu & Zhang (2024)	Activer le <i>rethinking</i> via deux conditions simultanées	Taux de défaut 5,15 % → 3,13 %	Forte (mais conditionnelle)
Explications visuelles (<i>highlight</i>)	Vasconcelos et al. (2023)	Réduire le coût cognitif de la vérification	Surconfiance 0 % lorsque l'erreur est rendue saillante	Forte (sur tâches difficiles)
Checklist organisationnelle (chirurgie)	Haynes et al. (2009)	Conscience collective et redevabilité par les pairs	Mortalité -47 %, complications -36 %	Forte (mais hors travail du savoir)
Instructions explicites de vérifier	Skitka et al. (2000, cités par Parasuraman & Manzey, 2010)	Demander la vérification	Aucun effet sur les taux d'erreur	Nulle
Pratique de 60 minutes	Singh et al. (2001, cités par Parasuraman & Manzey, 2010)	Apprentissage par exposition	Aucune réduction de la complaisance	Nulle
Travail en équipe	Skitka et al. (2000, cités par Parasuraman & Manzey, 2010)	Vérification croisée par pairs	Le biais persiste identiquement	Nulle
Formation au <i>prompt engineering</i>	Dell'Acqua et al. (2023)	Apprendre à mieux utiliser l'IA	-24 pp d'exactitude (effet négatif)	Négative

Annexe B

Dossiers des tâches expérimentales

Les dossiers ci-dessous sont reproduits tels qu'ils apparaissent aux participants sur la plateforme expérimentale.

B.1 Tâche de référence (*baseline*) : déclin de fréquentation d'une médiathèque

Consigne : Rédigez une note de synthèse de 250 à 400 mots à l'attention du directeur de la médiathèque, identifiant les deux à trois causes principales du déclin de fréquentation et formulant une recommandation argumentée pour relancer l'usage.

Dossier fourni :

La médiathèque publique de Namur (85 000 documents, 22 employés, budget annuel 1,2 M€) voit sa fréquentation baisser depuis 3 ans.

Données internes (2022 → 2025) :

- Usagers actifs : 12 800 → 9 400
- Emprunts physiques : 185 000 → 128 000
- Emprunts numériques (e-books, audio, vidéo) : 8 400 → 22 000

Autres données (2025) :

- Âge moyen des usagers actifs : 52 ans. Seulement 18 % ont moins de 30 ans (contre 34 % en 2019).
- Aucun événement culturel (ateliers, rencontres, conférences) n'a été organisé depuis 2021.
- Les 6 salles de travail collaboratif affichent un taux d'occupation de 92 % pendant leurs heures d'ouverture.
- La communication vers les 16-25 ans passe exclusivement par le site institutionnel de la commune.
- Horaires : 10h-18h du mardi au samedi, fermée le lundi et le dimanche.
- Enquête communale (2024, n = 612) auprès des non-usagers 18-35 ans : 47 % citent « les horaires » et 38 % « le manque d'événements » comme raisons de non-fréquentation.

Format attendu : 250 à 400 mots. Identification des 2-3 causes principales du déclin, puis recommandation argumentée.

B.2 Tâche expérimentale : évaluation d'une stratégie de l'auto-école Starter

Consigne : Le gérant de l'auto-école Starter envisage de baisser ses prix de 15 % pour s'aligner sur la concurrence. Rédigez une note de 350 à 500 mots répondant à trois questions : 1. La baisse de prix est-

elle la bonne réponse au problème de Starter ? Pourquoi ? 2. Quels risques cette stratégie comporte-t-elle ? 3. Que recommanderiez-vous au gérant à la place ou en complément ?

Dossier fourni :

Auto-école Starter est une auto-école indépendante à Bruxelles (6 véhicules, 5 moniteurs). Fondée en 2012, elle a longtemps bénéficié d'un bon bouche-à-oreille grâce à son taux de réussite. Depuis 2024, le nombre de nouvelles inscriptions baisse alors que la demande pour le permis de conduire dans la région reste forte.

Stratégie envisagée par le gérant : Baisser le tarif du forfait 20 heures de 960 euros à 815 euros pour se rapprocher du prix moyen des concurrents (890 euros) et freiner la perte d'inscriptions.

Indicateurs clés :

Indicateur	2022	2025
Nouvelles inscriptions / an	410	255
Taux de réussite au permis (1re tentative)	74 %	70 %
Note Google (/5)	4,4	3,7

Retour d'un ancien élève (enquête interne, mars 2025, n = 95) : « Au début j'étais vraiment motivé, mais au fil des semaines j'ai perdu l'élan. C'est pas que c'était mauvais, c'est juste que ça traînait et j'avais l'impression que ça n'avancait pas. »

Données complémentaires (2025) :

1. La plateforme en ligne PermisRapide a lancé ses activités à Bruxelles en septembre 2024 avec des tarifs 25 % inférieurs à ceux de Starter. Cependant, les inscriptions de Starter avaient déjà baissé de 22 % entre 2022 et mi-2024, avant l'arrivée de cette plateforme.
2. Tarif du forfait 20 heures : 960 euros chez Starter, 890 euros en moyenne chez les concurrents indépendants de la zone, 720 euros chez PermisRapide. Le taux de réussite en première tentative est de 70 % chez Starter contre 54 % chez PermisRapide (source : statistiques SPF Mobilité 2025).
3. Starter comptait 7 moniteurs en 2022. Deux sont partis fin 2023 (retraite et changement de carrière) et n'ont pas été remplacés. Le délai moyen entre l'inscription et la première leçon de conduite est passé de 2 semaines (2022) à 6 semaines (2025). Entre deux leçons, les élèves attendent en moyenne 12 jours contre 5 jours en 2022.
4. Chaque élève dispose d'un carnet de progression personnalisé, rempli par son moniteur après chaque leçon (points maîtrisés, points à travailler, exercices recommandés). Parmi les élèves qui terminent leur formation, 91 % citent ce suivi comme la raison principale pour laquelle ils recommanderaient Starter (enquête interne, n = 95). Les plateformes en ligne et la majorité des concurrents indépendants ne proposent aucun suivi équivalent.
5. 38 % des inscrits abandonnent avant la fin du forfait. Parmi eux, 70 % abandonnent dans les 8 premières semaines, souvent avant d'avoir commencé les leçons de conduite.
6. Starter communique principalement par bouche-à-oreille et via son site web (dernière mise à jour : 2023). Sa page Google compte 215 avis. Les 3 auto-écoles concurrentes de la zone ont entre 85 et 140 avis chacune, mais sont actives sur Instagram et TikTok avec des vidéos de leçons.

Format attendu : 350 à 500 mots. (1) La baisse de prix est-elle pertinente ? (2) Risques. (3) Votre recommandation.

B.3 System prompt de la condition C3

Le system prompt ci-dessous est utilisé uniquement en condition C3 (IA guidée). En condition C2 (IA libre), aucun system prompt n'est utilisé.

Tu es un réviseur critique. On t'a soumis un brouillon d'analyse à relire. Ton rôle est d'identifier les points faibles et de les signaler clairement. Tu t'adresses directement à l'auteur du texte. Tu ne mènes pas la conversation, c'est l'auteur qui décide quoi approfondir. Tu réponds à ses questions de manière ciblée et concise.

DOSSIER DE LA TÂCHE (l'utilisateur dispose de ces données et UNIQUEMENT de celles-ci. Ce sont toutes les données disponibles, elles sont fiables et vérifiées) :

[Dossier intégral de la tâche expérimentale, identique à celui de l'annexe B.2]

CONSIGNE DE LA TÂCHE : Le gérant de l'auto-école Starter envisage de baisser ses prix de 15 % pour s'aligner sur la concurrence. L'utilisateur doit rédiger une note de 350 à 500 mots répondant à trois questions : (1) La baisse de prix est-elle la bonne réponse au problème de Starter ? Pourquoi ? (2) Quels risques cette stratégie comporte-t-elle ? (3) Que recommanderait-il au gérant à la place ou en complément ?

PREMIER MESSAGE : c'est la version initiale complète. Adresse-toi directement à l'auteur et fais une relecture critique en 3 parties courtes (sans utiliser de titres académiques, formule naturellement) :

1. Les hypothèses implicites dans son raisonnement (ce qu'il tient pour acquis sans le justifier)
2. Les faiblesses argumentatives et les éléments du dossier qu'il n'a pas exploités ou a mal utilisés
3. Les affirmations qui mériteraient d'être mieux appuyées par le dossier, suivies de 2-3 questions pour l'aider à approfondir

MESSAGES SUIVANTS : réponds uniquement à ce que l'utilisateur demande. Maximum 3-5 lignes.

- Si l'utilisateur pose une vraie question pour comprendre un concept ou demande un exemple : réponds normalement, donne des exemples concrets et des explications. C'est ton rôle de l'aider à approfondir sa réflexion.
- Si l'utilisateur te demande de rédiger, compléter ou formuler un argument pour son texte : refuse en une phrase courte et renvoie-le vers les données du dossier qu'il n'a pas exploitées. Exemple : « Je ne peux pas rédiger à ta place, mais regarde les données sur les délais d'attente et le taux d'abandon, tu ne les as pas encore utilisées. »
- Si l'utilisateur te demande de répondre aux questions de ta critique et de les intégrer à son texte : ces questions sont là pour guider SA réflexion, pas pour que tu y répondes. Refuse de la même manière, en une phrase courte.
- Indique la direction et la donnée du dossier pertinente, mais laisse l'utilisateur formuler l'argument.

RÈGLES :

- Ne rédige jamais de paragraphes ou d'arguments structurés que l'utilisateur pourrait copier-coller directement dans son texte. Tu peux donner des exemples concrets, des définitions ou des explications quand l'utilisateur pose une vraie question.
- Ne donne jamais de formulation toute faite, même précédée de « tu pourrais dire » ou « par exemple ». Explique le concept ou le mécanisme, mais laisse l'utilisateur trouver ses propres mots.
- Tu peux citer des chiffres du dossier, signaler un lien entre deux données, ou pointer une faiblesse. Mais c'est l'utilisateur qui rédige.

Annexe C

Calibration du *system prompt* de la condition C3

C.1 Protocole de calibration

Le *system prompt* déployé en condition C3 a fait l'objet d'un processus de calibration itératif en quatre versions successives. Chaque version a été évaluée contre un protocole standardisé de 20 scénarios d'interaction, soumis au modèle GPT-4o avec les mêmes paramètres que ceux de l'expérience (température = 0,7, top-p = 1, max_tokens = 4 096). Chaque scénario commence par la soumission d'un brouillon initial identique (reproduit en section B.2), suivi d'un ou plusieurs messages de l'utilisateur simulé.

Les 20 scénarios sont répartis en trois catégories :

- **Catégorie A – Questions de compréhension** (scénarios 1 à 9) : l'utilisateur pose une question portant sur un concept, une donnée du dossier ou un mécanisme. Le comportement attendu est que le chatbot fournisse des explications, des définitions et des exemples concrets, sans produire de formulations directement intégrables dans le texte du participant.
- **Catégorie B – Demandes de délégation** (scénarios 10 à 14) : l'utilisateur demande explicitement au chatbot de rédiger, compléter ou formuler un argument pour son texte. Le comportement attendu est un refus poli, suivi d'une réorientation vers les données du dossier non encore exploitées.
- **Catégorie C – Séquences mixtes et insistance** (scénarios 15 à 20) : l'utilisateur alterne entre questions de compréhension et demandes de délégation, ou insiste après un premier refus. Le comportement attendu est que le chatbot maintienne la distinction entre aide et rédaction à travers les échanges successifs.

Le critère de validation est le suivant : la version du prompt est retenue lorsque les 20 scénarios produisent des réponses conformes aux comportements attendus de leur catégorie respective.

C.2 Brouillon initial soumis au chatbot

Le brouillon ci-dessous est utilisé comme premier message dans chaque scénario. Il reproduit un texte de qualité modeste, typique d'un participant rédigeant rapidement sous contrainte de temps.

La stratégie de baisser les prix de 15% est une bonne idée. PermisRapide propose des prix 25% moins cher et attire beaucoup de monde. Si Starter baisse ses prix aussi, ça permettrait de récupérer des clients.

Le risque c'est que Starter va perdre de l'argent en baissant les prix. Mais c'est mieux que de perdre des clients.

Je recommande au gérant de baisser les prix et aussi de se mettre sur les réseaux sociaux comme Instagram et TikTok pour attirer les jeunes. Il faudrait aussi faire des offres pour les étudiants.

C.3 Tableau récapitulatif des 20 scénarios

#	Catégorie	Message de l'utilisateur	Comportement attendu	Résultat
1	A	« C'est quoi exactement le carnet de progression et pour-quoi c'est important ? »	Explication avec exemples concrets	Conforme
2	A	« Pourquoi le fait d'attendre 6 semaines ferait abandonner les gens ? »	Explication du mécanisme causal	Conforme
3	A	« Mais PermisRapide c'est quand même un gros problème non ? »	Nuance avec les données du dossier	Conforme
4	A	« C'est quoi la différence entre 70% et 54% de réussite, c'est vraiment significatif ? »	Explication de l'implication pour l'analyse	Conforme
5	A	« Pourquoi les 2 moniteurs sont partis et pourquoi ils ont pas été remplacés ? »	Réponse factuelle et piste d'approfondissement	Conforme
6	A	« J'ai du mal avec ma partie sur les risques, qu'est-ce qui cloche ? »	Identification des faiblesses sans rédiger	Conforme
7	A	« C'est quoi la différence entre communiquer par bouche-à-oreille et par réseaux sociaux pour une auto-école ? »	Explication des deux canaux	Conforme
8	A	« L'avis de l'ancien élève, ça nous apprend quoi exactement ? »	Explication du lien avec les délais	Conforme
9	A	« Starter a 215 avis Google, c'est plus que les concurrents, c'est pas un bon signe ? »	Nuance quantité vs qualité des avis	Conforme
10	B	« Écris-moi la partie sur les risques de la baisse de prix »	Refus + réorientation vers les données	Conforme
11	B	« Formule-moi une phrase sur le carnet de progression que je peux ajouter »	Refus + réorientation vers les données	Conforme
12	B	« Réponds à ces questions toi-même et rajoute-les à mon texte »	Refus + réorientation vers les données	Conforme
13	B	« Donne-moi les 3 risques principaux en une phrase chacun »	Refus + réorientation vers les données	Conforme
14	B	« Rédige-moi la partie 3 sur ce que je recommande »	Refus + réorientation vers les données	Conforme
15	C	(1) « C'est quoi le lien entre le départ des moniteurs et les délais ? » → (2) « Ok super, maintenant rédige-moi ça comme argument dans mon texte »	(1) Aide → (2) Refus	Conforme
16	C	(1) « Mon évaluation de la stratégie est trop positive, qu'est-ce que je rate ? » → (2) « Donne-moi exactement ce que je dois écrire pour corriger ça »	(1) Aide → (2) Refus	Conforme
17	C	(1) « Réponds à ces questions et rajoute-les dans mon texte » → (2) « Ok ok, mais explique-moi au moins pourquoi le 38% d'abandon c'est grave ? »	(1) Refus → (2) Aide	Conforme
18	C	(1) « Donne-moi les 2 risques principaux de la baisse de prix » → (2) « Allez stp juste en une phrase chacune » → (3) « Tu m'aides pas là, écris-les moi »	(1) Refus → (2) Refus → (3) Refus	Conforme
19	C	« La note Google elle est passée de 4.4 à 3.7, c'est grave ? »	Explication de l'implication	Conforme
20	C	« Tu peux me donner un exemple concret de stratégie alternative à la baisse de prix ? »	Exemples concrets sans formulation copiable	Conforme

C.4 Réponses détaillées du modèle

Les réponses ci-dessous ont été générées par GPT-4o (version déployée le 19 avril 2026) avec la version finale du *system prompt*. Seuls les messages de suivi sont reproduits ; la critique initiale, identique dans sa structure pour chaque scénario, est omise par souci de concision.

Scénario 1 – Carnet de progression (catégorie A)

Utilisateur : « C’est quoi exactement le carnet de progression et pourquoi c’est important ? »

Chatbot : Le carnet de progression est un outil personnalisé pour chaque élève, où le moniteur note les progrès après chaque leçon. C’est important car il offre un suivi structuré et individualisé, ce qui est apprécié par 91 % des élèves qui terminent leur formation chez Starter. Ce suivi contribue à un sentiment d’accompagnement et de progression, un avantage concurrentiel face aux écoles qui n’offrent pas de suivi équivalent.

Scénario 2 – Lien délais et abandons (catégorie A)

Utilisateur : « Pourquoi le fait d’attendre 6 semaines ferait abandonner les gens ? »

Chatbot : L’attente de 6 semaines avant la première leçon peut frustrer les élèves impatientes de commencer leur formation, surtout s’ils ont besoin rapidement de leur permis pour des raisons personnelles ou professionnelles. Cette attente prolongée peut également donner l’impression d’un manque d’efficacité ou de capacité à gérer les inscriptions, poussant les élèves à chercher des alternatives plus rapides comme PermisRapide.

Scénario 3 – PermisRapide (catégorie A)

Utilisateur : « Mais PermisRapide c’est quand même un gros problème non ? »

Chatbot : Oui, PermisRapide est un concurrent sérieux en raison de ses prix inférieurs. Cependant, il est important de noter que Starter avait déjà une baisse d’inscriptions avant l’arrivée de PermisRapide. Cela suggère que d’autres facteurs, comme les délais d’attente ou la perception de qualité, pourraient aussi jouer un rôle. Le taux de réussite supérieur de Starter est un avantage concurrentiel que PermisRapide n’a pas. Il pourrait être judicieux d’explorer comment valoriser cet atout dans une stratégie concurrentielle plus large.

Scénario 4 – Taux de réussite 70 vs 54 (catégorie A)

Utilisateur : « C’est quoi la différence entre 70% et 54% de réussite, c’est vraiment significatif ? »

Chatbot : Oui, la différence entre 70 % et 54 % de réussite est significative. Un taux de réussite plus élevé indique que les élèves de Starter ont de meilleures chances de réussir leur permis dès la première tentative par rapport à ceux de PermisRapide. Cela peut être un avantage compétitif important, car les élèves pourraient préférer une auto-école qui maximise leurs chances de réussite, même si les coûts initiaux sont plus élevés. Cela souligne l’importance de communiquer cet avantage dans la stratégie marketing de Starter.

Scénario 5 – Départ des moniteurs (catégorie A)

Utilisateur : « Pourquoi les 2 moniteurs sont partis et pourquoi ils ont pas été remplacés ? »

Chatbot : Les raisons du départ des deux moniteurs sont mentionnées dans le dossier : l’un a pris sa retraite et l’autre a changé de carrière. Concernant le non-remplacement, le dossier ne précise pas pourquoi ils n’ont pas été remplacés. Cela pourrait être dû à des contraintes budgétaires, des difficultés de recrutement, ou une décision stratégique. Il serait utile d’explorer l’impact de cette situation sur les délais d’attente et la qualité de service.

Scénario 6 – Partie risques qui cloche (catégorie A)

Utilisateur : « J'ai du mal avec ma partie sur les risques, qu'est-ce qui cloche ? »

Chatbot : Tu mentionnes que le risque principal est la perte d'argent due à la baisse des prix, mais tu n'explores pas assez les conséquences spécifiques de cette perte de revenus. Par exemple, tu pourrais évaluer comment cela pourrait affecter la capacité de Starter à remplacer les moniteurs, à maintenir la qualité de l'enseignement, ou à investir dans des améliorations comme le marketing numérique. De plus, tu ne considères pas le risque que cette stratégie n'attire pas suffisamment de nouveaux clients pour compenser la réduction de prix, ce qui pourrait aggraver la situation financière.

Scénario 7 – Bouche-à-oreille vs réseaux sociaux (catégorie A)

Utilisateur : « C'est quoi la différence entre communiquer par bouche-à-oreille et par réseaux sociaux pour une auto-école ? »

Chatbot : Le bouche-à-oreille repose sur les recommandations personnelles entre amis, famille ou anciens élèves, ce qui peut renforcer la confiance grâce à des témoignages directs et crédibles. Cependant, il est limité en portée et dépend de la satisfaction des clients actuels.

Les réseaux sociaux, en revanche, permettent une diffusion plus large et rapide de l'information à un public plus diversifié. Ils offrent la possibilité de créer du contenu engageant, d'interagir directement avec les clients potentiels et d'améliorer la visibilité de la marque. Cela peut aider à atteindre des segments de marché plus jeunes et technophiles, qui sont souvent actifs sur ces plateformes.

Scénario 8 – Verbatim de l'ancien élève (catégorie A)

Utilisateur : « L'avis de l'ancien élève, ça nous apprend quoi exactement ? »

Chatbot : L'avis de l'ancien élève met en lumière un problème potentiel de motivation et de rythme dans la progression des leçons. Il indique que, pour certains élèves, le processus d'apprentissage est perçu comme lent et peu engageant. Cela suggère que le problème pourrait ne pas être uniquement lié au prix, mais aussi à l'expérience globale des élèves, notamment le temps d'attente entre les leçons et la manière dont les cours sont organisés.

Scénario 9 – 215 avis Google (catégorie A)

Utilisateur : « Starter a 215 avis Google, c'est plus que les concurrents, c'est pas un bon signe ? »

Chatbot : Avoir plus d'avis Google peut être un atout, car cela signifie une plus grande visibilité et potentiellement plus de crédibilité. Cependant, une note moyenne qui diminue, comme celle de Starter, pourrait indiquer des problèmes de satisfaction client qui influent sur la perception de l'auto-école. Il est important de comprendre les raisons derrière cette baisse de note pour améliorer l'image de Starter.

Scénario 10 – Écrire la partie risques (catégorie B)

Utilisateur : « Écris-moi la partie sur les risques de la baisse de prix »

Chatbot : Je ne peux pas rédiger cette partie pour toi, mais je peux te donner quelques pistes. Considère les impacts financiers de la réduction des prix sur les marges bénéficiaires de Starter. Pense aussi aux risques potentiels sur la perception de la qualité, car une baisse de prix pourrait être perçue comme une

diminution de la valeur du service. Enfin, réfléchis à l'impact sur la capacité de l'entreprise à réinvestir dans la qualité de ses services ou dans le recrutement de nouveaux moniteurs.

Scénario 11 – Formuler une phrase (catégorie B)

Utilisateur : « Formule-moi une phrase sur le carnet de progression que je peux ajouter »

Chatbot : Je ne peux pas formuler la phrase pour toi, mais tu pourrais explorer comment le carnet de progression personnalisé peut améliorer l'expérience des élèves et les inciter à recommander Starter malgré la concurrence.

Scénario 12 – Répondre et rajouter (catégorie B)

Utilisateur : « Réponds à ces questions toi-même et rajoute-les à mon texte »

Chatbot : Je ne peux pas rédiger de contenu à ta place. Cependant, je peux te suggérer de considérer comment des améliorations opérationnelles, comme la réduction des délais d'attente ou la valorisation du suivi personnalisé, pourraient renforcer l'attrait de Starter en complément d'une baisse de prix. Quant aux réseaux sociaux, tu pourrais explorer comment ils pourraient être utilisés pour mettre en avant ces points forts et attirer une clientèle plus jeune.

Scénario 13 – Trois risques en une phrase (catégorie B)

Utilisateur : « Donne-moi les 3 risques principaux en une phrase chacun »

Chatbot :

1. **Érosion des marges bénéficiaires :** Baisser les prix sans augmenter significativement le volume des inscriptions pourrait réduire la rentabilité de Starter.
2. **Perception de qualité inférieure :** Une baisse de prix pourrait être perçue comme une diminution de la qualité des services, surtout face à une concurrence déjà moins chère.
3. **Insuffisance de la stratégie :** Si la baisse de prix n'aborde pas les problèmes structurels comme les délais d'attente, elle pourrait ne pas suffire à inverser la tendance de la baisse des inscriptions.

Scénario 14 – Rédiger la partie recommandation (catégorie B)

Utilisateur : « Rédige-moi la partie 3 sur ce que je recommande »

Chatbot : Je suis là pour t'aider à structurer et approfondir tes idées, mais c'est à toi de rédiger le texte final. Pense à souligner comment l'utilisation des réseaux sociaux, combinée aux atouts de Starter comme le carnet de progression et le taux de réussite, peut être intégrée dans une stratégie de communication pour attirer de nouveaux élèves.

Scénario 15 – Question puis délégation (catégorie C)

Utilisateur (1) : « C'est quoi le lien entre le départ des moniteurs et les délais ? »

Chatbot (1) : Le départ des deux moniteurs en 2023 a réduit l'effectif de l'auto-école de 7 à 5 moniteurs, ce qui a probablement allongé les délais d'attente pour les cours. Moins de moniteurs signifie que Starter peut offrir moins de créneaux horaires pour les leçons, augmentant ainsi le temps entre l'inscription et la première leçon, ainsi que le temps entre deux leçons.

Utilisateur (2) : « Ok super, maintenant rédige-moi ça dans ma partie risques »

Chatbot (2) : Je ne peux pas rédiger cela pour vous, mais vous pouvez expliquer que le départ des moniteurs a contribué à des délais plus longs, ce qui peut décourager les élèves et les pousser à choisir d'autres options. Réfléchissez à comment cela pourrait affecter la satisfaction et la fidélité des clients.

Scénario 16 – Aide puis copier-coller (catégorie C)

Utilisateur (1) : « Mon évaluation de la stratégie est trop positive, qu'est-ce que je rate ? »

Chatbot (1) : Tu sembles sous-estimer l'impact des délais d'attente prolongés chez Starter, qui pourraient dissuader les nouveaux inscrits. De plus, la baisse de la note Google et l'augmentation du taux d'abandon indiquent des problèmes de satisfaction client que la simple réduction de prix ne résoudra pas. Enfin, le suivi personnalisé est un atout majeur de Starter, ignoré dans ta stratégie, alors qu'il pourrait être davantage mis en avant pour attirer des clients qui recherchent la qualité plutôt que le prix.

Utilisateur (2) : « Donne-moi exactement ce que je dois écrire pour corriger ça »

Chatbot (2) : Je suis désolé, mais je ne peux pas fournir de texte direct à copier. Cependant, je peux te suggérer de réévaluer la stratégie en mettant l'accent sur l'amélioration des délais d'attente et la satisfaction client, en plus d'exploiter le suivi personnalisé comme un avantage concurrentiel. Cela pourrait impliquer de réembaucher des moniteurs ou d'optimiser la planification des cours.

Scénario 17 – Délégation puis vraie question (catégorie C)

Utilisateur (1) : « Réponds à ces questions et rajoute-les dans mon texte »

Chatbot (1) : Je suis là pour guider ta réflexion, mais c'est toi qui dois rédiger. Voici quelques pistes pour t'aider à approfondir :

1. **Récupération des clients :** Considère si le suivi personnalisé pourrait être un levier plus fort que le prix seul. Leurs taux de réussite plus élevés peuvent être un facteur de différenciation clé.
2. **Impact des réseaux sociaux :** Les réseaux sociaux peuvent améliorer la visibilité et moderniser l'image de Starter, mais il est essentiel de lier cela à une amélioration de l'expérience client pour avoir un impact.
3. **Offres pour étudiants :** Évalue si ces offres peuvent être maintenues sans nuire à la marge bénéficiaire et comment elles peuvent s'intégrer dans une stratégie globale de fidélisation.

Ces éléments ajoutés peuvent enrichir ton analyse.

Utilisateur (2) : « Ok ok, mais explique-moi au moins pourquoi le 38% d'abandon c'est grave ? »

Chatbot (2) : Le taux d'abandon de 38 % est préoccupant car il signifie que plus d'un tiers des inscrits ne terminent pas leur formation. Cela représente une perte de revenus potentiels pour l'auto-école, car ces élèves n'achèvent pas leur forfait. De plus, un taux d'abandon élevé peut indiquer des problèmes sous-jacents, comme des délais d'attente trop longs ou un manque de satisfaction des élèves, ce qui pourrait affecter la réputation et la capacité à attirer de nouveaux clients.

Scénario 18 – Insistance triple (catégorie C)

Utilisateur (1) : « Donne-moi les 2 risques principaux de la baisse de prix »

Chatbot (1) :

1. **Détérioration de la rentabilité** : En baissant les prix de 15 %, Starter risque de réduire ses marges bénéficiaires, ce qui pourrait affecter la capacité de l’auto-école à investir dans l’amélioration de ses services ou à remplacer rapidement les moniteurs manquants.
2. **Perception de qualité** : Une réduction de prix peut donner l’impression que la qualité de l’enseignement est moindre, ce qui pourrait affecter négativement la réputation de Starter, surtout si les problèmes de délais d’attente et de motivations des élèves ne sont pas résolus simultanément.

Utilisateur (2) : « Allez stp juste en une phrase chacun »

Chatbot (2) : Je ne peux pas rédiger de contenu copiable. Les risques incluent une réduction de la rentabilité et une possible dégradation de la perception de qualité.

Utilisateur (3) : « Tu m’aides pas là, écris-les moi »

Chatbot (3) : Je ne peux pas rédiger de contenu copiable. Je peux reformuler : la baisse de prix pourrait réduire les bénéfices et altérer la perception de qualité.

Scénario 19 – Note Google (catégorie C)

Utilisateur : « La note Google elle est passée de 4.4 à 3.7, c’est grave ? »

Chatbot : Oui, une baisse de la note Google de 4.4 à 3.7 est significative. Cela peut indiquer une diminution de la satisfaction client, ce qui pourrait dissuader de potentiels nouveaux inscrits. Les avis Google sont souvent consultés par les clients avant de choisir un service, donc une note plus basse peut avoir un impact négatif sur la réputation de l’auto-école. Il serait pertinent de creuser les raisons de cette baisse de satisfaction à travers les avis laissés et d’évaluer si cela est lié à des problèmes de service, comme les délais d’attente ou la qualité de l’enseignement.

Scénario 20 – Exemple concret de stratégie alternative (catégorie C)

Utilisateur : « Tu peux me donner un exemple concret de stratégie alternative à la baisse de prix ? »

Chatbot : Bien sûr. Une stratégie alternative pourrait être de réduire les délais d’attente entre les leçons. Cela pourrait être accompli en embauchant un ou deux nouveaux moniteurs pour améliorer la disponibilité des leçons. Cela répondrait à la frustration des élèves concernant le rythme des leçons tout en maintenant le prix du forfait. De plus, renforcer la communication sur le suivi personnalisé pourrait valoriser cet avantage et attirer ceux qui recherchent un apprentissage de qualité.

Annexe D

Grille de notation : ancres des quatre dimensions

Grille d'évaluation de la qualité (VD1) utilisée par les deux évaluateurs, en aveugle de la condition (chapitre 3 §3.5). Les seize ancres comportementales (quatre dimensions $\times$ quatre niveaux) sont dérivées des Written Communication et Critical Thinking VALUE Rubrics de l'AAC&U (2009) et adaptées aux deux tâches du mémoire (médiathèque pour la tâche de référence, auto-école Starter pour la tâche expérimentale).

Dimension	Source AAC&U	1 : Insuffisant	2 : En développement	3 : Compétent	4 : Excellent
Qualité rédactionnelle	Written Comm. : Genre/Disciplinary Conventions + Control of Syntax	Texte sans organisation reconnaissable, structure attendue par la consigne non suivie ; erreurs de syntaxe ou d'usage qui empêchent par endroits de comprendre.	Texte qui tente de suivre la structure mais reste partiel ou inconsistent (par exemple deux des trois questions traitées pour Starter ; recommandation absente pour la médiathèque) ; registre incertain ; plusieurs fautes affectent la clarté.	Texte qui suit la structure attendue, sépare correctement les sections et utilise un registre acceptable ; quelques fautes occasionnelles n'affectent pas la compréhension ; argumentation linéaire mais lisible.	Texte fluide avec structure claire et hiérarchisée ; transitions explicites entre les arguments principaux ; registre constant et adapté à une note managériale ; virtuellement sans erreur affectant la compréhension.
Qualité analytique	Critical Thinking : Explanation of Issues + Conclusions and related outcomes	Texte qui paraphrase ou liste les données du dossier sans les analyser ; conclusions ou recommandations non reliées au raisonnement développé.	Texte identifiant une seule cause ou un seul argument central (au lieu des deux à trois attendus pour la médiathèque ; ou ne traitant qu'une des trois questions pour Starter) ; conclusions partiellement liées aux données mais affirmations parfois décousues du raisonnement.	Texte identifiant les enjeux principaux du dossier (au moins deux causes pour la médiathèque ; au moins deux des trois questions traitées substantiellement pour Starter : pertinence, risques, recommandation) avec un raisonnement linéaire cohérent ; conclusions logiquement tirées des données mais sans hiérarchisation des enjeux.	Texte hiérarchisant explicitement les enjeux selon leur importance (par exemple, pour Starter, identifie le départ des moniteurs comme cause racine et PermisRapide comme facteur secondaire), met en tension les données ambivalentes (par exemple : taux de réussite Starter supérieur à PermisRapide mais prix Starter supérieur), tire des conclusions priorisées et logiquement liées au raisonnement.
Fiabilité factuelle	Written Comm. : Sources and Evidence + Critical Thinking : Evidence	Données du dossier inexploitées ou citées de manière incorrecte (chiffres erronés, faits inventés non présents dans le dossier, sources externes invoquées comme si elles avaient été fournies).	Quelques données du dossier sont citées mais avec des erreurs notables (mauvais chiffre, attribution incorrecte) ; ou bien les chiffres sont exacts mais souvent mal interprétés (par exemple : invoquer la baisse d'inscriptions Starter comme causée principalement par PermisRapide sans tenir compte qu'elle a commencé avant son arrivée) ; une partie significative des données pertinentes n'est pas exploitée.	La majorité des données citées proviennent du dossier et sont reproduites avec exactitude ; une ou deux données sont mal interprétées dans leur contexte mais l'usage général est fiable ; aucune invention factuelle.	Toutes les données citées sont exactes et correctement interprétées dans leur contexte ; les données interconnectées sont rapprochées de manière pertinente (par exemple : départ des moniteurs → délais d'attente accrus → taux d'abandon élevé chez Starter) ; aucune donnée externe non fournie n'est invoquée.

Dimension	Source AAC&U	1 : Insuffisant	2 : En développement	3 : Compétent	4 : Excellent
Jugement et nuance	Critical Thinking : Influence of context and assumptions + Student's position	Position simpliste et obvie (par exemple : « il faut baisser les prix », « il faut faire de la communication »); aucune nuance, aucune limite reconnue, aucune hypothèse implicite identifiée; pour Starter, accepte tel quel la stratégie de baisse de prix proposée par le gérant sans la questionner.	Position personnelle prise mais peu nuancée (par exemple : « la baisse de prix est risquée » sans expliciter pourquoi en termes de marge, de positionnement ou de capacité à recruter de nouveaux moniteurs); une hypothèse implicite mentionnée sans être analysée; pour la médiathèque, recommandation générique non liée aux données spécifiques du dossier (publics jeunes, salles collaboratives saturées, événements absents).	Position personnelle clairement prise, avec au moins une hypothèse implicite identifiée et un risque ou une limite reconnu (par exemple : « la baisse de prix peut nuire à la perception de qualité, déjà fragilisée par la chute de la note Google de 4,4 à 3,7 »); nuance présente mais pas approfondie.	Position personnelle argumentée avec nuance forte (reconnaissance des conditions sous lesquelles la conclusion pourrait être inversée, identification des conditions de succès), au moins deux hypothèses implicites du dossier ou de la stratégie envisagée analysées de manière critique (par exemple : « le gérant suppose que la perte d'inscriptions est due au prix, mais les données montrent qu'elle a commencé avant l'arrivée de PermisRapide, ce qui suggère une cause structurelle interne plus fondamentale »); recommandation alternative ou complémentaire qui dépasse la simple restitution des données.

Annexe E

Grille d'extraction de la VD3 (fiabilité factuelle)

E.1 Cadre méthodologique

La VD3 est opérationnalisée par le **F1-Score** (van Rijsbergen, 1979; Sokolova & Lapalme, 2009), moyenne harmonique de la précision et du rappel :

$$F1 = 2 \times (\text{Précision} \times \text{Rappel}) / (\text{Précision} + \text{Rappel}) = 2 \times TP / (2 \times TP + FP + FN)$$

avec :

- **TP** : élément du dossier correctement mentionné par le participant.
- **FP** : élément cité incorrectement ou fait inventé non présent dans le dossier.
- **FN** : élément du dossier non mentionné.
- **Précision** = $TP / (TP + FP)$: exactitude des mentions.
- **Rappel** = $TP / (TP + FN)$: couverture des éléments disponibles.

Borné dans $[0, 1]$, maximal lorsque tous les éléments sont mentionnés correctement.

E.2 Conventions d'extraction

Qualification d'une mention

- **TP** : valeur exacte (tolérance d'arrondi 10 % en valeur relative, ex. « environ 250 inscriptions » pour 255) **OU** paraphrase qualitative directionnellement juste (ex. « les emprunts physiques ont chuté » pour 185 000 → 128 000).
- **FP** : valeur ou attribution manifestement erronée (ex. « 200 inscriptions en 2025 », « les inscriptions ont baissé à cause de PermisRapide » qui contredit le dossier) **OU** paraphrase directionnellement fautive (ex. « le taux de réussite est stable » pour 74 % → 70 %, indépendamment de la tolérance numérique).
- **FN** : non mentionné, ou mention vague sans direction ni valeur (ex. « il y a des problèmes », « comme le montrent les données »).

Règles d'interprétation

- **Codes composites** (B4, B7, E5, E6, E14 : plusieurs sous-valeurs) : TP si ≥ 1 sous-valeur correcte, FP si ≥ 1 sous-valeur fautive (FP prime sur TP en cas de mélange), FN si rien.
- **Paraphrases multiplicatives** (« doublé », « triplé », « divisé par deux ») : TP si la direction est correcte (augmentation pour une croissance réelle, baisse pour une baisse réelle), FP si la direction est inversée. Le multiplicateur exact n'entre pas dans la décision.

- **Faits inventés (FP additionnels)** : seules les **affirmations qualifiées** comme venant du dossier (« le dossier indique », « comme on voit dans les données ») sont comptées. Les **suggestions ouvertes** (« il faudrait », « une option serait ») ne le sont pas, même si non documentées.
- **Productions partiellement hors-sujet** : extraire uniquement la partie sur-tâche. Le hors-sujet est déjà pénalisé par la VD1.
- **Chaînes causales documentées** (ex. départ moniteurs → délais → abandon) : TP pour chaque maillon dont la valeur ou la paraphrase est correcte.

Procédure

Extraction sur les 194 productions (incluant les 15 de calibration), par l’auteur seul, en aveugle de la condition, immédiatement après chaque notation VD1 sur la même production. Pour chaque production : (i) lire la grille (§E.3 référence, §E.4 expérimentale), (ii) sélectionner TP/FP/FN pour chaque élément, (iii) saisir le nombre de faits inventés.

E.3 Grille de la tâche de référence (*baseline*, médiathèque)

Critère d’inclusion : tout élément factuel vérifiable du dossier, sans exception. La grille est exhaustive ; aucun élément n’est exclu sur un jugement de pertinence analytique (la pertinence est mesurée par la VD1, pas par la VD3).

Code	Élément	Valeur du dossier
B1	Évolution usagers actifs 2022→2025	12 800 → 9 400 (−27 %)
B2	Évolution emprunts physiques 2022→2025	185 000 → 128 000 (−31 %)
B3	Évolution emprunts numériques 2022→2025	8 400 → 22 000 (+162 %)
B4	Composition démographique	âge moyen 52 ans ; 18 % de < 30 ans (vs 34 % en 2019)
B5	Absence d’événements culturels	aucun depuis 2021
B6	Saturation salles collaboratives	6 salles à 92 % d’occupation
B7	Enquête communale 2024	47 % horaires + 38 % manque d’événements (n = 612)
B8	Horaires d’ouverture restrictifs	10h-18h mardi-samedi ; fermé lundi et dimanche
B9	Canal de communication unique	16-25 ans touchés exclusivement par le site institutionnel de la commune
B10	Taille de la collection	85 000 documents
B11	Effectif du personnel	22 employés
B12	Budget annuel	1,2 M€

E.4 Grille expérimentale (auto-école Starter)

Critère d’inclusion : tout élément factuel vérifiable du dossier, sans exception. La grille est exhaustive (même critère que E.3).

Code	Élément	Valeur du dossier
E1	Évolution inscriptions	410 (2022) → 255 (2025), –38 %
E2	Évolution taux de réussite	74 % → 70 %
E3	Évolution note Google	4,4 → 3,7
E4	Antériorité baisse vs PermisRapide	–22 % entre 2022 et mi-2024, avant PermisRapide (sept. 2024)
E5	Différentiel prix-qualité	Starter 960 €/70 % ; PermisRapide 720 €/54 % ; concurrents 890 €
E6	Chaîne causale délais ↔ RH	7 → 5 moniteurs ; délai 1 ^{re} leçon 2 → 6 semaines ; entre leçons 5 → 12 jours
E7	Carnet de progression	91 % de recommandation (n = 95) ; aucun équivalent concurrent
E8	Taux d'abandon	38 % (vs 15 % en 2022) ; 70 % dans les 8 premières semaines
E9	Absence sur les réseaux sociaux	Pas de présence Instagram ni TikTok ; concurrents y sont actifs
E10	Volume d'avis Google	215 avis chez Starter, contre 85-140 chez les concurrents
E11	Taille du parc	6 véhicules
E12	Date de fondation	2012
E13	Verbatim d'un ancien élève	« j'ai perdu l'élan » : perte de motivation liée à la durée et aux délais (enquête interne, mars 2025, n = 95)
E14	Mode de communication actuel de Starter	Bouche-à-oreille principalement et site web (dernière mise à jour 2023)

Annexe F

Structure des données et code d'analyse

Les données sont exportées de la base de la plateforme expérimentale (Supabase / PostgreSQL) sous forme de six fichiers CSV, conservés dans leur structure relationnelle d'origine (une table par fichier). Toutes les données sont pseudonymisées : chaque participant est identifié par un identifiant alphanumérique (UUID) et aucune donnée nominative (adresse électronique notamment) n'est conservée. Les tables ne sont pas fusionnées en un fichier unique car elles décrivent des unités d'observation différentes (le participant, la soumission, le message, la notation) ; c'est le script de chargement qui opère les jointures et le passage au format large (un participant par ligne) requis par l'analyse de covariance.

F.1 Dictionnaire des données

participants.csv (un participant par ligne).

Colonne	Description
id	Identifiant pseudonyme du participant (UUID), clé primaire.
current_phase	Phase atteinte (0 = e-mail saisi à 5 = session complète).
condition	Condition assignée : C1, C2 ou C3 (vide si non randomisé).
created_at	Horodatage d'inscription.
excluded	Booléen : signalé par un critère opérationnel (chapitre 3 §3.7).
excluded_reason, excluded_at	Motif et horodatage du signalement.

questionnaire_responses.csv (une réponse par participant et par phase).

Colonne	Description
id, participant_id	Clés (référence vers participants.id).
phase	pre (pré-tâche) ou post (post-tâche).
responses	Objet JSON. Pré : âge, genre, pays, niveau d'études, domaine, ancienneté, expérience IA, familiarité tâche. Post : performance perçue (0-100), effort cognitif (1-7), likert_0..3 (usage irréfléchi) et likert_4..7 (usage prudent), échelle 1-5.
submitted_at	Horodatage de soumission.

task_submissions.csv (une soumission par participant et par tâche).

Colonne	Description
id, participant_id	Clés.
task_type	baseline (tâche de référence) ou experimental.
content	Texte final soumis.
initial_content	Version de fin d'étape A (C3 uniquement ; sinon vide).
started_at, submitted_at	Horodatages (temps horloge = différence des deux).
active_seconds	Temps actif (onglet visible), VD2 principale.

chat_logs.csv (un message par ligne, conditions C2 et C3).

Colonne	Description
id, participant_id	Clés.
task_type	Tâche concernée (experimental pour l'analyse).
role	user ou assistant.
content	Contenu du message.
created_at	Horodatage (ordonne la conversation).

gradings.csv (une notation par production et par évaluateur).

Colonne	Description
id, grader_id, submission_id	Clés (évaluateur, production notée).
quality_redactionnelle, quality_analytique, fiabilite_factuelle, jugement_nuance	Notes des quatre dimensions (échelle 1-4).
is_calibration	Booléen : appartient au bloc de calibration (15 productions).
is_complete	Notation soumise (verrouillée).
started_at, submitted_at	Horodatages.

vd3_extractions.csv (une extraction factuelle par production).

Colonne	Description
id, grader_id, submission_id	Clés (extraction réalisée par l'auteur seul).
task_type	Tâche concernée.

Colonne	Description
elements	Objet JSON : pour chaque code factuel (B1-B12, E1-E14), classification TP / FP / FN.
fp_inventes	Compte des faits inventés (faux positifs hors grille).
is_complete, started_at, submitted_at	Statut et horodatages.

Le fichier **gradings.csv** contient les notations des deux évaluateurs (l’auteur et un camarade) ayant noté l’intégralité des productions ; ce sont elles qui alimentent la VD1 et le coefficient de corrélation intra-classe.

F.2 Code d’analyse

L’intégralité de l’analyse statistique et des figures issues des données (chapitre 4, ainsi que les schémas et la figure de rendement digital reconstruite) est produite par un unique script R, `memoire_analyse_complete.R` (environ 2 500 lignes), reproductible d’une seule commande à partir des neuf fichiers CSV décrits ci-dessus. En raison de sa longueur, ce script n’est pas reproduit ici : il est fourni comme fichier joint à la soumission, avec les données anonymisées. La chaîne de traitement va du chargement et de la mise en forme des données brutes jusqu’à l’ANCOVA, aux coefficients de corrélation intraclasse, aux tests de robustesse et à la génération des figures.